



**ESCUELA TÉCNICA SUPERIOR DE
INGENIERÍA DE TELECOMUNICACIÓN**

GRADO EN INGENIERÍA BIOMÉDICA

TRABAJO FIN DE GRADO

**FILTRADO AVANZADO DE LA SEÑAL DE
EEG APLICADO EN NEUROMARKETING**

Autora: Noemí González Lois

Tutora: Rebeca Goya Esteban

Curso académico: 2019/ 2020

“El trabajo va a ocupar gran parte de tu vida. La única forma de estar realmente satisfecho es hacer aquello que crees que es un buen trabajo, y la única forma de hacer un buen trabajo es amar aquello que haces.”

Steve Jobs

Agradecimientos

Este proyecto de fin de grado pone fin a una importante etapa de mi vida. Durante los últimos cuatro años ha habido algunos momentos difíciles, pero sin embargo, en ningún momento sentí estar en el lugar equivocado. Me gustaría agradecer a todas las personas que me aconsejaron y animaron a estudiar el Grado de Ingeniería Biomédica, gracias a ellos hoy estoy más cerca de donde quiero estar.

Por otro lado, este año académico ha terminado muy diferente a cómo nos imaginábamos todos. La pandemia por Covid-19 nos ha obligado a reorganizar nuestras rutinas para adaptarnos a las nuevas necesidades, ya no sólo profesionales sino también personales. Doy las gracias a mi tutora Rebeca, por seguir ayudándome a completar este trabajo tan importante para mí, por su dedicación y su tiempo.

A mis padres, por haberme dado siempre su apoyo y su cariño, por facilitarme los largos días de estudio y trabajo intenso y por ayudarme a perseguir mis sueños.

A mis amigas de toda la vida, pero también a los que me llevo gracias a la universidad, por estar ahí siempre y por el apoyo mutuo en esta etapa tan dura e importante de nuestras vidas.

Por último, a mi misma por priorizar lo importante, exigirme mucho y ponerme metas altas. Espero poder seguir aprendiendo de lo que me gusta y que con eso ayude a mucha gente en el futuro.

Resumen

El marketing es un conjunto de técnicas bien conocidas para aumentar las ventas de un producto o la conciencia del público objetivo. Su unión con la neurociencia da lugar a una novedosa disciplina conocida como neuromarketing, la cual busca aportar una valoración objetiva y fiel del público al que van dirigidos los anuncios. Un caso especial de anuncios son los de servicio público (PSA, del inglés *Public Service Announcements*), algunos de los cuales forman parte de campañas de promoción de la salud. La finalidad de estos es promover hábitos saludables o informar al público sobre los efectos nocivos de actividades como el consumo de tabaco y alcohol.

En este Trabajo de Fin de Grado (TFG) se emplean las grabaciones de la señal de electroencefalografía (EEG) adquiridas en un experimento previo realizado en la Universidad Rey Juan Carlos (URJC). Las señales fueron adquiridas con un casco de electrodos secos en malla (usando el *actiCAP Xpress Twist* y el software *BrainVision Recorder*) durante la observación de seis anuncios pertenecientes a campañas de salud pública.

El objetivo de este TFG es el procesamiento y acondicionamiento de señales de EEG para posteriormente poder extraer información de calidad sobre la respuesta fisiológica frente a la observación de diferentes anuncios publicitarios. En primer lugar, se aplica un filtro notch y un filtro paso banda (2-40 Hz) para reducir la interferencia de la red eléctrica y acotar el contenido espectral de la señal eliminando también la línea de tendencia. Seguidamente, se aplica la técnica central de procesado de este TFG, el Análisis de Componentes Independientes (ICA, del inglés *Independent Component Analysis*). Esta técnica permite aislar fuentes independientes como los artefactos oculares de parpadeo y movimiento de los ojos, además de los artefactos cardíacos. Por último, se calcula el índice neurométrico de aproximación-retirada o AWI (del inglés *Approach Withdrawal Index*), que mide la diferencia de actividad cerebral en la banda alpha entre la corteza frontal de los dos hemisferios.

El algoritmo de ICA es un método apropiado para la extracción de artefactos fisiológicos en la señal de EEG. Tanto la calidad de la señal como un tamaño muestral adecuado son aspectos críticos para la obtención de índices indicativos de comportamientos del usuario.

PALABRAS CLAVE: Neuromarketing, ICA, AWI, procesado, bioseñal, EEG.

Índice general

Agradecimientos

Resumen

Índice de figuras	XIII
--------------------------	-------------

Índice de tablas	XVII
-------------------------	-------------

Lista de acrónimos	XIX
---------------------------	------------

1. Introducción	1
1.1. Contexto y motivación	1
1.2. Objetivos y estructura de la memoria	3
2. Revisión de conceptos y técnicas	5
2.1. Conceptos básicos	5
2.1.1. Organización Sistema Nervioso	5
2.1.2. Neurona	7
2.1.3. Actividad eléctrica	8
2.1.4. Técnicas de captación de señales neurofisiológicas	9
2.2. Electroencefalografía	10
2.2.1. Historia del EEG	10
2.2.2. Bases técnicas	11

2.2.3. Ritmos y formas de onda	12
2.2.4. Aplicaciones del EEG	14
3. Métodos	19
3.1. Filtros lineales	20
3.1.1. Conceptos previos	20
3.1.2. Tipos de filtros	23
3.2. Independent Component Analysis	25
3.3. Principal Component Analysis	30
3.4. Análisis espectral	31
3.4.1. Parámetros espectrales	34
3.4.2. Índices neurométricos	35
4. Experimentos y resultados	39
4.1. Base de datos	39
4.2. Filtrado básico	43
4.2.1. Experimentos con filtro paso alto	43
4.2.2. Experimentos con filtro banda	45
4.2.3. Experimentos con filtro Notch	48
4.3. Filtrado avanzado	50
4.4. Extracción de indicadores	56
5. Conclusiones y líneas futuras	61
5.1. Conclusiones	61
5.2. Líneas futuras	61
A. Anexos	63
A.1. PSD experimentos filtros básicos sujeto 2900	63
A.2. Mapas topográficos sujeto 2900	65

A.3. ICA Anuncio 5 sujeto 6401	72
--	----

Anexos

Bibliografía	77
---------------------	-----------

Índice de figuras

2.1.	Sección sagital media del encéfalo	6
2.2.	Esquema básico de una neurona	8
2.3.	Colocación de electrodos extracraneales según el Sistema Internacional 10-20 . .	12
2.4.	Esquema de registro monopolar y bipolar	12
2.5.	Ritmos electroencefalográficos	14
2.6.	Crisis epiléptica generalizada	15
2.7.	Ritmos y formas de onda características de las diferentes fases del sueño. . . .	16
2.8.	Esquema de los componentes de una BCI	17
3.1.	Diagrama de Bode de un filtro Notch	21
3.2.	Esquema de las bandas de un filtro digital no ideal	22
3.3.	Esquema del problema del <i>cocktail party</i>	26
3.4.	Ecuaciones matriciales ICA: <i>mixing</i> y <i>unmixing</i> signals	27
3.5.	Esquema del problema de separación ciega de fuentes en el EEG	29
3.6.	Topografía y forma de onda de artefactos fisiológicos comunes	30
3.7.	Transformada de Fourier de la ventana de Barlett	33
4.1.	Representación en tiempo de la señal de EEG sin procesar.	42
4.2.	PSD de la señal de EEG sin procesar	42
4.3.	PSD de la señal filtrada con distintos HPF	44
4.4.	Representación en tiempo de la señal de EEG filtrada con HPF de $f_c = 2$ Hz . .	44

4.5.	PSD de la señal filtrada con HPF con frecuencia de corte 2 Hz	45
4.6.	Diagrama de Bode del BPF	47
4.7.	Señal en tiempo filtrada con BPF con <i>filter_length</i> = 'auto'	47
4.8.	PSD de la señal filtrada con BPF con <i>filter_length</i> = 'auto'	48
4.9.	Señal en tiempo filtrada con filtro notch con <i>filter_length</i> = 'auto'	49
4.10.	PSD de la señal filtrada con filtro notch con <i>filter_length</i> = 'auto'	49
4.11.	ICA con 20 componentes	51
4.12.	ICA con 31 componentes	52
4.13.	Mapas topográficos de las componentes independientes	53
4.14.	Forma de onda y mapa topográfico de la componente independiente que captura el parpadeo	53
4.15.	Forma de onda y mapa topográfico de la componente independiente que captura el movimiento de los ojos	54
4.16.	Forma de onda y mapa topográfico de la componente independiente que captura ruido introducido por un electrodo	54
4.17.	Representación en tiempo del efecto del filtrado con ICA	55
4.18.	Representación de los AWI, sin normalizar	57
4.19.	Representación de la media de los AWI, sin normalizar	57
4.20.	Representación de los AWI, dividiendo por el AWI basal	58
4.21.	Representación de la media de los AWI, dividiendo por el AWI basal	59
4.22.	Representación AWI con normalización min-max	60
4.23.	Gráfica poblacional AWI con normalización min-max	60
A.1.	PSD de la señal de EEG filtrada con LPF de diferentes longitudes. Sujeto 2900, promedio de los 31 canales.	63
A.2.	PSD de la señal de EEG filtrada con BPF de diferentes longitudes. Sujeto 2900, promedio de los 31 canales.	64
A.3.	PSD de la señal de EEG filtrada con BPF y con HPF+LPF. Sujeto 2900, promedio de los 31 canales.	64

A.4. PSD de la señal filtrada con filtro notch de distintas longitudes	65
A.5. Mapa topográfico de las componentes independientes del sujeto 2900, minuto de actividad basal	66
A.6. Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 1	67
A.7. Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 2	68
A.8. Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 3	69
A.9. Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 4	70
A.10. Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 5	71
A.11. Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 6	72
A.12. Anuncio 5 paciente 6401 antes de aplicar ICA	73
A.13. Componentes independientes, anuncio 5 sujeto 6401	73
A.14. Mapas topográficos, anuncio 5 sujeto 6401	74
A.15. Anuncio 5 paciente 6401 después de aplicar ICA	75

Índice de tablas

4.1. Componentes independientes asociadas a artefactos en cada uno de los sujetos y tramos de la señal de EEG	56
4.2. Índices AW de cada tramo y media, sin normalizar	57
4.3. Índices AW de cada tramo y media, normalización según [1]	58
4.4. Índices AW de cada tramo y media, con normalización min-max	59

Lista de acrónimos

AWI Approach Withdrawal Index (en español, Índice de Aproximación-Retirada)

BCI Brain Computer Interface (en español, Interfaz Cerebro Ordenador)

BPF Band Pass Filter (en español, Filtro Paso Banda)

BSS Blind Source Separation (en español, Separación ciega de fuentes)

CEI Cerebral Effort Index (en español, Índice de Esfuerzo Cerebral)

DEP Densidad Espectral de Potencia

DFT Discrete Fourier Transform (en español, Transformada Discreta de Fourier)

ECG Electrocardiograma

ECoG Electrocorticograma

EDA Electrodermic Activity (en español, Actividad Electrodérmica)

EEG Electroencefalograma

EMG Electromiograma

EOG Electrooculograma

FC Frontal Cortex (en español, Corteza Frontal)

fMRI functional Magnetic Resonance Imaging (en español, Imagen por Resonancia Magnética funcional)

FOI Frecuencies Of Interest(en español, Frecuencias de Interés)

GFP Global Field Power (en español, Potencia de Campo Global)

- HPF** High Pass Filter (en español, Filtro Paso Alto)
- ICA** Independent Component Analysis (en español, Análisis de Componentes Independientes)
- LPF** Low Pass Filter (en español, Filtro Paso Bajo)
- MEG** Magnetoencefalograma
- ML** Maximum Likelihood
- PCA** Principal Component Analysis (en español, Análisis de Componentes Principales)
- pdf** probability density function (en español, función de densidad de probabilidad)
- PET** Positron Emission Tomography (en español, Tomografía por Emisión de Positrones)
- PFC** Prefrontal Cortex (en español, Corteza Prefrontal)
- PSA** Public Service Announcement (en español, Anuncios de Servicio Público)
- PSD** Power Spectral Density (en español, Densidad Espectral de Potencia)
- SNC** Sistema Nervioso Central
- SNP** Sistema Nervioso Periférico
- SN** Sistema Nervioso
- SPECT** Single Photon Emission Computed Tomography (en español, Tomografía Computarizada por Emisión de Fotón Único)
- SQUID** Superconducting Quantum Interference Devices (en español, Dispositivos Superconductores de Interferencia Cuántica)
- SSW** Sharp Slow Waves (en español, Ondas Agudas Lentas)
- TFG** Trabajo Fin de Grado
- TF** Transformada de Fourier
- UCI** Unidad de Cuidados Intensivos
- vmPFC** ventromedial Prefrontal Cortex (en español, Corteza Prefrontal Ventromedial)

Capítulo 1

Introducción

Este primer capítulo enmarca el proyecto en un contexto social, temporal y de la disciplina, al mismo tiempo que se detallan las motivaciones que llevaron a desarrollarlo. Seguidamente, se precisan los objetivos a alcanzar y, por último, se muestra la estructura de la memoria del Trabajo de Fin de Grado (TFG).

1.1. Contexto y motivación

Cada vez es más difícil ignorar la creciente incorporación de mensajes publicitarios en el día a día de las personas que viven en los países desarrollados. La publicidad llega a través de la televisión, los periódicos o el correo postal, y ahora también a través de las redes sociales y otros recursos de Internet. Algunos estudios señalan que la cantidad de información que recibe una persona en cada segundo es 10 millones de veces superior a la que se puede retener en la memoria [2]. Por ello, el interés acerca de producir anuncios eficientes y atractivos que llamen nuestra atención más que el resto es un área de grandes desafíos en el mundo actual del Marketing.

Tradicionalmente, la manera más común de testear productos y servicios ha sido entrevistar a grupos de consumidores o realizar encuestas de satisfacción. Ambos métodos son fáciles y baratos, ya que no requieren grandes recursos. Sin embargo, con el paso del tiempo se ha ido demostrando que la información proporcionada por los consumidores mediante estos métodos no es totalmente fiable. Esto se debe a que los consumidores no siempre revelan sus intereses de manera exacta, clara y sincera. De hecho, el desajuste entre lo que los consumidores expresan verbalmente y lo que piensan en realidad ha causado el fracaso de hasta el 70 % de los productos

lanzados al mercado mundial [2].

Teniendo esto en cuenta, algunos investigadores de la comunidad neurocientífica han volcado su trabajo en investigar las señales cerebrales durante la visualización de anuncios publicitarios. La neurociencia comprende el estudio de todos los aspectos relacionados con el sistema nervioso (SN) como son su estructura, las patologías asociadas, la bioquímica subyacente o el desarrollo ontogenético, entre otros. Un campo más concreto y muy avanzado de la neurociencia es el de la “neurociencia cognitiva”, el cual se basa en el estudio de las interacciones entre diferentes elementos del SN, dando lugar a las bases biológicas de la cognición y la conducta humanas [3]. Resulta de gran interés conocer el comportamiento de las distintas áreas del cerebro ante diferentes situaciones y estímulos, ya que, avances en este campo de la neurociencia posibilitan comprender patrones de conducta aplicables a otros campos como el del marketing.

El término neuromarketing fue acuñado en 2002 por el holandés Ale Smidts, y desde entonces ha dado lugar al aumento de la producción de artículos científicos relacionados con el área [4]. El neuromarketing podría definirse como el puente entre la neurociencia cognitiva y el marketing, con la pretensión de mejorar las estrategias de marketing de una compañía para dirigirla hacia su mercado de ventas específico, haciendo uso de las técnicas y conocimientos de la neurociencia [5].

Así, desde el punto de vista neurocientífico, la meta se basa en entender mejor los mecanismos neurológicos que afectan al proceso de cognición, elección y toma de decisiones. Para conseguir esta meta se necesitan una serie de métodos científicos que permitan estudiar esos mecanismos de manera fiable y objetiva. Los métodos de análisis de la señal del cerebro comprenden distintas técnicas, entre las que se encuentran la Imagen por Resonancia Magnética funcional (fMRI), el Electroencefalograma (EEG) o el Magnetoencefalograma (MEG), entre otros muchos. Estos métodos ofrecen perspectivas distintas acerca de qué ocurre en el cerebro de los consumidores durante la actuación de un estímulo publicitario.

En conclusión, el neuromarketing representa una de las primeras y más evidentes aplicaciones de la neurociencia a un área industrial no relacionada con la atención médica como es la evaluación de anuncios comerciales o marcas. Esta técnica se está haciendo cada vez más popular, y aunque todavía existen varias dificultades para relacionar ambas disciplinas no cabe duda de que su estudio se seguirá desarrollando en los años siguientes [2].

1.2. Objetivos y estructura de la memoria

Este proyecto tiene como objetivo principal el procesamiento y acondicionamiento de señales de EEG para posteriormente poder extraer información de calidad sobre la respuesta fisiológica frente a la observación de diferentes anuncios publicitarios. Principalmente, se estudian e implementan técnicas de filtrado básico y avanzado y análisis espectral de la señal. Para la consecución de este objetivo concreto se definen los siguientes objetivos específicos:

- Revisión de conceptos anatómicos y fisiológicos del SN.
- Revisión del estado del arte de las técnicas de captación de señales neurofisiológicas.
- Revisión del estado del arte de las técnicas de procesado de señal de EEG.
- Familiarización con la señal de EEG: visualización y representación.
- Preprocesamiento básico de la señal: localizar y aislar fuentes de ruido no fisiológicas mediante filtrado básico lineal. Diseño de filtros paso banda y rechaza banda.
- Preprocesamiento avanzado de la señal: aplicación del método de Análisis de Componentes Independientes.
- Extracción de un índice para la evaluación de la respuesta de cada sujeto a los diferentes anuncios mediante técnicas de análisis espectral de la señal utilizando la potencia en la banda de frecuencia alpha.

Para conseguir los objetivos propuestos, se ha realizado un trabajo de investigación del ámbito que nos ocupa, así como un repaso de los temas fundamentales para el correcto desarrollo del TFG. Por todo esto, la estructura de la memoria es como sigue:

- **Capítulo 1 - Introducción.** Se recoge una introducción del contexto y la importancia del estudio para la sociedad actual y la disciplina del Marketing además de presentar el objetivo principal del proyecto y la estructura de la memoria.
- **Capítulo 2 - Revisión de conceptos y técnicas.** Se realiza una breve explicación de los conceptos generales de este TFG, desde el punto de vista clínico.
- **Capítulo 3 - Métodos.** Se abordan las diferentes técnicas de procesado utilizadas, así como el método de extracción de características empleado en esta ocasión.

- **Capítulo 4 - Experimentos y resultados.** Se detallan los pasos seguidos en el desarrollo del proyecto, documentando con experimentos y aportando los resultados correspondientes en cada ocasión.
- **Capítulo 5 - Conclusiones y líneas futuras.** Se muestran las conclusiones obtenidas y se proponen posibles líneas de trabajo a tener en cuenta en futuras ampliaciones de este estudio.
- **Anexos.** Se recogen figuras adicionales relacionadas con experimentos o actividades realizados durante el desarrollo del proyecto que no han sido mostradas en el cuerpo de la memoria.

Todas las imágenes utilizadas en el desarrollo de este TFG son de elaboración propia o de dominio público disponibles en Internet.

Capítulo 2

Revisión de conceptos y técnicas

El segundo capítulo incluye un breve repaso de los conceptos generales relacionados con el tema central del TFG. En primer lugar, se abordan los conceptos más anatómicos y fisiológicos. Seguidamente, se ofrece información sobre la electroencefalografía, que, tal y como se explica en el *Capítulo 4*, es la técnica empleada para obtener las señales de la base de datos utilizada para el desarrollo del proyecto.

2.1. Conceptos básicos

En esta sección se abordan los conceptos tanto neuroanatómicos como neurofisiológicos para comprender la organización básica de las principales estructuras que forman el SN.

2.1.1. Organización Sistema Nervioso

Para poder comprender las bases biológicas del comportamiento humano es imprescindible conocer la organización de las diferentes estructuras del SN, ya que está involucrado en todas nuestras acciones, ya sean voluntarias o no. Existen diferentes criterios para la clasificación del SN.

La clasificación anatómica divide el SN en Sistema Nervioso Central (SNC) y Sistema Nervioso Periférico (SNP). Así, el SNC se compone de encéfalo y médula espinal mientras que el SNP consta de los nervios y los ganglios. Para el desarrollo de este Proyecto es esencial conocer las principales estructuras del SNC, en concreto del encéfalo, debido a que esta estructura es la responsable de las emociones humanas y de recibir e interpretar las señales que le llegan desde

el interior del organismo y desde el exterior. En la figura 2.1 se pueden apreciar las distintas estructuras del encéfalo. La corteza cerebral es la delgada lámina de sustancia gris que cubre la superficie de los hemisferios cerebrales. En ella ocurren la percepción, el pensamiento y la decisión, entre otras funciones que caracterizan al ser humano.

La clasificación funcional divide el SN en Sistema Nervioso Somático (SNS) y Sistema Nervioso Autónomo (SNA) o Vegetativo. El SNA se divide, a su vez, en Simpático y Parasimpático. El Sistema Nervioso Simpático predomina en situaciones de estrés y prepara al organismo frente a la huida o la lucha estimulando el gasto energético. Por el contrario, el Sistema Nervioso Parasimpático predomina en situaciones de relajación propiciando la reposición energética.

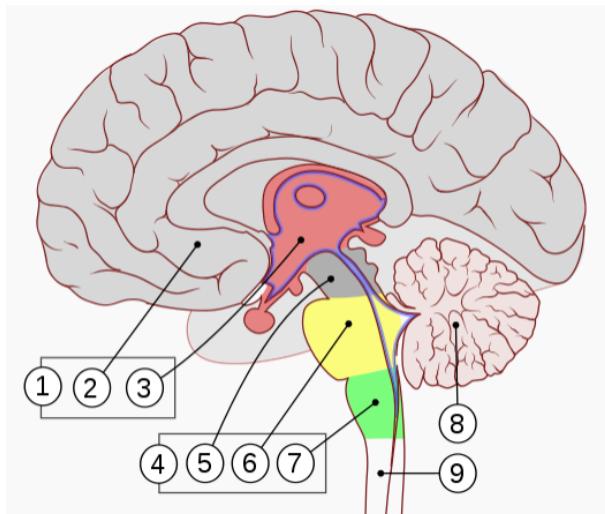


Figura 2.1: Sección sagital media del encéfalo. 1. Cerebro anterior; 2.Telencéfalo, 3.Diencéfalo. 4.Tronco del encéfalo; 5.Mesencéfalo, 6.Protuberancia, 7.Bulbo raquídeo. 8.Cerebelo. 9.Médula Espinal. Reproducido de [6]

Principales estructuras cerebrales involucradas en el Marketing

Numerosos autores han estudiado la relación entre el procesamiento emocional y la creación de recuerdos estables en la memoria [2]. De esta forma, se ha hecho relevante en el área del marketing inferir el compromiso emocional del sujeto durante la observación de un anuncio para evaluar el impacto y consecuente éxito del mensaje publicitario. Las variaciones fisiológicas en la corteza prefrontal (*Prefrontal Cortex*, PFC) y en la corteza frontal (*Frontal Cortex*, FC) están vinculadas a dicha actividad de procesamiento emocional humano, por lo que son objeto de estudio [2].

La PFC es una parte de la corteza cerebral perteneciente al lóbulo frontal, se ubica detrás de los ojos y la frente. Estudios realizados sobre la potencia espectral del EEG indican que

los hemisferios cerebrales están lateralizados diferencialmente en cuanto a las emociones y tendencias de atracción-rechazo. Concretamente, el papel de la PFC en las emociones se conoce bien a pesar de ser una zona estructural y funcionalmente heterogénea y se ha propuesto que el desequilibrio entre la región derecha e izquierda podría ser un indicador sobre el sistema de atracción-rechazo [2]. Esto último proporciona un indicador útil para juzgar qué partes de los anuncios comerciales causan más apreciación o menos a cada tipo de observador.

Otras estructuras como la corteza prefrontal ventromedial (*vmPFC*, del inglés *ventromedial Prefrontal Cortex*), el giro frontal medio o la corteza cingulada anterior mostraron una mayor actividad durante la observación de una marca preferida en comparación con una marca menos popular en diferentes estudios de fMRI basados en señales hemodinámicas [2].

2.1.2. Neurona

La neurona es la unidad estructural básica del SN. Se trata de células altamente especializadas que realizan un elevado consumo energético. Entre sus características se incluyen la excitabilidad y la conductibilidad. Son capaces de responder de manera gradual a estímulos y de transmitir la información de un lugar a otro del organismo. Se estima que el SN aloja alrededor de un billón de neuronas. Estas células se encuentran en una determinada proporción anatómica con las células gliales, lo que confiere al cerebro tan alto nivel de complejidad que ha sido objeto de estudio de innumerables y extensas investigaciones.

La estructura básica de una neurona (fig. 2.2) consta de cuerpo o soma, del que surgen unas ramificaciones conocidas como dendritas, y del axón. El soma es la parte más abultada de la neurona y está asociado con el núcleo de procesamiento de la información. Las dendritas son numerosas, pueden contener espinas para aumentar su superficie de contacto y su función es actuar de emisor de la información procesada por el soma. El axón es la región más excitable de la neurona debido a la mayor concentración de canales de Na⁺ y por tanto constituye el inicio del impulso nervioso. Esta última estructura puede estar rodeada por una sustancia lipoproteica llamada mielina que se halla interrumpida por los nodos de Ranvier. La vaina de mielina no está presente en todas las neuronas, pero de estarlo, produce una conducción saltatoria más rápida y económica en cuanto al gasto energético de la célula.

A pesar de que todas las neuronas comparten una estructura común, se diferencian varias clasificaciones atendiendo a la polaridad, la forma y el tamaño o la función, entre otras características. Según la distribución de las prolongaciones se clasifican en unipolares, bipolares, pseudopolares y multipolares. Estas últimas, las multipolares, son las más abundantes en la fisiología

humana. Dentro de este grupo se diferencian Golgi I (axón largo) y Golgi II (axón corto). Las neuronas piramidales son de tipo multipolar Golgi I, son muy grandes y están presentes en la corteza cerebral principalmente.

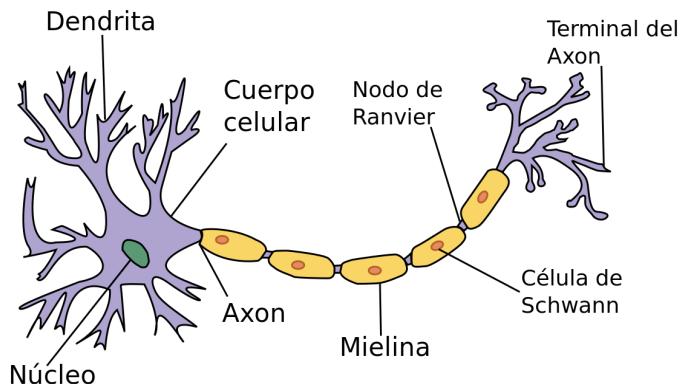


Figura 2.2: Esquema básico de una neurona [7]

2.1.3. Actividad eléctrica

La sinapsis es el mecanismo de unión especializada que permite la comunicación y coordinación entre neuronas. Según la transmisión del impulso nervioso, la sinapsis se clasifica en dos tipos: sinapsis química y eléctrica.

La sinapsis química está generada por la acción de neurotransmisores y neororreceptores. Entre dos neuronas que se comunican hay un espacio de unos pocos nanómetros conocido como hendidura sináptica. Cuando la señal eléctrica llega a los terminales de la neurona presináptica, se produce un cambio en la permeabilidad de la membrana por lo que ésta libera los neurotransmisores al espacio sináptico. Los receptores de la neurona postsináptica captan los neurotransmisores y, dependiendo de su naturaleza y proporción, la neurona se inhibe o se excita. La sinapsis eléctrica consiste en una transmisión más rápida y directa de la actividad eléctrica entre neuronas. Se produce por el paso de iones a través de estructuras proteicas conocidas como uniones gap.

La diferencia de potencial presente en las neuronas se debe a la distribución desigual de iones dentro y fuera de ellas, algo que está en constante cambio. Los flujos eléctricos que se producen en las sinapsis son atenuados por las gruesas capas de tejidos que se interponen entre las neuronas y el cuero cabelludo. Sin embargo, la actividad conjunta de millones de neuronas corticales produce un campo eléctrico que los electrodos sí pueden detectar.

La actividad eléctrica de la corteza cerebral es, en conclusión, una señal resultante de la

excitación conjunta de un gran grupo de neuronas piramidales corticales. El rango de amplitud (medida en voltios, V) y frecuencia (medida en hercios, Hz) que caracteriza a todas las señales dependerá en este caso de factores como el estado mental del sujeto, su edad, el grado de atención y el estado de vigilia/sueño, entre otros.

2.1.4. Técnicas de captación de señales neurofisiológicas

En los últimos años, las técnicas de neuroimagen han permitido mapear las regiones cerebrales implicadas en las distintas funciones cognitivas tales como la memoria o el lenguaje [2]. Técnicas como la tomografía por emisión de positrones (PET), la tomografía computarizada por emisión de fotón único (SPECT) y la fMRI proporcionan una resolución espacial elevada además de información del flujo sanguíneo en diferentes estructuras del cerebro.

La modalidad de fMRI es una de las más populares. Se basa en obtener imágenes del cambio del flujo sanguíneo en el cerebro, por medio del contraste de la señal BOLD (Blood Oxygen Level Dependent), lo que proporciona una precisa medición de la actividad neuronal. Además, esta tecnología ofrece la principal ventaja de poder permitir la visualización de estructuras cerebrales profundas, especialmente aquellas que se encuentran involucradas en las respuestas emocionales [8].

Las técnicas de neuroimagen tienen un costo total asociado muy elevado y la resolución temporal que ofrecen es baja en comparación con otras técnicas. Además de la fMRI, otras modalidades muy empleadas para el estudio de las señales neurofisiológicas son el EEG y el MEG.

El EEG refleja la actividad eléctrica del cerebro tal y como se registra al colocar varios electrodos en el cuero cabelludo, permitiendo establecer relaciones funcionales con la red cerebral. Esta técnica no invasiva se utiliza para distintos fines clínicos aunque también se puede realizar de forma invasiva uniendo los electrodos directamente a la corteza cerebral para registrar la actividad eléctrica cerebral durante una cirugía, realizando lo que se conoce como electrocorticograma (ECoG). En contraposición con los métodos de neuroimagen, el EEG ofrece una elevada resolución temporal, por lo que el uso de esta técnica es importante para el monitoreo en tiempo real de pacientes en el quirófano y en la unidad de cuidados intensivos (UCI). Además, el costo total asociado a los instrumentos de grabación y los técnicos requeridos para administrar el equipo es muy inferior.

Otra técnica que cabe destacar es el magnetoencefalograma (MEG). Consiste en cuantificar el campo magnético asociado a la actividad eléctrica que realizan las neuronas. Como el cam-

po magnético que se produce es extremadamente pequeño, se emplea un sensor ultrasensible SQUID (del inglés Superconducting Quantum Interference Devices) para captar ese mínimo campo magnético. La principal ventaja de la técnica MEG frente al EEG es que el campo magnético está menos distorsionado por el cráneo que el potencial eléctrico. A pesar de ello, las demandas técnicas de los equipos para grabar EEG son mucho más modestas.

Una combinación de todos los factores anteriormente descritos explican por qué la fMRI es la técnica más adecuada hoy en día para el análisis de neuromarketing. A pesar de ello, la técnica más utilizada es el tradicional EEG, debido a su bajo coste y buena prestación de resolución temporal.

2.2. Electroencefalografía

En esta sección se hará un breve resumen de las bases y aspectos técnicos del EEG, además de hablar de los ritmos y formas de onda más característicos y las aplicaciones más comunes de la técnica. Esta sección está basada principalmente en información extraída de la referencia [8], aunque otras serán referenciadas.

2.2.1. Historia del EEG

El estudio de la actividad eléctrica en tejidos vivos comenzó a llevarse a cabo en el siglo XVIII de la mano de dos grandes personajes italianos, Luigi Galvani y Alessandro Volta, quienes realizaron diversos experimentos en modelos animales. Poco después de las aportaciones de Faraday y Maxwell acerca del electromagnetismo (siglo XIX), Richard Caton llevó a cabo los primeros registros de señal cerebral utilizando un galvanómetro. No fue hasta 1929 cuando Hans Berger, considerado en la actualidad el padre de la electroencefalografía, emitió su primera publicación acerca de la técnica y sus descubrimientos a lo largo de su investigación [9].

La electroencefalografía ha ocupado durante las últimas dos décadas la mente de los investigadores ya que es, tal y como decía Berger, ‘una especie de ventana al cerebro’, además de presentar unas características técnicas muy favorables para su uso (no invasiva, económica y fácil de utilizar). A partir de la década de los 60, gracias al uso de los ordenadores, se comenzó a introducir la digitalización, cuantificación y normalización del EEG. Debido al continuo desarrollo tecnológico, hoy en día existe multitud de hardware dirigido a la captación de las señales

y software destinado a su procesamiento y visualización [9].

2.2.2. Bases técnicas

Tal y como se comentaba en secciones anteriores, cada grupo de neuronas corticales produce una actividad eléctrica que puede registrarse gracias a la presencia de diferentes electrodos. En la superficie de contacto de los electrodos se encuentra la interfase metal-disolución, siendo más común el uso de plata-cloruro de plata (Ag-ClAg). Cuando las corrientes eléctricas producidas por la actividad neuronal conjunta de millones de células pasan por esa interfase, se modifica el equilibrio iónico y se produce una variación en el potencial de dicho electrodo.

Los electrodos pueden ser no invasivos, si están situados en la superficie del cuero cabelludo (EEG estándar), o pueden ser invasivos. El EEG invasivo permite realizar estudios más complejos con un alto grado de detalle, y para ello utilizan electrodos corticales (EEG cortical o ECoG) o intracraneales (EEG profundo) [10].

Una vez que la señal es captada por los electrodos, ésta pasa necesariamente por un proceso de amplificación digital que magnifica la diferencia de potencial entre cada par de puntos (amplificador diferencial), ya que la señal captada es de muy baja amplitud. Este proceso aumenta también el ruido, lo que afecta especialmente en el caso del EEG no invasivo.

En cuanto al sistema de posicionamiento de los electrodos, el mayormente utilizado es el ‘sistema internacional 10-20’. Estas cifras hacen referencia a las distancias entre los electrodos y ciertos puntos reconocibles del cráneo: el ‘nasion’ está situado entre la frente y la nariz, el ‘inión’ se encuentra en la parte más baja del cráneo y, por último, el punto ‘preauricular’ está situado en las orejas (Fig. 2.3). En cuanto a la nomenclatura de los electrodos, por una parte las letras señalan el área de la corteza: prefrontal (Fp), frontal (F), central (C), parietal (P), occipital (O) y temporal (T). Por otra parte, los números pares indican hemisferio cerebral derecho, los impares el izquierdo y los de la línea media se designan con la letra z.

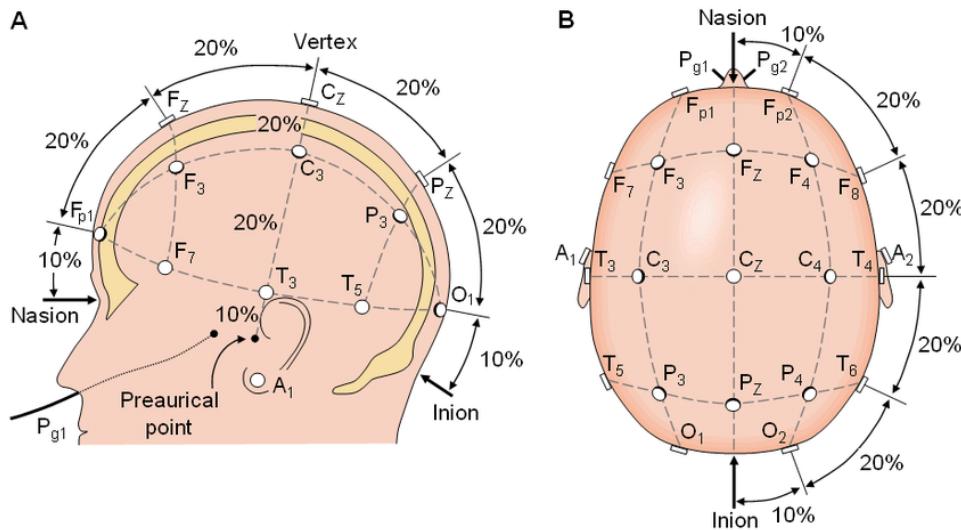


Figura 2.3: Colocación de electrodos extracraneales según el Sistema Internacional 10-20 [9]

La interpretación del EEG va a ser siempre relativa, ya que el potencial se calcula como la diferencia entre dos puntos. Según esto, existen registros monopolares o bipolares (Fig. 2.4). En los registros monopolares se toma la señal de cada electrodo de manera independiente (electrodos activos) y el potencial se calcula respecto a un electrodo de referencia. El electrodo de referencia puede estar situado a potencial cero (hueso mastoides, mentón, lóbulo de la oreja...) o puede consistir en la suma de los potenciales de todos los demás electrodos. En los registros bipolares, los potenciales se calculan entre pares de electrodos activos.

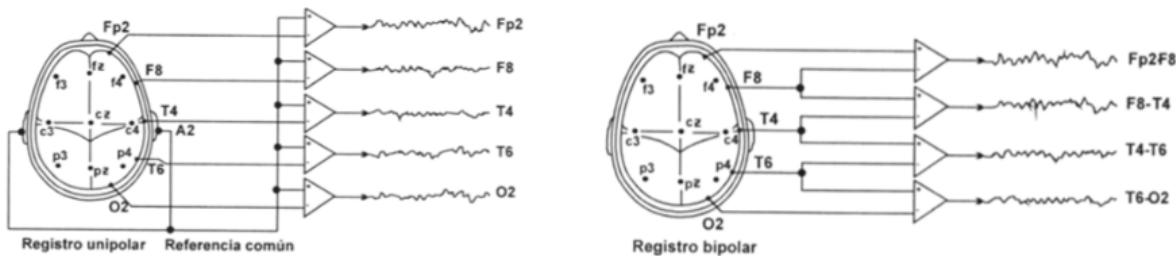


Figura 2.4: Esquema de registro monopolar (izquierda) y registro bipolar (derecha) [11]

2.2.3. Ritmos y formas de onda

Las señales recogidas mediante electrodos en la superficie del cuero cabelludo de un sujeto tienen amplitudes de aproximadamente entre 10 y $150\mu\text{V}$ y una frecuencia comprendida entre 0.5 y 30-40 Hz. Las bandas de frecuencia que se indican a continuación son algo burdas, ya

que los intervalos varían ligeramente para cada sujeto. Aún así, proporcionan una útil guía de categorización clínica de los principales ritmos, los cuales se pueden observar en la figura 2.5.

- **Ritmo delta (δ), <4 Hz.** Es el de mayor amplitud y se encuentra en bebés y adultos en sueño profundo. La detección de este ritmo en adultos en estado despierto es indicativo de daño o enfermedad cerebral.
- **Ritmo theta (θ), 4-8 Hz.** Esta banda de frecuencia se registra durante la somnolencia y en algunas etapas del sueño ligero. Además, también pueden producirse por estrés emocional, especialmente frustración o desilusión. Presentan una amplitud de entre 30 y $60\mu\text{V}$ y, junto con las delta, son conocidas como ondas lentas.
- **Ritmo alpha (α), 8-14 Hz.** Es el ritmo más prominente en sujetos despiertos, llegando a alcanzar los $50\mu\text{V}$. Su amplitud aumenta al cerrar los ojos, en estado de relajación mental y en las zonas occipitales.
- **Ritmo beta (β), 14-30 Hz.** Ritmo rápido de baja amplitud. Está asociado a una corteza activada en estado de concentración o actividades mentales intensas y también puede aparecer en algunas etapas del sueño. Se observa principalmente en las regiones frontales del cortex cerebral.
- **Ritmo gamma (γ), >30 Hz.** Se relaciona con el estado de procesamiento de información más activo, es decir, momentos de extrema concentración y atención. Es el de menor amplitud. Colocando un electrodo en el área sensoriomotora y conectando a un sistema de grabación de alta sensibilidad, se puede observar cómo fluctúa este ritmo durante el movimiento de los dedos.

Además de los ritmos de onda anteriormente descritos, también se han definido ciertas formas de onda transitorias. Las espigas (*spikes*) y las ondas lentes agudas (SSW, del inglés *Sharp Slow Waves*) son formas de onda transitorias de patrón irregular. Son indicativas de un comportamiento neuronal desviado, que a menudo se encuentra en pacientes con epilepsia. Debido a su relación con las convulsiones epilépticas, también se suelen denominar ondas interictales.

Durante las distintas fases del sueño se pueden observar algunas formas de onda transitorias como los husos del sueño (*sleep spindles*), los complejos k (*k complexes*) o las ondas vértece (*vertex waves*). Los husos del sueño son ondas sinusoidales de 12-14 Hz de frecuencia y unos 50 mV de amplitud. Aparecen de forma breve e intermitente (suelen aparecer unos 5 por minuto). Los complejos k son ondas lentas que presentan una primera fase negativa de gran amplitud

seguida por una fase positiva más lenta y de menor amplitud (se suelen registrar 3 o 4 por minuto). Están asociados con los *sleep spindles*. Las ondas vértice son también ondas transitorias de gran amplitud (50-150mV), pero no están relacionadas con los *sleep spindles*. En niños y adultos jóvenes pueden ser agudas y tener un patrón repetitivo, lo que no debe confundirse con un episodio epiléptico.

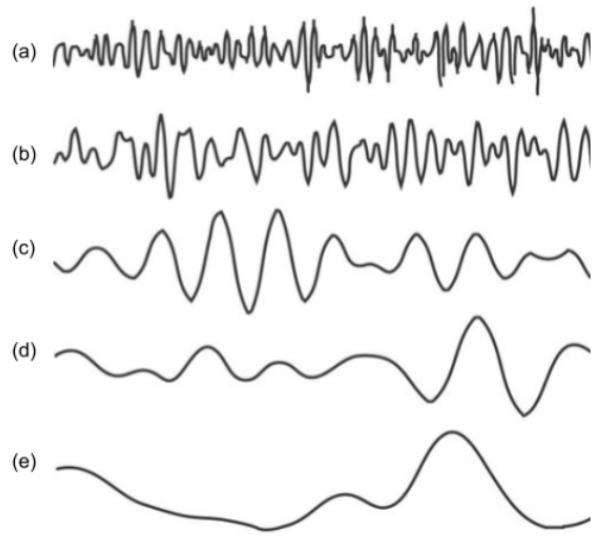


Figura 2.5: Ritmos electroencefalográficos (a) Gamma, (b) Beta, (c) Alpha, (d) Theta (e) Delta. Adaptado de [12].

2.2.4. Aplicaciones del EEG

En esta subsección se consideran las principales aplicaciones del análisis del EEG. Desde una perspectiva puramente clínica están el estudio de la epilepsia y de los trastornos del sueño. Sin embargo, el diseño de interfaces cerebro-computadora o el tema central de este TFG, el Neuromarketing, son otras aplicaciones en auge que se han estudiado principalmente desde una perspectiva más orientada a la investigación.

Epilepsia

Los episodios epilépticos consisten en explosiones de la actividad eléctrica simultánea y descontrolada de un grupo de neuronas en la corteza cerebral. El foco epiléptico está definido por un grupo de neuronas cuya funcionalidad está deteriorada y se cree que un desequilibrio entre las señales excitadoras e inhibidoras es uno de los desencadenantes principales. Las crisis epilépticas se han clasificado según un esquema basado en las características del EEG. Por

la ubicación del foco epiléptico pueden ser parciales o generalizadas. Las generalizadas presentan varios focos epilépticos simultáneos como puede verse en la figura 2.6 mientras que las parciales tienen un sólo foco. Aún así, las parciales pueden desencadenar en generalizadas, denominándose generalizadas secundarias.

El EEG interictal es la principal prueba para el diagnóstico de la epilepsia, y la mayoría de los sujetos siguen una rutina clínica de aproximadamente media hora en la que se ven sometidos a diferentes métodos de activación como la hiperventilación, la estimulación lumínica intermitente e incluso la privación del sueño. Otra modalidad de diagnóstico es la recopilación del EEG durante 24h de forma ambulatoria, lo que requiere del desarrollo de las técnicas más precisas de procesamiento y filtrado de señal para su correcta interpretación, evitando interferencias con posibles fuentes de ruido como el parpadeo, el ceño fruncido o rascarse la cabeza. Tras el análisis en tiempo real del EEG o de la señal recogida de 24h, la aparición de SSW podría sugerir ataques parciales en un área local del cerebro mientras que la aparición de espigas sugiere que el ataque es primario generalizado. A menudo, estas señales de EEG se recogen a la vez que una grabación el vídeo del paciente, para permitir al neurólogo correlacionar posibles hallazgos sospechosos.



Figura 2.6: Crisis epiléptica generalizada [13]

Trastornos del sueño

El sueño no es un estado uniforme y los diferentes patrones de onda siguen un comportamiento cíclico durante este estado. Las modificaciones del EEG a lo largo del sueño indican la existencia de una reorganización de la actividad córtico-subcortical. Los trastornos del sueño son cada vez más frecuentes en nuestra sociedad y se pueden clasificar en cuatro grupos:

- **Insomnio:** consiste en trastornos al iniciar o mantener el sueño.
- **Hipersomnia:** se basa en trastornos que causan sueño excesivo y/o somnolencia.
- **Trastornos del ritmo circadiano:** recoge los trastornos en el horario de sueño-vigilia.
- **Parasomnia:** desviaciones en el patrón de sueño normal.

Para detectar cada uno de los desórdenes del sueño anteriormente citados es necesario un estudio polisomnográfico, esto es, la recogida durante toda una noche de señales fisiológicas tales como el EEG, ECG, EMG, EOG, presión arterial, respiración nasal y abdominal e incluso la grabación de vídeo del paciente. El esfuerzo manual asociado al análisis de todos estos datos por parte del neurólogo es complejo y tedioso, por lo que un sistema que realice de manera automática la estadificación del sueño es de amplia utilidad.

Las fases del sueño se dividen en dos etapas, una fase REM y una fase no-REM. Para la correcta estadificación de los estados del sueño y la consecuente evaluación de la calidad del sueño de cada paciente es fundamental detectar las ondas y ritmos que caracterizan las diferentes etapas del sueño. En la figura 2.7 podemos observar algunas de las características direfenciales más relevantes.

FASES DEL SUEÑO				
NO REM				REM
FASE I	FASE II	FASE III	FASE IV	
Somnolencia	Sueño ligero	Sueño profundo	Sueño muy profundo	
Vertex waves Theta (θ)	Sleep spindles K complexes θ - Δ	K complexes Algun spindle Delta (Δ)	Algún K complex Δ	

Figura 2.7: Ritmos y formas de onda características de las diferentes fases del sueño.

Interfaces Cerebro Ordenador

Una Interfaz Cerebro Ordenador (BCI, del inglés Brain Computer Interface) es una tecnología de reciente incorporación que tiene como finalidad conseguir que el sujeto se comunique con el mundo externo usando salidas alternativas a la salida fisiológicamente normal del SNC. Esta tecnología está dirigida a personas con trastornos neuromusculares severos, las cuales serían beneficiarias de herramientas que posibiliten la comunicación verbal o el movimiento de una neuroprótesis.

El procesamiento de la señal de EEG para esta aplicación concreta hace uso del análisis de la potencia espectral en diferentes bandas de frecuencia de distintos canales. Las bandas de frecuencia seleccionadas reflejan los ritmos de EEG de interés. Los ritmos α y β , debido a que se originan en la corteza sensoriomotora, se han encontrado particularmente útiles en las BCI. La mayor complicación de esta tecnología reside en la velocidad de transferencia de la información. En una BCI sofisticada, se necesitan velocidades de transmisión muy elevadas que posibiliten el control en tiempo real.

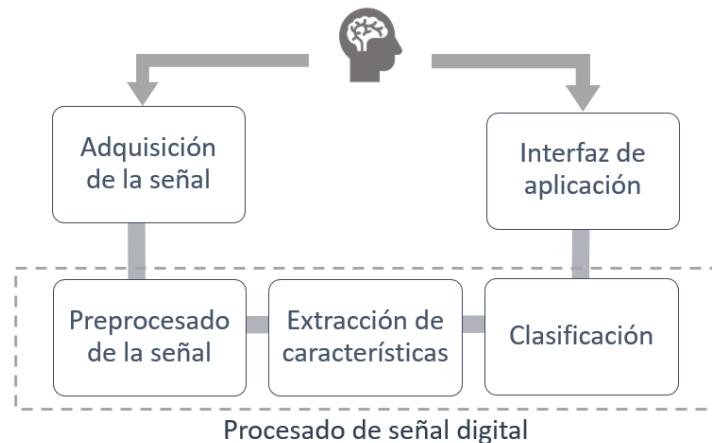


Figura 2.8: Esquema de los componentes de una BCI. Adaptado de [8].

Neuromarketing

El Neuromarketing, tal y como se detallaba anteriormente en el *Capítulo 1*, consiste en la aplicación de la neurociencia al marketing con la finalidad de señalar cómo mejorar un producto de cara al mercado e investigar cómo son los procesos de decisión del consumidor de una manera realmente objetiva.

En la medición de las respuestas fisiológicas a la publicidad existen numerosas técnicas que

permiten su estudio. Las tres técnicas no invasivas más populares son el EEG, la MEG y la fMRI. Otras técnicas como el ECoG, aunque muy precisas, no son tan populares en este ámbito debido a que al ser técnicas invasivas no son de buena acogida en el campo de la investigación publicitaria. Cada una de estas técnicas tiene sus ventajas e inconvenientes (*Sección 2.1.4*). El EEG no presenta una buena resolución espacial en comparación con las otras dos tecnologías mencionadas. Sin embargo, tiene una gran resolución temporal y, en cuanto a la variable económica, es una técnica muy modesta y asequible. Es por ello que resulta la técnica más recurrida a la hora de realizar el análisis de Neuromarketing.

Las técnicas de estudio de señales neurofisiológicas permiten al investigador obtener información relevante para la extracción de parámetros útiles en el campo del Marketing. Estos indicadores son transformados luego en conclusiones y decisiones aplicables al mercado económico, en el caso de anuncios comerciales, o se aplicarán directamente sobre la conducta de la sociedad, en el caso de anuncios no comerciales, con el fin de popularizar causas sociales, mejorar la actitud pública o cambiar hábitos de la salud poblacional.

Capítulo 3

Métodos

Los métodos utilizados en el desarrollo de este TFG se centran principalmente en el procesado y acondicionamiento de la señal de EEG. En este tercer capítulo se habla, en primer lugar, de varios tipos de filtros lineales y los artefactos que pueden eliminarse gracias a ellos. Seguidamente, se dedica una sección a la técnica de separación ciega de fuentes ICA, la cual resulta de gran utilidad para separar señales que se solapan en contenido espectral con el EEG. Por último, se detallan las técnicas de análisis espectral.

Cuando se trabaja con señales fisiológicas, en la mayoría de las ocasiones las señales de interés están entremezcladas con otras (ruido) y no es posible separarlas en el dominio temporal. Es por ello que se utilizan métodos que trabajan en el dominio de la frecuencia, centrándose en distintas bandas o intervalos de frecuencia.

El ruido y los artefactos pueden ser generados por razones fisiológicas como el movimiento ocular y el parpadeo, la actividad muscular, la respiración o la actividad cardíaca, entre otras. Algunos de ellos como el parpadeo pueden ser más fáciles de localizar debido a que tienen una amplitud superior a la del EEG y una forma de onda muy característica. Sin embargo, otros como la actividad muscular se solapan con el espectro del EEG y su eliminación puede suponer un gran reto. Además, el origen de los artefactos también puede ser técnico o no fisiológico, como puede ser el caso de la interferencia de la red eléctrica, el movimiento de electrodos o el ruido originado en cualquiera de las etapas de digitalización de la señal grabada.

3.1. Filtros lineales

Los filtros lineales juegan un papel muy importante en la etapa de preprocesamiento, ya que constituyen un método sencillo de eliminar información que no es propia de las señales en estudio. En esta sección se describe tanto la utilidad como el diseño de los principales filtros que pueden ser aplicados a la señal de EEG para un acondicionamiento básico, además de una serie de conceptos previos básicos relacionados con el filtrado digital.

3.1.1. Conceptos previos

DIAGRAMA DE BODE

Una de las herramientas fundamentales a la hora del diseño y análisis de filtros digitales es el diagrama de Bode. Éste consiste en una representación gráfica que permite caracterizar la respuesta en frecuencia de un sistema, lo que da información acerca de la variación de la señal de entrada a ese sistema. La entrada $V_{in}(s)$ y la salida $V_{out}(s)$ de un sistema se pueden relacionar mediante un modelo matemático sencillo. Esta relación, que puede estar plasmada por un cociente, se conoce como función de transferencia (ecuación 3.1).

$$H(s) = \frac{V_{out}(s)}{V_{in}(s)} \quad (3.1)$$

Por lo general, el diagrama de Bode consta de dos gráficas separadas, como se puede observar en el ejemplo de la figura 3.1. Por una parte, el diagrama de magnitud representa la ganancia del sistema (en decibelios) en función de la frecuencia (en hertzios). La ganancia o amplitud se calcula como el módulo de la función de transferencia. Por otro lado, el diagrama de fase dibuja la fase del sistema (en grados o radianes) en función de la frecuencia (en hertzios). Esta gráfica permite evaluar el desplazamiento de la señal de salida con respecto a la señal de entrada al sistema en función de la frecuencia y permite valorar la eficacia de un filtro tras su diseño, lo que ayudará a seleccionar el más adecuado para cada aplicación.

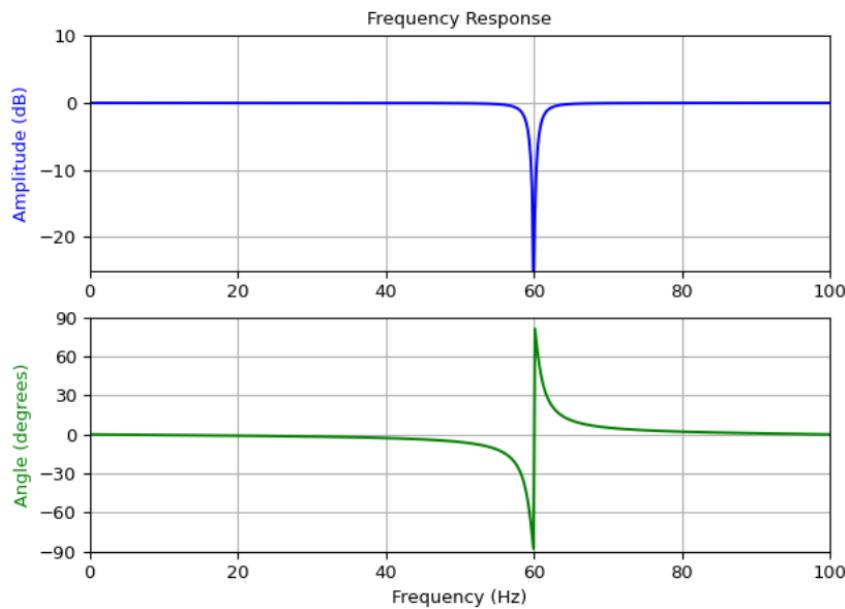


Figura 3.1: Diagrama de Bode (magnitud y fase) de un filtro Notch de 60 Hz.

Regiones de un filtro digital

En un filtro ideal se distinguen distintas regiones según la atenuación proporcionada. La banda de paso (en inglés, *pass band*) coincide en contenido espectral con la parte de la señal cuyo contenido no debe ser alterado. En esta banda la atenuación es mínima, por lo que en un filtro ideal su ganancia es 0 dB. El rizado o *ripple* es un fenómeno que aparece en la banda de paso y perjudica la calidad del filtro.

Las frecuencias que abarca la banda eliminada (en inglés, *stop band*) deben coincidir con las que se desean suprimir en la señal. La ganancia en esta zona ha de ser muy negativa (en dB) para eliminar al máximo ese contenido.

En los filtros no ideales existe además una tercera región, la banda de transición (en inglés, *transition band*), entre las dos anteriores. La pendiente de esta banda es otro de los factores que influyen en la calidad del filtro. Cuanto más pronunciada sea la pendiente más específico será el filtro. Este valor se conoce como atenuación y se mide en decibelios por década o decibelios por octava.

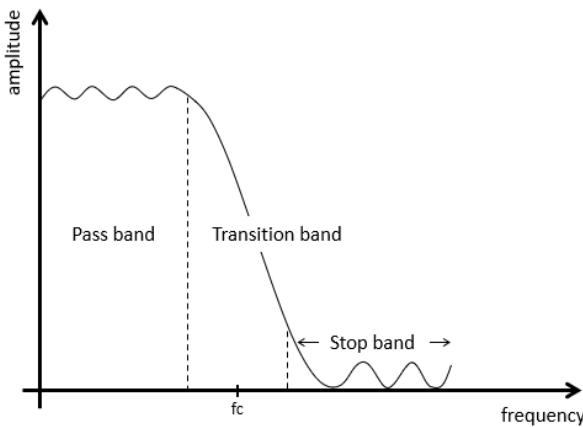


Figura 3.2: Esquema de las bandas de un filtro digital no ideal

Diseños FIR e IIR

Los filtros lineales digitales pueden dividirse en dos clases según su implementación: los filtros IIR (del inglés *Infinite Impulse Response*) y los filtros FIR (del inglés *Finite Impulse Response*).

Los filtros IIR tienen fase no lineal y respuestas al impulso asimétricas que nunca vuelven al reposo. La respuesta al impulso está determinada por una función definida por los coeficientes del filtro y las variables de estado. Debido a errores de redondeo acumulados en el cálculo de las variables de estado, los filtros IIR pueden ser inestables. Es por ello que el filtrado debe realizarse de manera recursiva y comprobar su estabilidad especialmente al utilizar f_c extremas. En estudios cardíacos sobre arritmias se suelen emplear filtros Butterworth, debido a que la ondulación en la banda de paso es mínima. Sin embargo, el orden que necesita para cumplir los mismos requerimientos que un filtro de Chebyshev o Elíptico es mayor [14].

Los filtros FIR pueden tener respuesta en fase lineal, son muy estables y se caracterizan por tener una respuesta al impulso con un número finito de términos no nulos. En este caso, el filtrado se implementa como una convolución de la entrada del filtro y la respuesta al impulso, por lo que la longitud del filtro está determinada por la longitud de la respuesta al impulso. Para reducir la ondulación en la banda de paso, se aplica una ventana a la respuesta al impulso. El ancho de la banda de transición está determinado por el orden del filtro y el tipo de ventana, siendo el orden del filtro la longitud del filtro menos uno.

En conjunto, los filtros IIR presentan la ventaja de utilizar una menor carga computacional que un filtro FIR, ya que necesitan menos orden para cumplir las mismas exigencias. Sin em-

bargo, los filtros FIR son siempre estables, más fáciles de controlar y tienen mejores resultados en el filtrado de señales de EEG [15].

Frecuencia de corte

La frecuencia de corte (f_c) es uno de los valores que caracterizan al filtro digital, ya que delimita su atenuación. Como se puede observar en la figura 3.2, la f_c separa la banda de paso y la banda de parada del filtro, coincidiendo en la región de transición. Un valor óptimo de este parámetro debe separar la señal de los componentes ruidosos en el dominio de la frecuencia, eliminando al máximo los artefactos pero a la vez atenuando lo más mínimo posible los componentes espectrales de la señal de interés.

Cuanto mayor sea el orden del filtro, más se parecerá este a un filtro ideal, aunque a expensas de la aparición de rizado en la banda de transición. El factor de calidad Q es un parámetro que proporciona información sobre la selectividad del filtro. Se calcula como el cociente de la frecuencia central de la banda de paso entre la región de la banda de paso que comprende las frecuencias de corte inferior y superior (ec. 3.2). Por ejemplo, un valor alto de este factor indica que la banda de paso del BPF es más reducida, es decir, que el filtro es más selectivo.

$$Q = \frac{f_{center}}{f_2 - f_1} \quad (3.2)$$

3.1.2. Tipos de filtros

FILTROS PASO ALTO

El movimiento de los electrodos debido a la sudoración o a un contacto inadecuado con el cuero cabelludo puede originar la aparición de artefactos de muy baja frecuencia y gran amplitud en las grabaciones de EEG. Estas ondas lentas, conocidas como *slow drifts*, son el origen de la distorsión de la línea de base. Para filtrar este tipo de ruido se recomienda la utilización de filtros paso alto (HPF, del inglés *High Pass Filter*) con una f_c de entre 0.5 y 2 Hz, con el objetivo de eliminar la línea de tendencia sin perder o modificar información propia de la actividad cerebral [16]. Sin embargo, algunos autores aseguran que la aplicación de HPF con f_c superiores a 0.1 Hz introducen distorsiones en la señal de EEG [17].

Entre otras aplicaciones de los filtros digitales se encuentra el procesamiento digital de ima-

gen, un conjunto de técnicas de filtrado con el objetivo fundamental de obtener una imagen final cuyo resultado sea más adecuado para una aplicación concreta. El HPF suaviza las frecuencias bajas y deja pasar las altas, acentuando los bordes y contornos de la imagen y constituyendo así una de las principales técnicas de realce [18].

FILTROS PASO BAJO

Otro artefacto común en la señal de EEG es la interferencia de actividad eléctrica de alta frecuencia debida a la contracción muscular. Este artefacto afecta en mayor medida a los electrodos temporales por el movimiento de la mandíbula, aunque puede afectar también a los demás. La mayor dificultad que presenta la eliminación de este artefacto es que puede solaparse con el contenido frecuencial de la banda beta (14-30 Hz). Para reducir estos artefactos de elevada frecuencia es conveniente aplicar un filtro paso bajo (LPF, del inglés *Low Pass Filter*) con frecuencias de corte de entre 35 y 70 Hz [19].

Siguiendo el ejemplo anterior de procesado digital de imagen, el LPF en este caso funciona como suavizador. Mientras que deja pasar inalteradas las bajas frecuencias, modifica las altas frecuencias espaciales atenuándolas lo máximo posible. Una aplicación común de esta herramienta de procesado es la reducción de ruido mediante el suavizado o difuminado espacial [18].

FILTROS NOTCH O RECHAZA BANDA

La señal de EEG se expone a menudo a la interferencia de la red eléctrica de 50 o 60 Hz, según el área geográfica. Las salas de grabación blindadas pueden ayudar a reducir este artefacto, pero aún así son una solución muy costosa y poco práctica. El método de procesado digital más común para la eliminación de este artefacto es el filtro Notch, también conocido como filtro rechaza banda. El filtro Notch deja pasar la mayoría de las frecuencias sin alterar, pero atenúa hasta niveles muy bajos aquellas frecuencias de un rango específico muy estrecho. Sin embargo, debido a que este filtro tiene una transición muy abrupta, se corre el riesgo de la aparición de distorsiones en la banda de paso (rizado) y consecuentemente en la señal filtrada resultante en tiempo. Se han llevado a cabo algunos estudios en torno a esta cuestión con el fin de comparar distintos métodos alternativos. En el artículo [20], se valoran enfoques tales como la Transformada Discreta de Fourier (DFT, del inglés *Discrete Fourier Transform*), CleanLine y la interpolación del espectro, resultando este último un buen método ya que introduce menos distorsiones que el filtro Notch.

FILTROS PASO BANDA

Aplicar un filtro paso banda (BPF, del inglés *Band Pass Filter*) a la señal de EEG es de gran ayuda para reducir los artefactos existentes y quedarse sólo con la señal contenida en el intervalo de frecuencias de interés. Su implementación puede ser directa, indicando una frecuencia de corte inferior (f_1) y una frecuencia de corte superior (f_2). Otra manera de construir un BPF es usar un HPF en serie con un LPF, donde hay un rango de frecuencias que ambos filtros dejan pasar.

3.2. Independent Component Analysis

La mayoría de los artefactos de origen técnico pueden reducirse de manera significativa controlando las características del medio de grabación. Sin embargo, algunos artefactos de origen fisiológico son inevitables y pueden resultar un gran desafío hasta para los profesionales más experimentados. Algunas señales como el EOG o el ECG pueden recogerse simultáneamente para la cancelación de artefactos usando señales de referencia, pero otras como el EMG no ofrecen esa posibilidad de procesado ya que no hay una forma de recoger toda la actividad muscular corporal.

La separación ciega de fuentes (BSS, del inglés *Blind Source Separation*) consiste en recuperar una serie de señales conocidas como *fuentes*, que no han podido ser observadas directamente, a partir de señales obtenidas como mezcla de esas, denominadas *observaciones* [21]. Uno de los ejemplos más típicos de BSS es el problema del efecto *cocktail party* (Fig. 3.3), en el que hay varias personas hablando simultáneamente en una habitación. Diferentes micrófonos colocados por la sala graban las señales acústicas $x_M(t)$ que reciben, que consisten en una suma ponderada de las señales de voz individuales $s_N(t)$ de cada persona. Los factores de ponderación a_{MN} dependen de la distancia entre el micrófono y los distintos interlocutores. El cerebro humano puede resolver este tipo de problemas de separación de fuentes auditivas de manera sencilla y automática, pero el procesamiento digital de señales con esta finalidad tiene una complejidad mucho mayor.

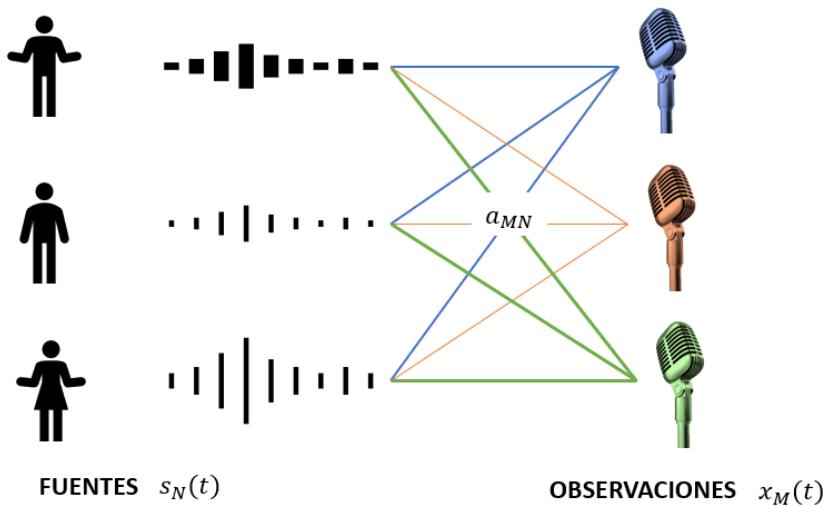


Figura 3.3: Esquema del problema del *cocktail party*. Tres señales fuente son generadas por tres individuos. Las señales sufren un proceso lineal de mezcla y son recogidas por tres micrófonos. El objetivo de este problema es reconstruir las señales fuente a partir de las observaciones.

El Análisis de Componentes Independientes (*ICA*, del inglés *Independent Component Analysis*) es uno de los algoritmos más conocidos para resolver problemas similares al del *cocktail party*. ICA es un método computacional que sirve para separar una señal mezclada en sus componentes aditivos.

El pilar fundamental sobre el que se apoya el método de ICA es la suposición de que las fuentes sean estadísticamente independientes [22], es decir, que una variable no aporte información de la otra, y viceversa. De esta forma, la mezcla de las señales no es independiente ya que consiste en una combinación lineal de las señales fuente. Matemáticamente, la independencia se demuestra con la función de densidad de probabilidad (pdf, del inglés probability density function). Sean y_1 e y_2 dos variables aleatorias, se dice que son independientes cuando la pdf conjunta ($p(y_1, y_2)$) es igual al producto de sus pdf marginales ($p_i(y_i)$).

La segunda restricción fundamental para poder aplicar ICA con éxito es que las señales fuente no tengan una distribución gaussiana. Las señales mezcla sí tienen una distribución gaussiana por consecuencia directa del teorema central del límite, el cual indica que la suma de n variables aleatorias independientes y con varianza finita no nula tienen una función de distribución que se approxima a una normal o gaussiana. Esta propiedad es utilizada para buscar las señales con distribución no Gaussiana en la señal de mezcla y así extraer las señales independientes o fuentes [22] [23].

ICA emplea un modelo matemático lineal muy sencillo representado por la ecuación $\mathbf{x} = \mathbf{As}$,

donde \mathbf{X} es la matriz de observaciones, \mathbf{S} la matriz de fuentes y \mathbf{A} es la matriz de mezcla (*mixing matrix*) que contiene los pesos. Este modelo describe cómo se generan las observaciones a partir de las fuentes originales mediante un proceso de mezcla determinado por la matriz de pesos. Tanto las señales fuente como el proceso de mezcla de éstas se desconoce en el problema. Lo único que se conoce es la matriz de observaciones, por lo que el objetivo es calcular los demás términos bajo las asunciones de independencia y distribución no gaussiana. Para ello, hay que estimar la matriz de mezcla y calcular su inversa, \mathbf{W} (*unmixing matrix*). De esta manera, la ecuación que describe la extracción de las fuentes independientes (denotadas por \mathbf{Y}) es $\mathbf{Y} = \mathbf{WX}$.

Es importante saber que el número máximo de componentes independientes que se pueden calcular con ICA está limitado por el número de observaciones ($n \geq p$). Cuando el número de señales de mezcla es menor que el número de señales fuente ($n < p$), la matriz A no es cuadrada y por tanto no es invertible. Este problema se conoce como *over-complete* e imposibilita la aplicación de ICA para la extracción de las componentes independientes. Por otro lado, cuando el número de señales de mezcla es mayor que el número de señales fuente ($n > p$), el problema se conoce como *under-complete*.

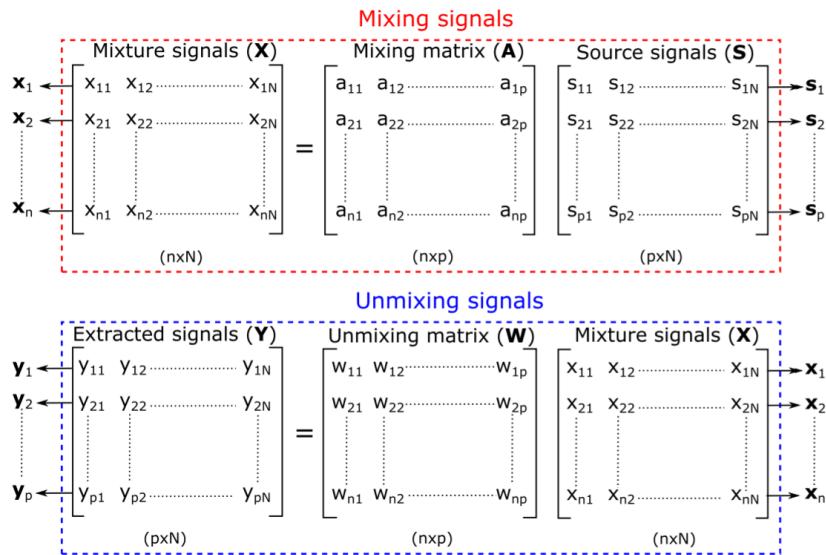


Figura 3.4: Diagrama de las ecuaciones matriciales del proceso de mezcla (*mixing*) y extracción (*unmixing*) de las señales del problema de BSS. Extraído de [23].

El método de ICA presenta algunas ambigüedades a la hora de la interpretación de los resultados. En primer lugar, no es posible determinar las varianzas individuales de cada una de las componentes independientes. Debido a que se desconocen \mathbf{A} y \mathbf{X} , la solución podría

estar multiplicada o dividida por cualquier escalar; es por ello que se suele asignar varianza unidad a todas ellas. Esta cuestión va ligada a la ambigüedad del signo. Por último, esta técnica no permite averiguar la ordenación original de las componentes independientes, lo que limita bastante aquellas aplicaciones donde la ubicación espacial de las fuentes es relevante [22].

El centrado y el preblanqueamiento de los datos son dos pasos importantes de preprocessamiento de los datos que facilitan la extracción de las señales fuente. El primero de ellos consiste en centrar los datos mediante la sustracción de la media. Después de aplicar ICA se puede reincorporar el vector media a los datos. El paso de blanqueamiento consta de una etapa de decorrelación y una etapa de escalado para que todos los datos tengan varianza unitaria [23].

Con el fin de maximizar la independencia estadística de los componentes estimados, las definiciones más extendidas de independencia en ICA son la maximización de la no-gaussianidad, la minimización de la información mutua y la máxima verosimilitud (ML, del inglés *Maximum Likelihood*). La kurtosis y la negentropía son dos formas diferentes de medir la no-gaussianidad. Por otro lado, la familia de algoritmos de minimización de la información mutua utiliza la maximización de la entropía conjunta para obtener los componentes independientes, entre otras medidas. En cuanto al uso de la ML, normalmente se utiliza su logaritmo para hacer más sencillo el estimador. El proceso de optimización de los diferentes métodos utilizados es un gran desafío en términos de velocidad y exactitud, y es por ello que se han estudiado constantemente nuevos algoritmos como Infomax [24][25], FastICA [22] o Picard [26].

Una situación similar a la del problema del *cocktail party* es la grabación de señales de EEG. En este caso, sólo se dispone de las observaciones recogidas por los electrodos en diferentes posiciones sobre el cuero cabelludo, pero se desconocen las componentes originales de la actividad cerebral (figura 3.5). Además, en la señal recogida se entremezclan tanto las fuentes de interés como artefactos de todo tipo.

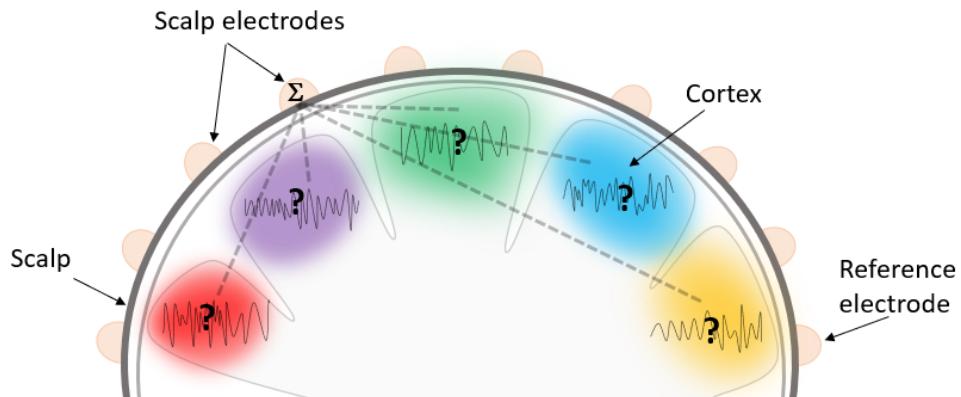


Figura 3.5: Esquema del problema de separación ciega de fuentes en el EEG. Los colores representan fuentes independientes. Los electrodos captan las observaciones.

La aplicación de la técnica de ICA sobre los canales de EEG devuelve un conjunto de componentes lo más independientemente posible entre ellas, idealmente las fuentes originales. La selección de las componentes con información ruidosa es un proceso subjetivo, aunque algunos artefactos como los oculares o la actividad cardíaca han demostrado tener unos patrones de onda característicos y una topografía concreta [27]. La *unmixing matrix* que estima ICA contiene en cada columna una componente independiente con un peso para cada canal. La representación topográfica consiste en la proyección de cada una de estas columnas sobre el mapa de colocación de los sensores. Cada uno de los mapas topográficos es estacionario durante toda la grabación y los colores indican la afectación de cada canal por la componente independiente, es decir, los colores son proporcionales al valor de los pesos. Es importante recordar que ICA presenta la ambigüedad del signo, por lo que los colores fuertes, tanto azul como rojo, indican un valor alto del peso del canal. Los colores más claros indican que el valor del peso es más bajo. En la figura 3.6 se pueden observar dos posibles tipos de interferencias oculares en la señal de EEG, los parpadeos y el movimiento horizontal de los ojos, además de la interferencia de la actividad eléctrica del corazón. Si la calidad de la señal de EEG es suficientemente buena después de haber sido preprocesada, es posible localizar las componentes independientes asociadas a estas interferencias y con ello mejorar considerablemente la calidad de la señal.

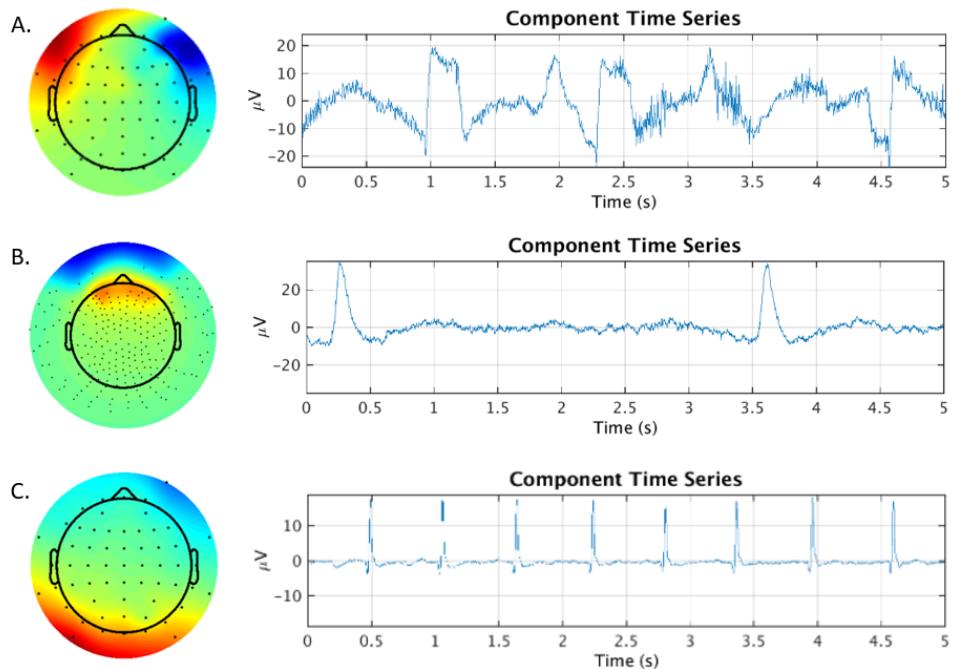


Figura 3.6: Representación de la topografía (izquierda) y la forma de onda (derecha) de artefactos fisiológicos comunes en el EEG. A) Movimiento horizontal ocular. B) Parpadeo. C) Actividad cardíaca. Adaptado de [28].

El empleo de ICA es una útil herramienta en el manejo digital de señales biomédicas y tiene numerosas aplicaciones en diferentes problemas como la separación del ECG fetal en embarazadas [21] o la eliminación de artefactos en el EEG [1]. Sin embargo, también se ha estudiado su aplicación en otros escenarios, como la obtención de factores ocultos en datos financieros [29] o el procesado de imágenes. En el artículo [30] se muestran los resultados de un estudio realizado con imágenes de radar de apertura sintética, en el cual las manchas de las capturas se reducen más con ICA que con otras técnicas tradicionales.

3.3. Principal Component Analysis

El Análisis de Componentes Principales (PCA, del inglés *Principal Component Analysis*) es una técnica estadística de tratamiento de datos. Su finalidad principal es reducir la redundancia de un conjunto de datos para realizar la extracción de patrones o simplemente reducir la dimensionalidad de un problema.

El enfoque básico de funcionamiento de esta técnica consiste en la obtención de los autovalores y autovectores de la matriz de covarianza de un conjunto de datos. Seguidamente, los

autovectores de clasifican según el valor decreciente de su autovalor asociado y se seleccionan los k primeros autovectores. Con este proceso, los datos sufren una transformación de su espacio de representación. El nuevo eje de coordenadas está formado por una base ortogonal de manera que se maximiza la varianza a lo largo de dichos ejes. Como resultado, los datos en el nuevo espacio no están correlacionados.

Aunque PCA e ICA se basan en propiedades diferentes, no son técnicas excluyentes. La técnica de PCA puede emplearse para blanquear los datos antes de aplicar ICA, en la etapa de decorrelación. El objetivo de esta etapa de preblanqueo de los datos es reducir la complejidad del problema, transformando los datos adquiridos para que no estén correlacionados entre sí. De esta forma, será más sencilla la búsqueda de las componentes independientes en el nuevo espacio ortogonal de PCA.

3.4. Análisis espectral

El análisis espectral basado en la Transformada de Fourier (TF) es una técnica que permite la caracterización en frecuencia de una amplia gama de señales biomédicas. Esta técnica correlaciona esencialmente la señal de EEG con senos y cosenos de varias frecuencias para producir un conjunto de coeficientes que definen el espectro de potencia $S_x(e^{j\omega})$ de la señal en estudio, $x(n)$. Teniendo en cuenta que muchos ritmos de EEG tienen comportamiento oscilatorio, esta técnica se consideró muy útil desde el punto de vista computacional y se ha utilizado para obtener una detallada caracterización de la actividad de fondo del EEG. El análisis espectral basado en la TF se conoce como análisis espectral no paramétrico, ya que no se introducen hipótesis de modelado paramétrico con respecto a la señal.

El espectro de potencia, también denominado Densidad Espectral de Potencia (DEP), se define con la ecuación 3.4, que se obtiene a partir de la Transformada de Fourier de la función de correlación $r_x(k)$ (ecuación 3.3).

$$r_x(k) = E[x(n)x(n-k)] \quad (3.3)$$

$$S_x(e^{j\omega}) = \sum_{k=-\infty}^{\infty} r_x(k)e^{-j\omega k} \quad (3.4)$$

Al combinar las dos expresiones anteriores se obtiene una estimación de la DEP (ecuación

3.5). El estimador de la densidad espectral de potencia recibe el nombre de periodograma. Para obtener el periodograma de un proceso resulta más conveniente expresar la estimación de la DEP en función de la TF de la señal en estudio $x(n)$. Tomando la TF y aplicando el teorema de la convolución se obtiene la ecuación 3.6.

$$\hat{S}_x(e^{j\omega}) = \sum_{k=-N+1}^{N-1} \hat{r}_x(k) e^{-j\omega k} \quad (3.5)$$

$$\hat{S}_x(e^{j\omega}) = \frac{1}{N} |X(e^{jw})|^2 = \frac{1}{N} \left| \sum_{n=0}^{N-1} x(n) e^{-jwn} \right|^2 \quad (3.6)$$

Características del periodograma

El periodograma, a efectos prácticos, es un estimador sesgado e inconsistente en varianza. La segunda afirmación se puede deducir de la ecuación 3.7, ya que $V[\hat{S}_x(e^{j\omega})]$ no tiende a 0 cuando N tiende a infinito.

$$V[\hat{S}_x(e^{j\omega})] \approx S_x^2(e^{j\omega}) \left[1 + \left(\frac{\sin wN}{N \sin w} \right)^2 \right] \quad (3.7)$$

En cuanto al sesgo, se estudia la ecuación 3.8 de la esperanza del estimador, donde $w_B(k)$ es una ventana triangular conocida como ventana de Barlett. En la figura 3.7 se muestra la TF de esta ventana. En ella se pueden distinguir dos regiones: el lóbulo principal y los lóbulos secundarios. El lóbulo principal está relacionado con el difuminado del espectro o ‘smearing’. Este efecto limita su resolución, y lo más conveniente es que el lóbulo principal sea lo más estrecho posible. Los lóbulos secundarios son la representación de las fugas de potencia del lóbulo principal, también conocidas como ‘leakage’. Además, el efecto de ‘leakage’ es más pronunciado en las señales de banda estrecha, por lo que dentro del contexto de análisis de las señales de EEG, este efecto implica que la señal se caracterizará de mejor manera por la potencia espectral contenida en una banda de frecuencia y no sólo en su pico espectral. Las características descritas de la ventana de Barlett demuestran que el periodograma es un estimador sesgado.

$$E[\hat{S}_x(e^{j\omega})] = \sum_{k=-N+1}^{N-1} r_x(k)w_B(k)e^{-j\omega k}, \quad (3.8)$$

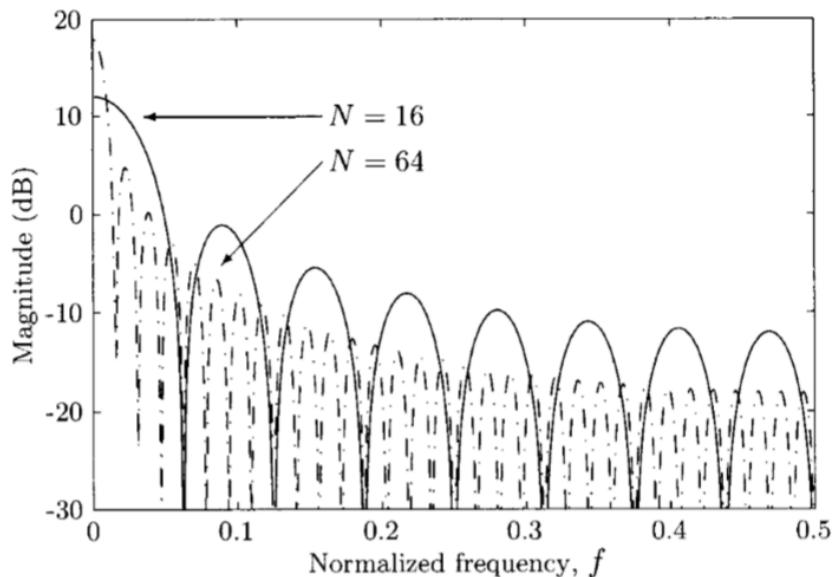


Figura 3.7: Transformada de Fourier de la ventana de Barlett para $N=16$ y $N=64$. El ancho del lóbulo principal y la magnitud de los lóbulos secundarios disminuyen a medida que aumenta el número total de muestras N [8].

Modificaciones del periodograma

Las propiedades de periodograma, junto con los efectos de ‘smearing’ y ‘leakage’, han estimulado el desarrollo de varios enfoques para mejorar el rendimiento del periodograma. Las modificaciones más importantes se describen a continuación y giran en torno al uso de ventanas y promedios.

- **Enventanado (Periodograma modificado).** La ventana cuadrada que se utiliza para calcular la DEP influye en el *leakage*, debido a los lóbulos secundarios que aparecen en el espacio de frecuencia. Al sustituirla por otras ventanas con lóbulos secundarios menores, mejora la fuga de potencias a otras bandas de frecuencias donde la señal original no tiene contenido (*leakage*). Las ventanas más comúnmente utilizadas son la de Hamming, Hann o Blackman.

Esta reducción de los lóbulos secundarios se realiza a expensas de un lóbulo principal más ancho. Es decir, se reduce el *leakage* a costa de perder resolución espectral.

- **Promediado (Método de Barlett).** Consiste en partir $x(n)$ en K segmentos sin solape de longitud L ($N = KL$).

$$x_i(n) = x(n + iL), n = 0, \dots, L - 1; i = 0, \dots, K - 1 \quad (3.9)$$

Se obtienen las estimaciones de los K periodogramas $\hat{S}_{x_i}(e^{j\omega})$ y se promedian. De esta manera se consigue una estimación de la DEP consistente en varianza, ya que esta tiende a 0 cuando $K \rightarrow \infty$.

$$V[\hat{S}_x(e^{j\omega})] = \frac{1}{K} V[\hat{S}_{x_i}(e^{j\omega})] \quad (3.10)$$

Con esta modificación se reduce la varianza a costa de reducir la resolución frecuencial.

- **Combinación de enventanado y promediado (Método de Welch).** Esta modificación consiste en una combinación de los dos métodos anteriores y se obtiene como el promedio de los periodogramas modificados.

Se parte la señal $x(n)$ en K segmentos (con solapamiento) de L muestras de longitud y se aplica a cada segmento una ventana (no cuadrada). A continuación, se promedian los periodogramas de las K estimaciones de los distintos segmentos. De esta forma, la estimación de la DEP es:

$$\hat{S}_x(e^{j\omega}) = \frac{1}{KLU} \sum_{i=0}^{K-1} \left| \sum_{n=0}^{L-1} x_i(n)w(n)e^{-j\omega n} \right|^2, \quad (3.11)$$

donde U es un factor de normalización relacionado con las características de la ventana (la energía).

Con esta modificación combinada se reducen varianza y leakage a costa de reducir resolución frecuencial.

3.4.1. Parámetros espectrales

El análisis espectral es muy útil para el análisis del EEG, sin embargo, su interpretación no es sencilla. Por este motivo, a menudo se recurre a la extracción de parámetros representativos más adecuados, lo que resulta indispensable debido a la gran cantidad de datos contenidos en

una grabación de EEG multicanal. Para el desarrollo de un parámetro espectral es fundamental elegir un formato de representación gráfica (escala lineal o logarítmica). Esto se debe a que la evaluación visual es muy importante a la hora de juzgar si un parámetro es representativo o no de una determinada propiedad espectral o para comprender la forma en que los artefactos distorsionan el espectro de potencia.

Los parámetros espetrales más utilizados son la pendiente espectral, los descriptores de Hjorth, el índice de pureza espectral y la potencia en las bandas de frecuencia. La pendiente espectral es un parámetro clínico de utilidad para calcular la actividad irregular del EEG (actividad no rítmica). Los descriptores de Hjorth se obtienen mediante el cálculo de los momentos del espectro de potencia y son de gran utilidad en la clasificación de las etapas del sueño. El índice de pureza espectral refleja el ancho de banda de la señal y está relacionado con el descriptor de complejidad de Hjorth. En cuanto a la potencia en las bandas de frecuencia, los límites de las bandas se establecen según parámetros clínicos (bandas de frecuencia de los distintos ritmos, descritos en la sección 2.2.3). Puede calcularse de manera absoluta o relativa. La potencia relativa se calcula como el ratio entre la potencia en una banda de interés y la potencia total o como el ratio de la potencia entre diferentes bandas de frecuencia y puede ayudar a identificar los picos más prominentes.

3.4.2. Índices neurométricos

La valoración de la eficacia de los anuncios de servicio público (PSA, del inglés Public Service Announcement) se puede realizar en base a informes de carácter oficial sobre los cambios comportamentales hacia actitudes más saludables y/o que producen un ahorro económico, tras la exposición al PSA. Dentro de estos estudios, la utilización de una métrica objetiva es fundamental para poder valorar de manera insesgada cada anuncio. Técnicas como la entrevista personal o las encuestas pueden introducir sesgos relacionados con la sinceridad de los sujetos o los intereses profesionales, entre otros. En esta sección se describen dos índices neurométricos, cuya utilidad y beneficios frente a los métodos tradicionales de análisis de la eficacia han sido estudiados en [1]. Ambos índices se calculan a partir de la recopilación de ritmos electroencefalográficos.

El índice de agrado-rechazo o AWI (del inglés Approach Withdrawal Index) está relacionado con la asimetría de la actividad en la banda alpha en ambos hemisferios cerebrales, más concretamente de la corteza frontal. Se ha demostrado que esa asimetría implica una diferente tendencia motivacional hacia los estímulos propuestos: durante la motivación negativa se ob-

serva una mayor activación del hemisferio derecho mientras que hay una mayor activación del hemisferio izquierdo durante la motivación positiva [31] [32]. Así mismo, en la región central y parietal de la corteza cerebral no se aprecian diferencias relativas a la obtención de este índice. El cálculo del AWI se realiza trabajando con los electrodos específicos de la corteza frontal. De este modo, acotando las frecuencias características de la banda alpha (8-12 Hz), se extrae la potencia de la banda alpha en cada electrodo. Realizando el promedio de la potencia en la banda alpha de los electrodos del área cortical de interés se calcula la potencia de campo global o GFP (del inglés Global Field Power), tal y como se muestra en la ecuación 3.12, donde $x_{i,\alpha}$ representa la potencia en banda alpha de la señal registrada con el electrodo i y N es el número total de electrodos. El área cortical de interés para el cálculo de este índice son los hemisferios derecho e izquierdo, por lo que para cada sujeto se calcula el GFP (left) y el GFP (right). De este modo, la obtención del AWI consiste en la resta de ambos GFP. Si el objetivo del estudio es la valoración exhaustiva de un sólo PSA se puede calcular el índice AW n veces, dividiendo el eje temporal del anuncio en n intervalos para un estudio profundo de la actividad cerebral generada en cada uno de los intervalos del anuncio.

$$GFP_\alpha = \frac{1}{N} \sum_{i=1}^N (x_{i,\alpha}(t))^2 \quad (3.12)$$

$$AWI = GFP_{\alpha_right} - GFP_{\alpha_left} \quad (3.13)$$

El segundo índice, el índice de esfuerzo cerebral o CEI (del inglés, Cerebral Effort Index) se define como la actividad de la banda theta en la corteza frontal. Ha sido relacionado con el nivel de dificultad de una tarea [33] y especialmente estudiado durante estímulos auditivos [33] o en su aplicación en el funcionamiento de las interfaces cerebro ordenador [34]. El cálculo de este índice se realiza mediante la obtención de los GFP de la banda theta de los electrodos del área frontal.

Además de estos índices, un importante catalizador para la memorización de estímulos y consecuentemente la asimilación de PSA es la participación emocional. Este índice emocional se deriva de la respuesta galvánica de la piel y del ritmo cardíaco. Existen estudios como el de la referencia [35] que evidencian la relación entre las oscilaciones del EEG en las ondas alpha y theta y la capacidad de memoria de los sujetos.

La extracción de estos parámetros permite la elaboración de informes objetivos y detallados de la importancia de cada PSA, lo que posibilita la combinación de diferentes estilos de comunicación con el público objetivo para facilitar la comprensión del PSA y mejorar el impacto deseado.

Capítulo 4

Experimentos y resultados

En este capítulo se explica el proceso llevado a cabo desde la obtención de las señales de EEG hasta conseguir la extracción de un índice informativo de las sensaciones producidas por la observación de diferentes anuncios, pasando por todo el proceso intermedio de acondicionamiento de la señal. Así, el capítulo 4 empieza con la presentación de la base de datos, su estructura y contenido. A continuación se detallan los experimentos llevados a cabo con filtros lineales y con ICA. Por último, se realiza la extracción de dicho índice.

Para la implementación de código se utiliza el lenguaje de programación Python (versión 3.7.4) en el entorno interactivo de Jupyter Notebook además del entorno de desarrollo integrado Spyder. El paquete de software libre MNE es utilizado para la visualización, exploración y análisis de datos neurofisiológicos. Todo el código realizado durante este proyecto, incluyendo versiones antiguas y experimentos previos, están accesibles *online* a través del repositorio de libre acceso de GitHub disponible en la referencia [36].

4.1. Base de datos

Los datos con los que se trabaja en este proyecto han sido recopilados gracias a un experimento realizado en la Universidad Rey Juan Carlos, durante el curso académico 2018/2019. Durante el experimento, los voluntarios se colocan en una postura cómoda sobre una silla, frente a un monitor de ordenador y sin ninguna distracción que pueda interferir en los resultados. De esta manera se procede a la obtención de 3 tipos de señales fisiológicas diferentes: ECG, EDA y EEG.

Para la grabación de la señal de ECG se colocan 3 electrodos. Dos de ellos, el negativo y el positivo, se colocan centrados en ambas muñecas. El tercero, que debe estar en un sitio neutro, se ha colocado en la parte anterior del codo. En el caso de las señales EDA, su grabación se ha realizado con 2 electrodos colocados en la palma de la mano dominante. Sin embargo, en este TFG se trabaja exclusivamente con las señales de electroencefalografía, por lo que no se utilizan las señales de ECG o EDA.

Las señales de EEG de este experimento han sido recogidas con el casco *actiCAP Xpress Twist*, cuya posibilidad de uso es estrictamente la investigación. Se trata de un sistema de posicionamiento con 32 canales de electrodos activos en seco, que se adhieren al cuero cabelludo mediante presión, sin necesidad de aplicar gel conductor. De esta manera, la participación en el experimento se favorece al resultar menos incómodo y más rápido, aunque por otra parte se disminuye la calidad de la señal adquirida. Este dispositivo realiza un registro monopolar de la actividad eléctrica generada por el cerebro y envía toda la información al *BrainVision Recorder, software* a través del cual se pueden visualizar y almacenar las señales capturadas.

La grabación de las tres señales se ha llevado a cabo durante la observación de 6 anuncios publicitarios. Todos ellos fueron seleccionados por un grupo de expertos formado por cuatro académicos y cuatro publicistas. Cada uno tiene una duración de aproximadamente un minuto y fueron reproducidos de forma continuada, precedidos por un minuto de grabación basal del EEG. En cuanto al contenido de los anuncios, cuatro de ellos presentan una emoción predominante mientras que los otros dos muestran contenido formativo (mensajes racionales):

- **Anuncio 1.** Contenido racional: respetar los límites de velocidad puede salvar vidas.
- **Anuncio 2.** Emoción principal de disgusto: consumir drogas te destruye.
- **Anuncio 3.** Emoción principal de ira: la violencia y el maltrato infantil provocan futuros inestables.
- **Anuncio 4.** Emoción principal de sorpresa: si bebes no conduzas, y si lo hacen tus amigos intenta impedirlo.
- **Anuncio 5.** Emoción principal de tristeza: al volante, eres el responsable de todas las vidas que te acompañan.
- **Anuncio 6.** Contenido racional: las adicciones son enfermedades, pide ayuda a un especialista.

El experimento termina con una encuesta escrita que consta de 20 preguntas relacionadas con el contenido de los anuncios. De esta manera, se pretende valorar la memoria a corto plazo de cada sujeto para analizar el impacto que tiene cada anuncio sobre la sociedad. Además, es conveniente destacar que para minimizar los efectos de primacía y recencia, el orden de los anuncios se aleatorizó.

A pesar de que participaron un total de 60 personas en el experimento, se ha decidido seleccionar inicialmente para este proyecto 5 grabaciones por motivos de manejabilidad, ya que hay algunos procedimientos que no permiten realizar una rutina automática.

La primera tarea que se ha realizado con la señal adquirida es un análisis inicial exploratorio de los datos, el cual se puede encontrar en el repositorio de Github [36], bajo el título '*Exploratory Data Analysis*'. Los datos disponibles se distribuyen en 5 carpetas, cada una con un sujeto al que se le ha realizado el experimento de *Neuromarketing*, identificados mediante un código numérico de 4 dígitos. Cada una de las grabaciones de EEG extraídas gracias al *software* de BrainVision consta de 3 ficheros. El fichero '.eeg' contiene todas las muestras de la señal de EEG mientras que los otros dos son ficheros de texto. El '.vhdr' incluye la cabecera de la señal con información acerca de cada uno de los 32 canales, la frecuencia de muestreo y otra información relacionada con el sistema de adquisición de señales del casco. Por último, el fichero '.vmrk' contiene dos marcadores importantes: el momento de inicio del minuto de actividad basal y el momento de inicio de reproducción del último anuncio.

A efectos de simplificar la explicación y la representación gráfica, se emplea el contenido de la carpeta del sujeto 2900. El objeto Raw que contiene los datos de EEG del sujeto 2900 tiene una dimensión de 31 x 252.620 (505.2 s), es decir, consta de 31 canales de EEG cada uno con 252.620 muestras de tiempo tomadas con una frecuencia de muestreo de 500 Hz y que se distribuyen en un total de 8.42 minutos. En la gráfica de la figura 4.1 se representa el voltaje de la señal de EEG recogida en el canal F3 expresado en μ V en función del tiempo en segundos, y cada color representa un anuncio. El tramo en azul se corresponde con el minuto de actividad basal previo a la reproducción de los anuncios. Se observa una tendencia lineal marcada y un trazado grueso provocados por artefactos de adquisición de la señal.

En la figura 4.2 se representa un promedio de la Densidad Espectral de Potencia (PSD, del inglés *Power Spectral Density*) de los 31 canales de la señal de EEG en crudo. Esta representación informa de cómo está repartida la potencia de la señal según las diferentes frecuencias que la conforman. La línea vertical discontinua se debe a la introducción de un filtro en la etapa de adquisición de la señal ($f_c = 140$ Hz y pendiente de 12 dB/octava).

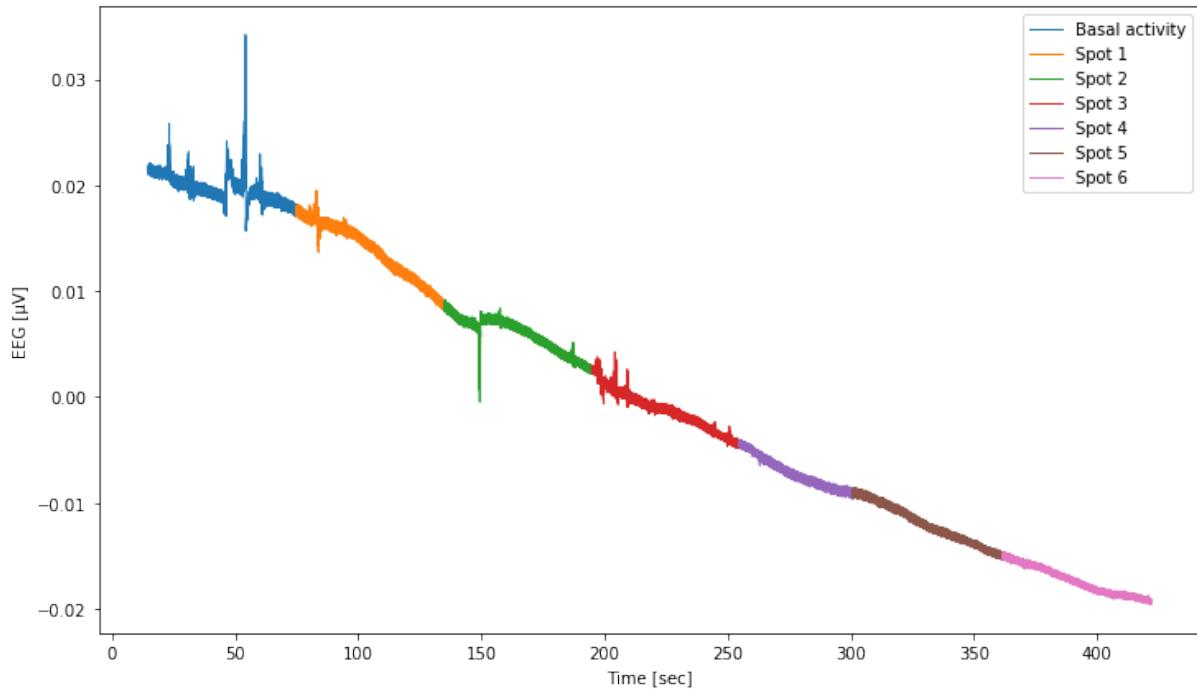


Figura 4.1: Representación en tiempo de la señal de EEG sin procesar. Canal F3 del sujeto 2900.

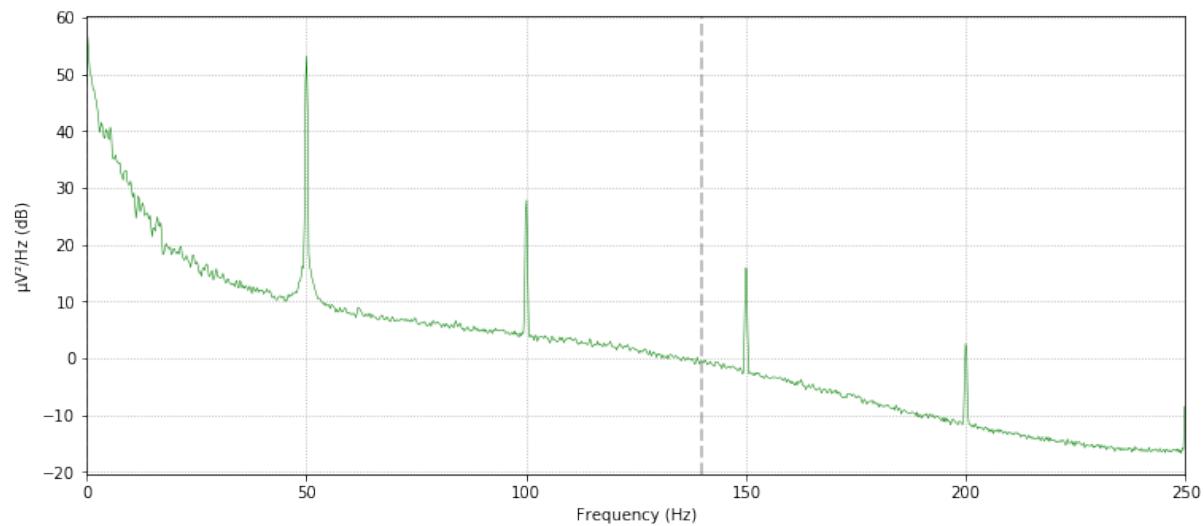


Figura 4.2: PSD de la señal de EEG sin procesar. Sujeto 2900, promedio de los 31 canales.

4.2. Filtrado básico

El filtrado lineal es una herramienta indispensable para mejorar la calidad de las señales de EEG y facilitar su interpretación visual. Además, algunos autores han demostrado la utilidad que el filtrado digital de los artefactos inherentes a la adquisición de la señal de EEG contribuye a la calidad de la separación ciega de fuentes [37]. Por tanto, en esta sección se muestran los resultados obtenidos tras aplicar diferentes filtros lineales a la señal de EEG, con la finalidad de construir una serie de pasos de procesamiento que son comparados entre ellos para seleccionar los más adecuados. El Notebook con el código completo puede encontrarse en el repositorio de Github [36], bajo el título ‘Experiments with linear filters’. Cabe destacar que en este TFG se ha decidido utilizar filtros FIR por su mayor estabilidad y porque tienen respuestas de fase lineal, lo cual no introducirá distorsiones en la señal en estudio.

4.2.1. Experimentos con filtro paso alto

La línea de tendencia que se aprecia en la figura 4.1 está originada por la interferencia de las ondas de baja frecuencia, por lo que el primero de los filtros diseñados es un filtro paso alto para eliminar esa tendencia. El parámetro frecuencia de corte se ha sometido a un experimento con los valores 0.1, 0.5 y 2 Hz. El filtro ha sido diseñado con el método *filter* de la clase *Raw* del paquete MNE. En los parámetros de la función se ha especificado que el filtro sea FIR y utilice un diseño *firwin* con una ventana de *Hamming*, ya que es la que tiene el lóbulo central más ancho y la amplitud de los lóbulos secundarios es prácticamente nula.

En la figura 4.3 se puede observar una representación de la PSD en las frecuencias de interés (FOI, del inglés *Frequencies of interest*) de la señal de EEG sin filtrar (*Raw signal*) y después de haberla filtrado con cada uno de los HPF. Las líneas verticales discontinuas se corresponden con las diferentes frecuencias de corte en estudio. El filtro con $f_c = 2$ Hz es el que más reduce el contenido espectral en las frecuencias bajas. Por el contrario, el filtro con $f_c = 0.1$ Hz apenas disminuye el contenido espectral de bajas frecuencias.

Por lo tanto, después de los resultados obtenidos, debido a que el objetivo de este TFG es la aplicación de la técnica de filtrado avanzado ICA, y siguiendo las recomendaciones de la literatura existente ([16][38]), la frecuencia de corte seleccionada para el HPF es de 2 Hz. Esto contribuye enormemente a la mejora de la calidad del resultado de la aplicación de ICA, ya que se trata de una técnica muy sensible a las interferencias de baja frecuencia.

En la figura 4.4 se representa en tiempo la señal filtrada con el HPF de 2 Hz, separada en tramos de colores según el anuncio. La tendencia lineal desaparece mientras que el contenido espectral no presenta variaciones sustanciales, como se puede observar en la figura 4.5.

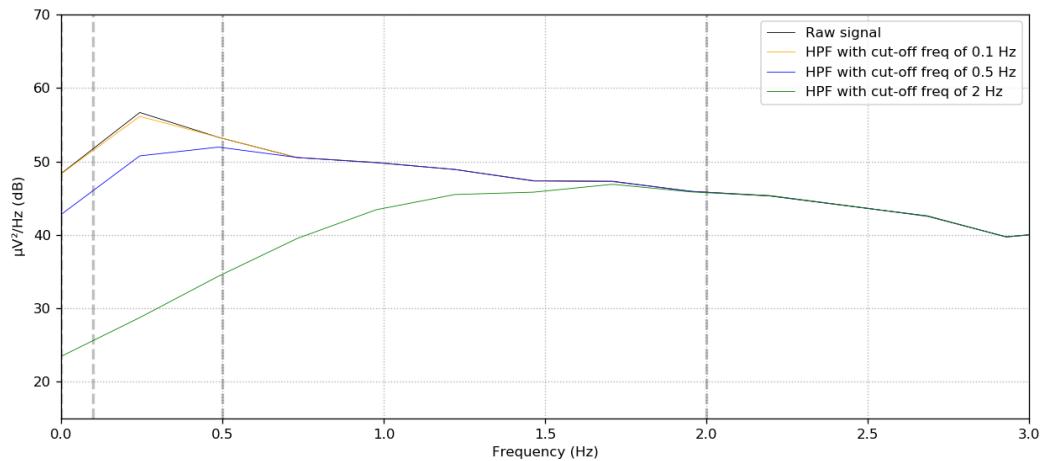


Figura 4.3: FOI de la PSD de la señal de EEG filtrada con HPF de distintas f_c . Sujeto 2900, promedio de los 31 canales.

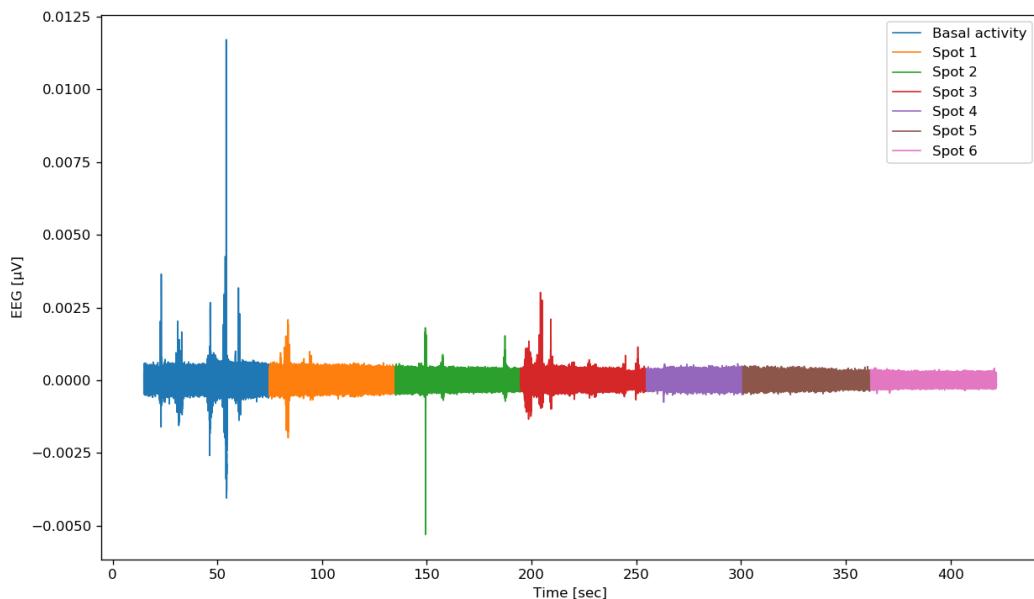


Figura 4.4: Representación en tiempo de la señal de EEG filtrada con HPF de $f_c = 2$ Hz. Canal F3 del sujeto 2900.

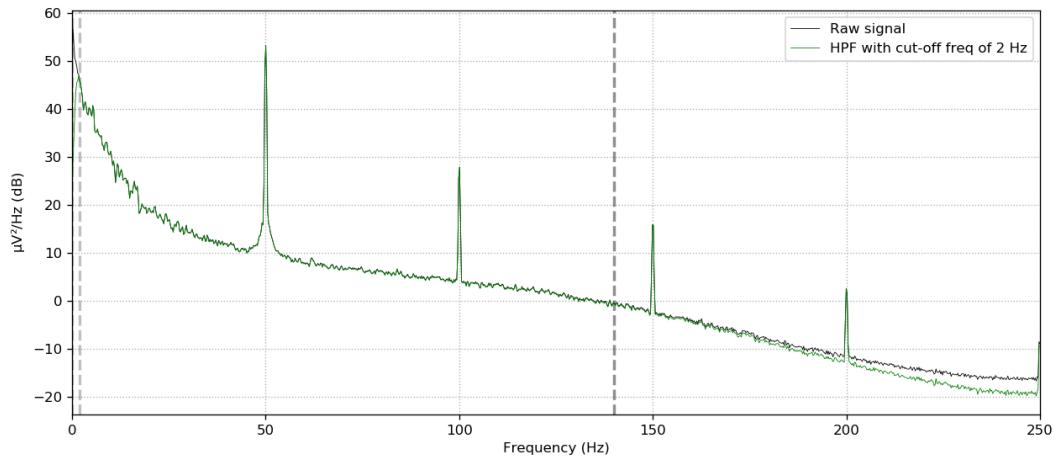


Figura 4.5: PSD de la señal de EEG filtrada con HPF de 2 Hz. Sujeto 2900, promedio de los 31 canales.

4.2.2. Experimentos con filtro paso banda

El contenido espectral propio del EEG se encuentra hasta aproximadamente unos 40 Hz en sujetos sanos, por lo que es útil eliminar el contenido espectral que esté por encima de ese umbral. En esta sección se reporta un experimento para valorar la calidad del filtrado según dos rutas de procesamiento. La primera de ellas consiste en aplicar un LPF con $f_c = 40$ Hz sobre el anterior resultado del HPF. La segunda ruta de filtrado consiste en sustituir ambos filtros por un BPF con $f_1 = 2$ Hz y $f_2 = 40$ Hz.

De la misma manera que en el HPF, el LPF y el BPF han sido diseñados con el método *filter* de la clase *Raw* del paquete MNE. En los parámetros de la función se ha especificado que el filtro sea FIR y utilice el diseño *firwin* con una ventana de *Hamming*. En ambos filtros se han tenido en cuenta diferentes valores del parámetro *filter_length*, que especifica la longitud del filtro u orden que se utiliza y en este caso se indica en unidades de tiempo. Se someten al experimento los valores: ‘auto’, 50s y 500s. El valor auto se elige basándose en el tamaño de la región de transición, siendo 6.6 veces el recíproco de la banda de transición más corta para *fir_window = 'hamming'* y *fir_design = "firwin2"*, y la mitad para “*firwin*”. Si no se especifica un valor, las bandas de transición se calculan como en las ecuaciones 4.1 y 4.2, donde *l_trans_bandwidth* es el ancho de la banda de transición inferior, *h_trans_bandwidth* es el ancho de la banda de transición superior, *f_s* es la frecuencia de muestreo y *l_freq* y *h_freq* son las frecuencias de corte inferior y superior respectivamente.

$$l_trans_bandwidth = \min(\max(l_freq * 0,25, 2), l_freq) \quad (4.1)$$

$$h_trans_bandwidth = \min(\max(h_freq * 0,25, 2), f_s/2 - h_freq) \quad (4.2)$$

No se observan cambios con la modificación del parámetro *filter_length* en ninguna de las rutas de filtrado (consultar fig. A.1 y fig. A.2), por lo tanto se deja el valor por defecto 'auto' ya que tiene un menor coste computacional. En cuanto a las diferencias en los resultados del filtrado según las dos rutas, tampoco hay ningún cambio destacable mediante exploración visual (A.3), por lo que se decide utilizar el filtro paso banda, ya que su implementación es más rápida e igual de efectiva.

En la figura 4.6 se representa la respuesta en amplitud y fase del filtro paso banda. El resultado en tiempo y en frecuencia del filtrado de la señal de EEG se puede observar en las figuras 4.7 y 4.8, respectivamente. La señal en tiempo tiene un trazo más fino y limpio, pero en la gráfica de densidad espectral de potencia se aprecia un pico de frecuencia centrado en 50 Hz que conviene eliminar en esta etapa de filtrado lineal.

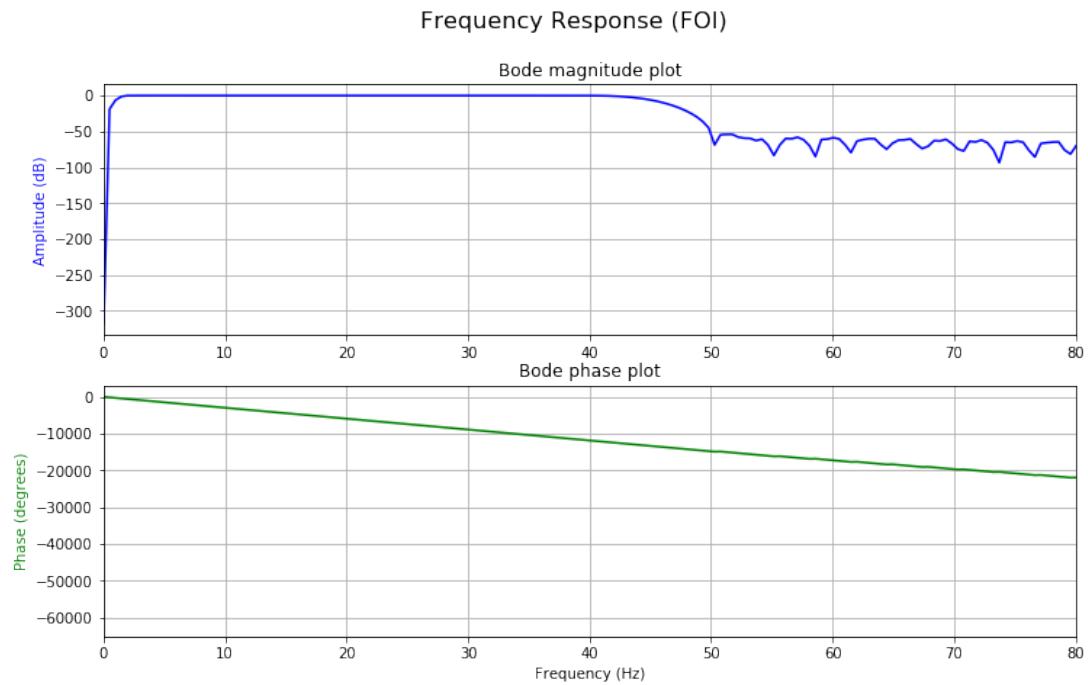


Figura 4.6: Diagrama de Bode del BPF con ($f_1 = 2$ Hz, $f_2 = 40$ Hz) y $filter_length = \text{'auto'}$.

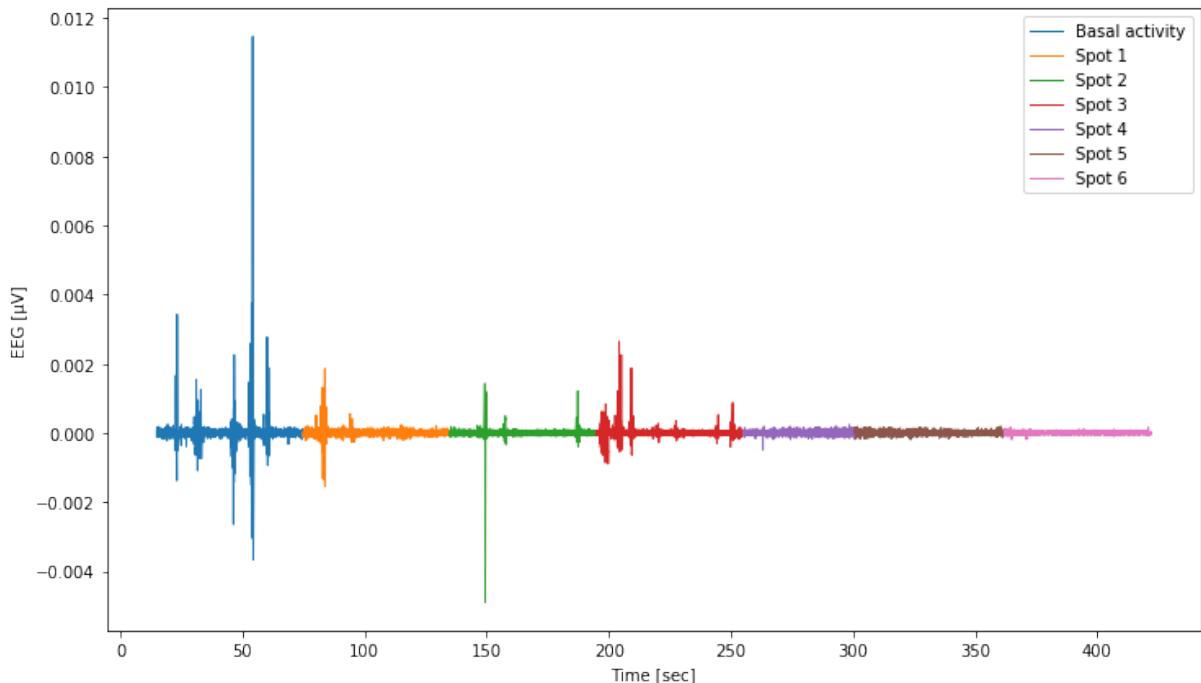


Figura 4.7: Representación de la señal de EEG en tiempo filtrada con BPF con $filter_length = \text{'auto'}$. Sujeto 2900, canal F3.

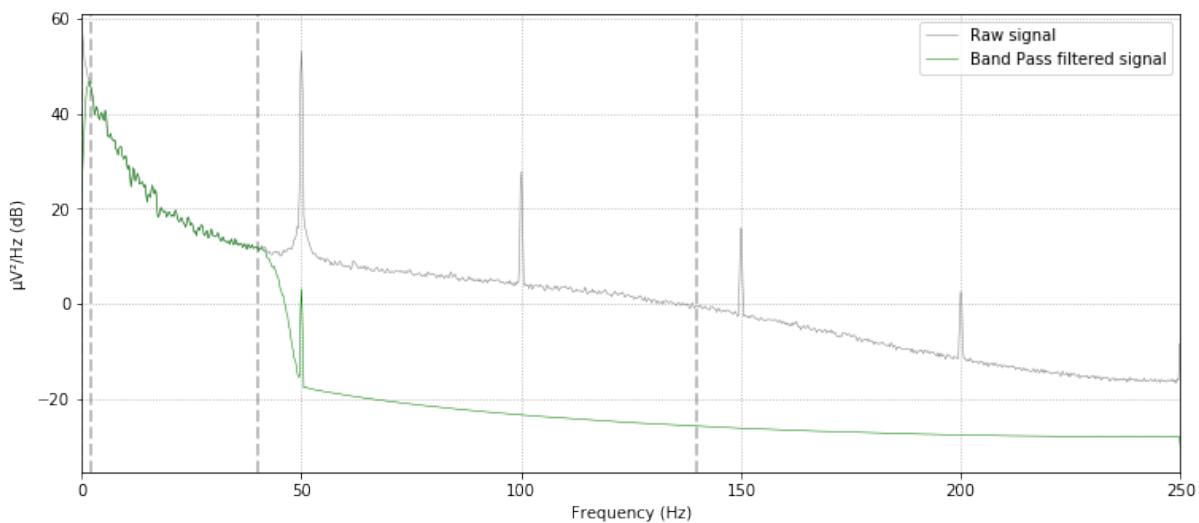


Figura 4.8: PSD de la señal filtrada con BPF con `filter_length= 'auto'`. Sujeto 2900, promedio de los 31 canales.

4.2.3. Experimentos con filtro Notch

El artefacto de la red eléctrica permanece tras haber utilizado el BPF. En la figura 4.8 se puede apreciar el pico de frecuencia centrado alrededor de 50 Hz, no así sus harmónicos, los cuales ya han sido eliminados.

Al igual que en los filtros anteriores, el filtro notch se ha diseñado con un método de la clase *Raw* del paquete MNE, *notch_filter*. De nuevo, se ha especificado en los parámetros de la función que el filtro sea FIR, tenga un diseño *firwin* y utilice una ventana de *Hamming*. Se han probado distintos valores de `filter_length`: 'auto', 50s y 500s. Los resultados no varían con la modificación de este parámetro, como se puede observar en la gráfica de la figura A.4. Se ha seleccionado el valor por defecto 'auto' como longitud del filtro, por ser el de menor coste computacional.

En la figura 4.10 se observa cómo se ha eliminado el pico de frecuencia de 50 Hz, permaneciendo el resto de frecuencias inalteradas. En la figura 4.9 se puede ver el resultado final de la señal de EEG del canal F3 del sujeto 2900 filtrada con el filtro paso banda y el filtro Notch.

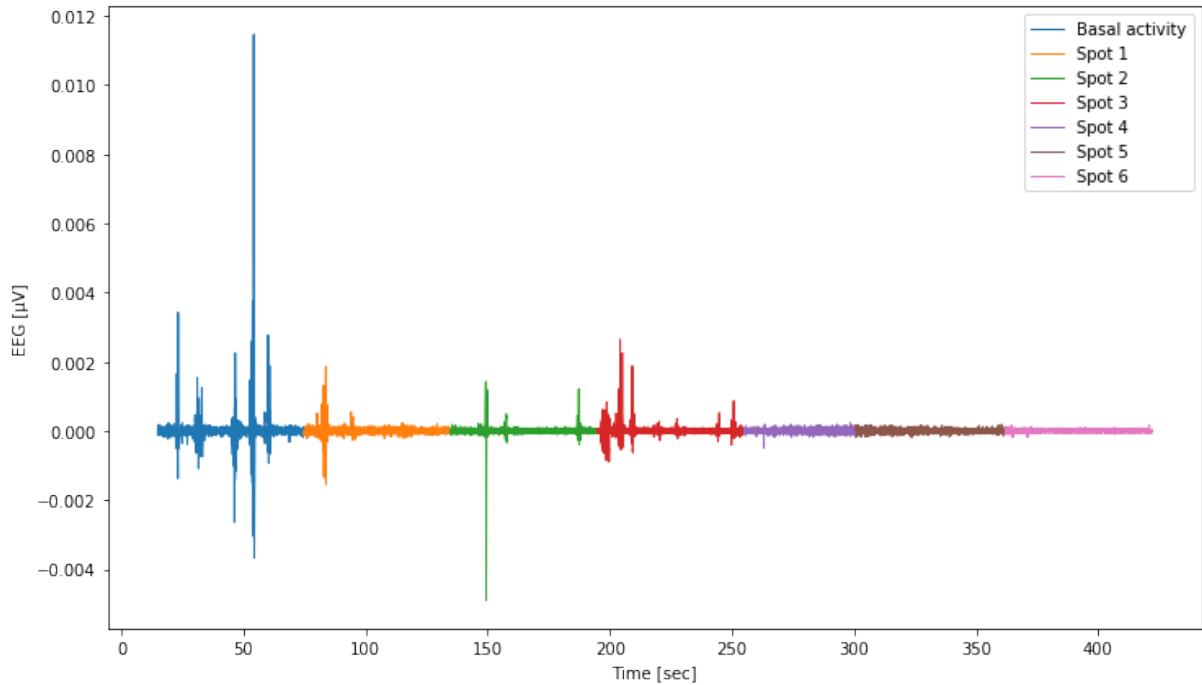


Figura 4.9: Representación de la señal de EEG en tiempo filtrada con filtro notch con *filter_length= 'auto'*. Sujeto 2900, canal F3.

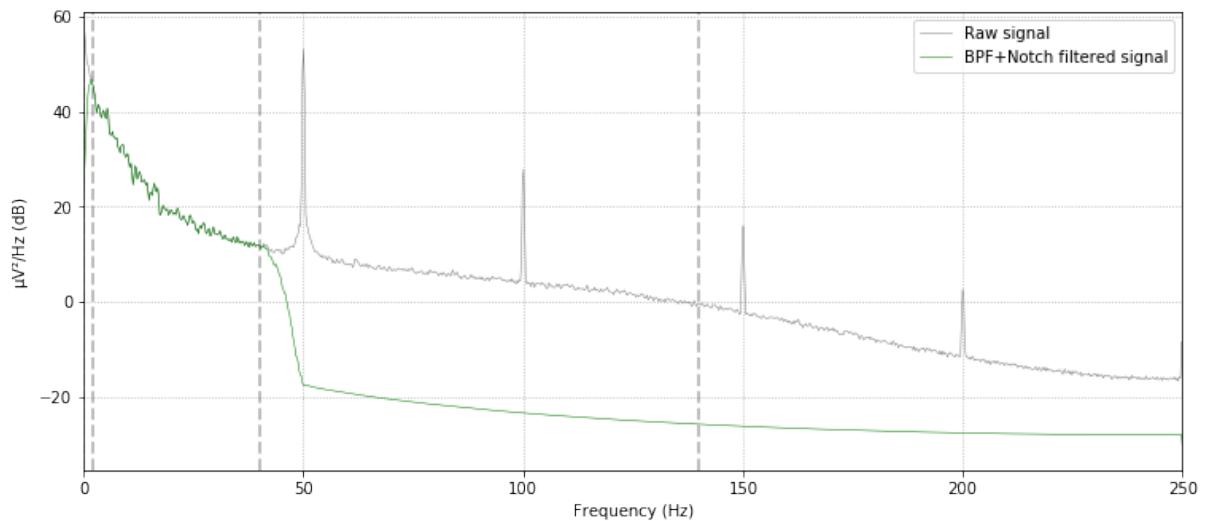


Figura 4.10: PSD de la señal filtrada con filtro notch con *filter_length= 'auto'*. Sujeto 2900, promedio de los 31 canales.

4.3. Filtrado avanzado

El algoritmo de ICA está implementado en Python por la función *mne.preprocessing.ICA* del módulo *preprocessing* del paquete MNE. El método que utiliza esta función se indica a través del parámetro *method*, pudiendo ser este: *FastICA*, *Infomax* o *Picard*. En este caso se ha decidido utilizar Picard porque realiza un buen trabajo sobre datos reales y es similar a la versión extendida de *Infomax* pero requiere menor tiempo de ejecución [26].

Otro parámetro importante de esta función es *n_components*. Éste indica el número de componentes principales, procedentes de la etapa de preblanqueo, que se utilizan para extraer las componentes independientes con ICA. Si *n_components* es igual al número de observaciones (canales), se utilizan todas las componentes principales y no se realiza una reducción de la dimensionalidad. Esta actuación se recomienda cuando no se conoce exactamente el número de fuentes independientes. Sin embargo, un valor de *n_components* demasiado alto introduce problemas de interpretabilidad. Por otra parte, si *n_components* es menor que el número de observaciones, se realiza una reducción de la dimensionalidad al extraer las componentes independientes con ICA. De manera análoga, un valor demasiado bajo de este parámetro impide que se separen correctamente las fuentes independientes. El parámetro *random_state* se ha fijado igual a 1, para poder obtener resultados reproducibles. Se evalúan los efectos de realizar ICA con *n_components*= 20 y 31 para elegir el valor más adecuado en este contexto. En las figuras 4.11 y 4.12 se representan las componentes independientes extraídas en cada caso. Se pueden observar resultados muy similares: en ambos casos se extrae una componente de contenido ocular (componente 14 y componente 19) y se ven otros artefactos espontáneos concentrados en las primeras componentes. El tiempo de ejecución del algoritmo con 31 componentes es cuatro veces superior al tiempo que tarda en realizarse con 20 (10s frente a 2s). Debido al menor tiempo de ejecución y a la similar interpretación, se selecciona *n_components* = 20.

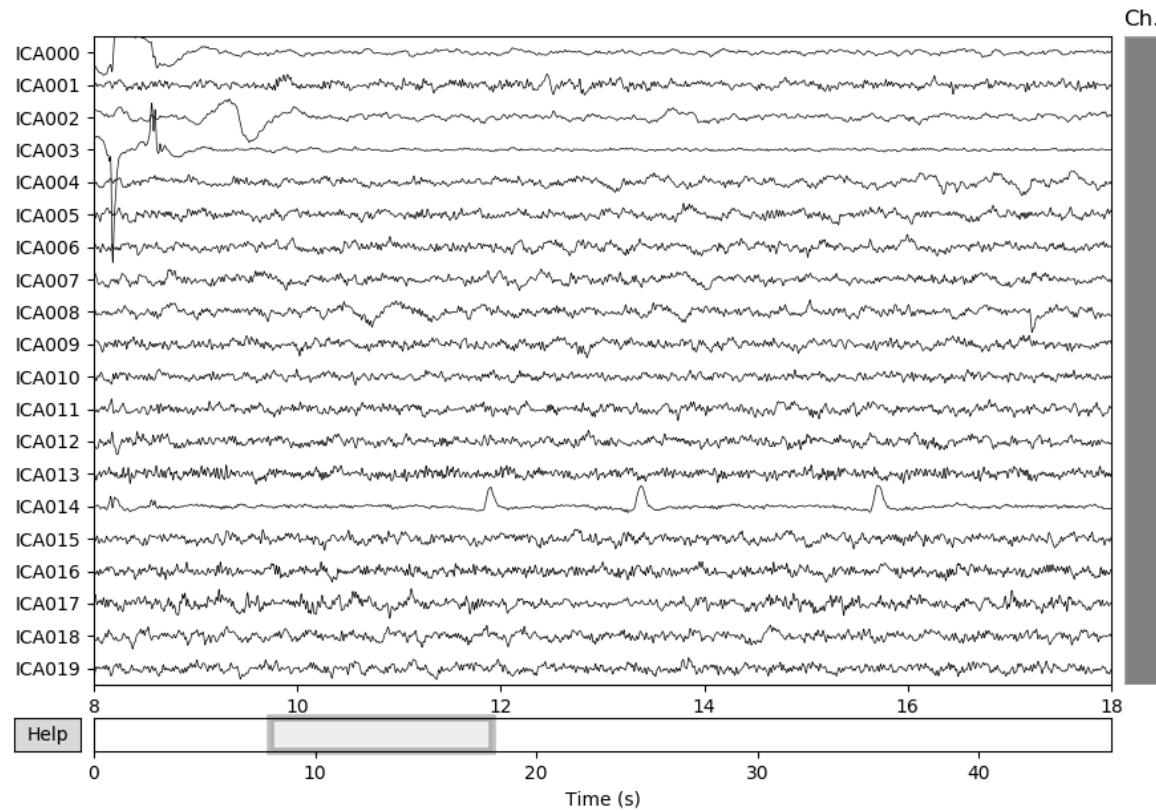


Figura 4.11: Componentes independientes obtenidas por ICA con 20 componentes. Sujeto 2900, anuncio 3.

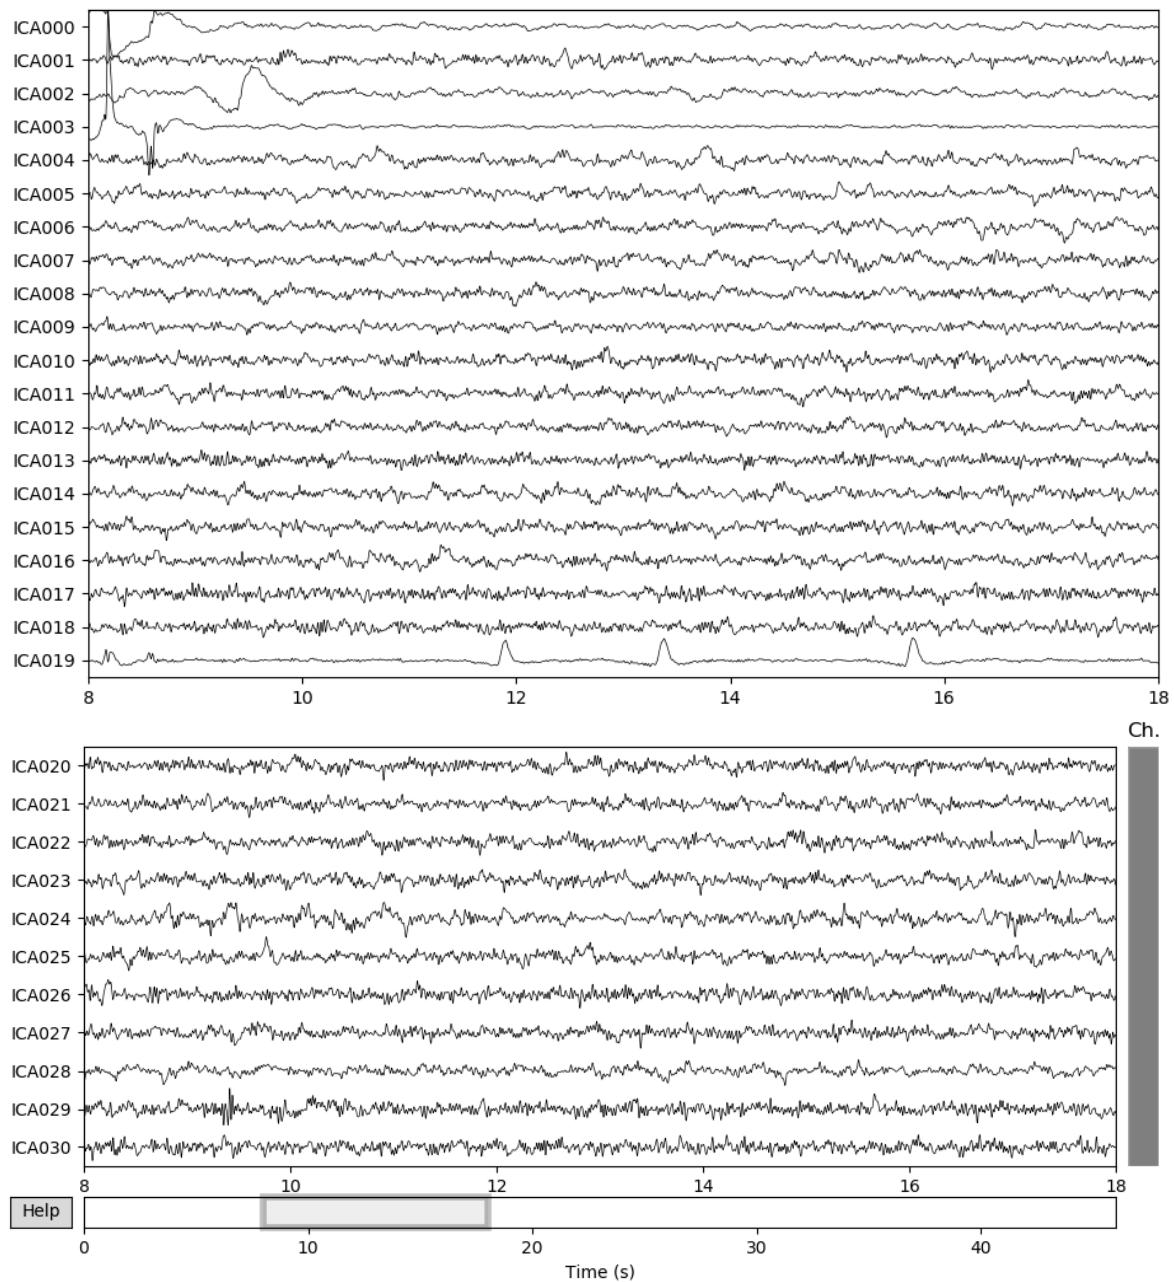


Figura 4.12: Componentes independientes obtenidas por ICA con 31 componentes. Sujeto 2900, anuncio 3.

La interpretación de las componentes independientes extraídas por ICA se realiza en conjunto con la representación de las fuentes y los mapas topográficos. En la figura 4.13 se puede ver el mapa topográfico de las 20 componentes independientes obtenidas por ICA en el tramo del anuncio 3 de la señal de EEG extraída del sujeto 2900. Así, la componente número 14 (fig. 4.14) representa claramente actividad ocular, concretamente parpadeo, debido a los patrones

periódicos observables en la señal y la distribución frontal de los pesos más grandes en el mapa topográfico.

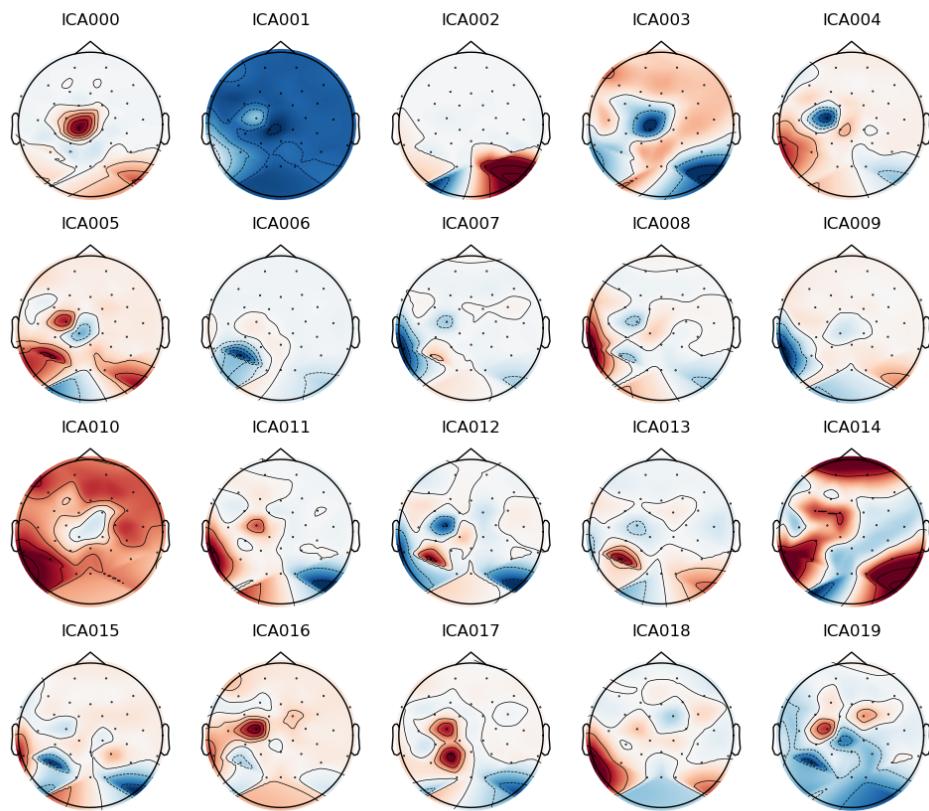


Figura 4.13: Mapas topográficos de las componentes independientes. Sujeto 2900, anuncio 3.

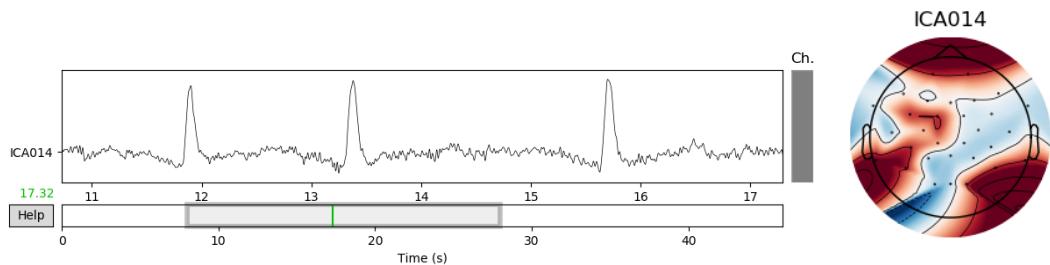


Figura 4.14: Forma de onda y mapa topográfico de la componente independiente que captura el parpadeo. Componente 14, anuncio 3, sujeto 2900.

En la figura 4.15 se observa otro patrón ocular característico, el movimiento de los ojos,

localizado en la señal de EEG del anuncio 4, sujeto 0656. Otro patrón repetido durante la localización de artefactos en este proyecto es el de la figura 4.16, debido a la concentración de ruido en un electrodo concreto.

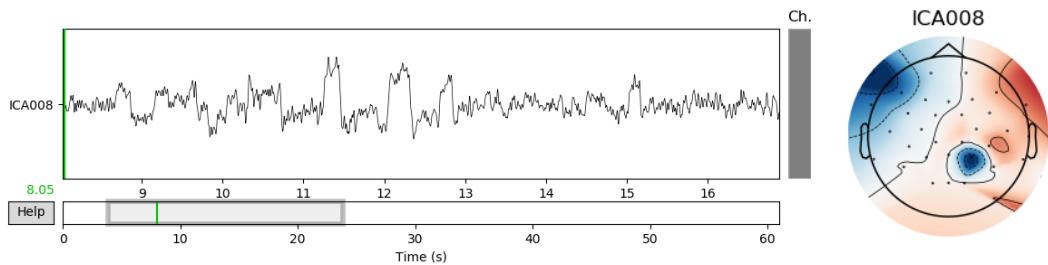


Figura 4.15: Forma de onda y mapa topográfico de la componente independiente que captura el movimiento de los ojos. Componente 5, anuncio 2, sujeto 0656.

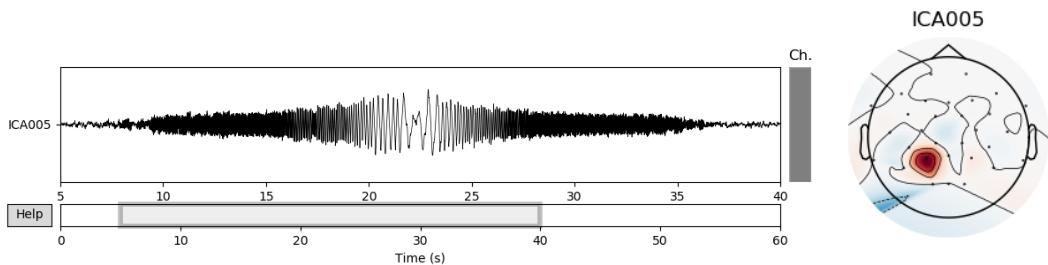


Figura 4.16: Forma de onda y mapa topográfico de la componente independiente que captura ruido introducido por un electrodo. Componente 8, anuncio 4, sujeto 0656.

La utilidad de ICA en este proyecto es eliminar artefactos, y no localizar las componentes independientes, por lo que tras eliminar las componentes claramente asociadas a ruido (consultar tabla 4.1) se reconstruye la señal original. En la figura 4.17 se compara la señal de EEG del sujeto 2900 durante la visualización del anuncio 3 procesada sólo con filtros lineales básicos (arriba) y después de retirar las componentes con artefactos (0, 2, 3, 8, 10 y 14) extraídas con la técnica de ICA (abajo). Este proceso se repite para todos los tramos de la señal, es decir, para el minuto de actividad basal y los 6 anuncios en cada uno de los 5 sujetos seleccionados. Por lo tanto, se trata de un proceso manual de selección de las componentes con artefactos, lo que varía considerablemente tanto entre diferentes sujetos como dentro del mismo sujeto.

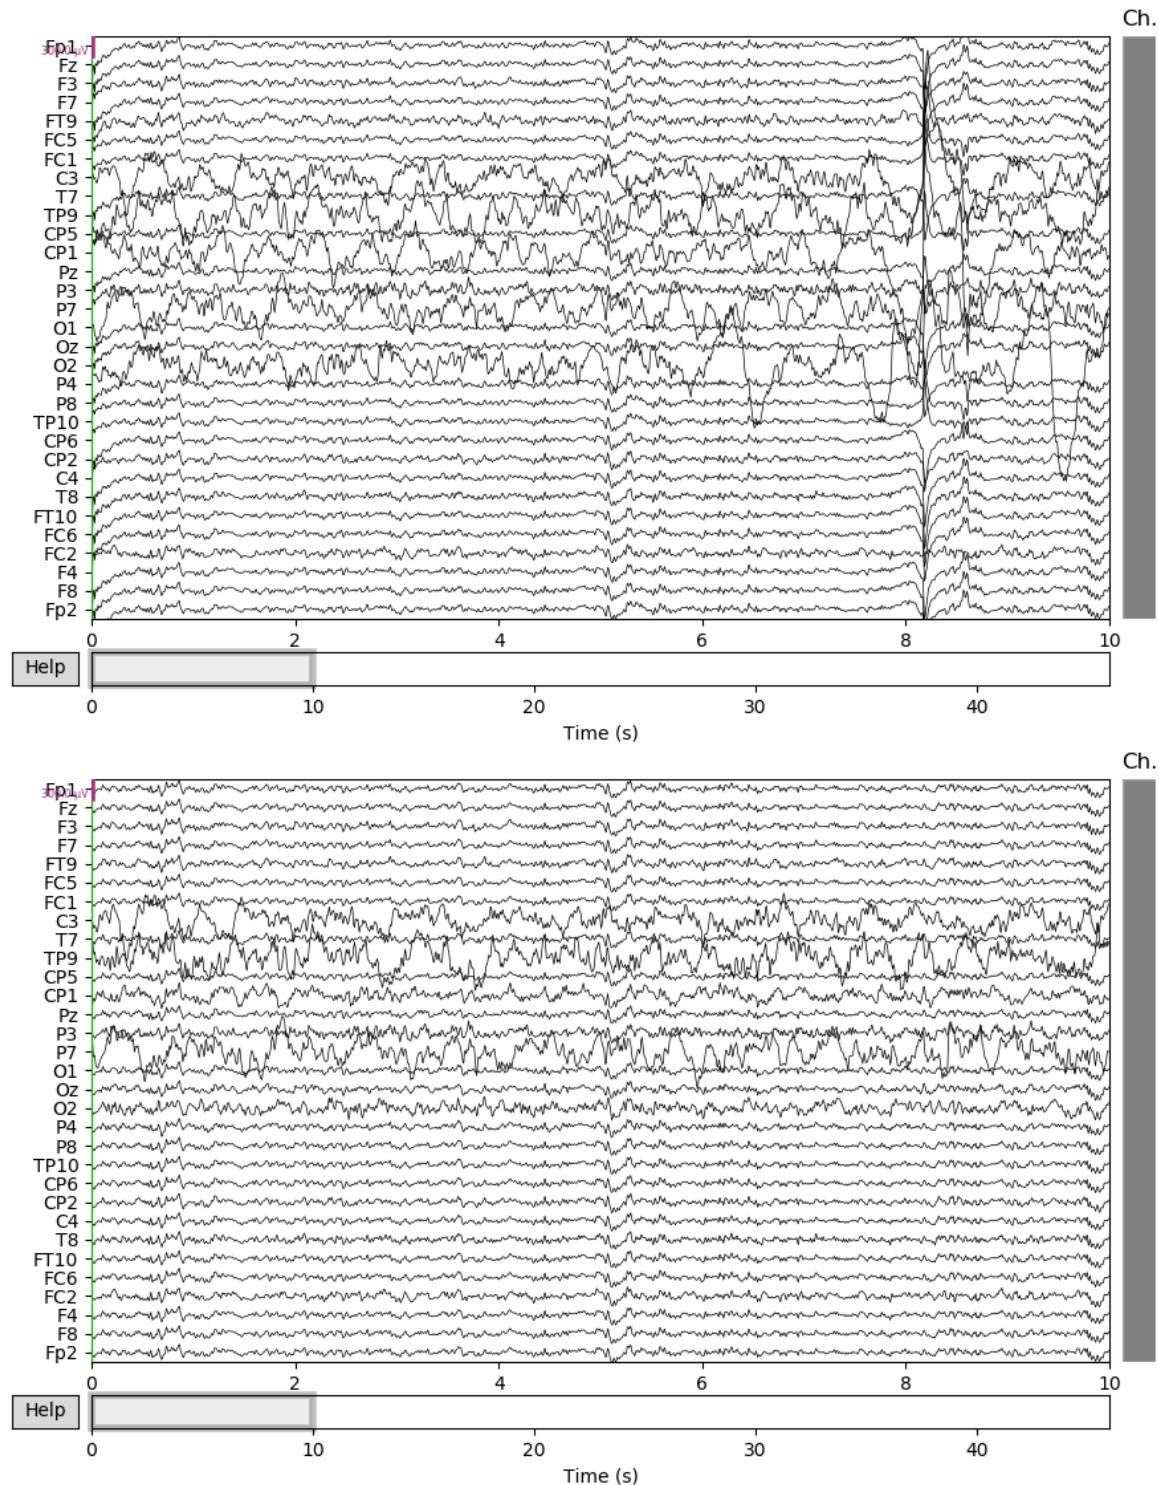


Figura 4.17: Representación en tiempo del efecto del filtrado con ICA. Sólo filtros lineales básicos (arriba) y filtros lineales básicos + ICA (abajo). Sujeto 2900, anuncio 3.

Subject	Basal Activity	Spot 1	Spot 2	Spot 3	Spot 4	Spot 5	Spot 6
0656	0, 1, 2, 3, 4, 5, 6, 12, 14, 15, 19	0, 1, 3, 11, 16, 17	0, 1, 5, 10, 11, 13, 14, 18	0, 1, 2, 3, 4, 5, 6, 8, 9, 13, 19	0, 1, 2, 3, 6, 8, 9, 18	0, 1, 10, 14, 18, 19	0, 1, 3, 5, 7, 15, 19
1702	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 15, 17, 18, 19	0, 1, 2, 3, 8, 11, 12, 16, 17, 18, 19	0, 1, 2, 5, 10, 13, 16, 18, 19	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 14, 16, 17, 18, 19	0, 1, 2, 3, 4, 5, 6, 7, 9, 11, 13, 14, 16, 17, 18, 19	1, 2, 3, 4, 7, 8, 9, 13, 15, 16, 18, 19	0, 1, 2, 3, 4,
2900	0, 1, 2, 3, 4, 5, 15, 17	0, 1, 2, 5, 11, 12, 16	0, 1, 2, 3, 4, 5, 7, 9, 10, 11, 12, 19	0, 2, 3, 8, 10, 14	0, 1, 2, 11, 16, 18, 19	0, 1, 2, 3, 7, 9, 11, 14, 19	5, 6, 7, 10, 11, 12, 13, 15, 16, 17, 18, 19
6401	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 12, 13, 15, 18	0, 1, 9, 15	0, 1, 19	0, 1, 11, 19	0, 1, 2, 3, 5, 6, 19	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 11, 12, 14, 15, 16, 17, 18	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 15, 17, 18
8091	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 16, 18, 19	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 16, 17, 19	0, 1, 2, 3, 4, 5, 6, 7, 8, 10, 9, 10, 11, 12, 13, 14, 16	0, 1, 2, 3, 4, 5, 6, 7, 8, 10, 11, 12, 14, 15, 19	0, 1, 2, 3, 4, 5, 6, 7, 8, 10, 11, 12, 15, 16, 18	0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 12, 13	0, 1, 2, 3, 5, 6, 7, 9, 11, 12, 13, 15

Tabla 4.1: Componentes independientes asociadas a artefactos en cada uno de los sujetos y tramos de la señal de EEG.

4.4. Extracción de indicadores

Para extraer la potencia en la banda alpha de las señales se define la función `get_pow_alpha` en el archivo .py ‘*TFG_utils*’. Esta función calcula el periodograma de la señal con la función `signal.periodogram` del módulo *SciPy* y obtiene las potencias asociadas al rango de frecuencias de la banda alpha, 8-14 Hz. Los canales utilizados para la extracción del índice de agrado-rechazo son el F3 y F7 del hemisferio derecho y el F4 y F8 del hemisferio izquierdo. Con las potencias de la banda alpha de cada uno de esos canales se calcula el GFP y a continuación el AWI.

En la tabla 4.2 se muestran los resultados de los AWI de cada anuncio para cada sujeto, así como la media para cada tramo de la señal. La representación de estos valores se muestra en las figuras 4.18 y 4.19. Se puede observar que el anuncio con un índice más bajo es el 3, en el que aparecen escenas de maltrato y violencia de manera repetitiva durante toda la duración del anuncio. Por otra parte, el anuncio con un AWI más elevado es el 5, en el que 50 segundos pertenecen a una conversación entre dos conductores y las secuencias más desagradables transcurren en menos de 3 segundos. Aún así, es importante saber que los datos no están normalizados y consecuentemente no es correcto establecer comparaciones según el valor del índice.

Subject	Basal Activity	Spot 1	Spot 2	Spot 3	Spot 4	Spot 5	Spot 6
0656	-3.505×10^{-22}	9.340×10^{-23}	1.994×10^{-23}	2.690×10^{-23}	1.017×10^{-22}	9.974×10^{-23}	1.837×10^{-23}
1702	6.548×10^{-23}	-8.395×10^{-24}	-2.107×10^{-23}	-2.038×10^{-23}	3.337×10^{-23}	5.950×10^{-24}	-4.853×10^{-24}
2900	3.876×10^{-20}	-2.539×10^{-23}	-1.183×10^{-22}	1.431×10^{-20}	1.911×10^{-22}	1.136×10^{-21}	-2.781×10^{-20}
6401	-2.570×10^{-21}	-6.668×10^{-20}	-7.316×10^{-20}	-5.155×10^{-20}	-4.385×10^{-20}	1.109×10^{-17}	3.209×10^{-21}
8091	-8.506×10^{-19}	5.623×10^{-20}	-2.615×10^{-19}	-1.078×10^{-16}	-6.597×10^{-20}	-6.892×10^{-19}	-1.953×10^{-19}
mean	-1.629×10^{-19}	-2.077×10^{-21}	-6.697×10^{-20}	-2.156×10^{-17}	-2.189×10^{-20}	2.080×10^{-18}	-4.398×10^{-20}

Tabla 4.2: Índices de agrado-rechazo de cada uno de los tramos de la señal EEG de cada sujeto. Datos sin normalizar.

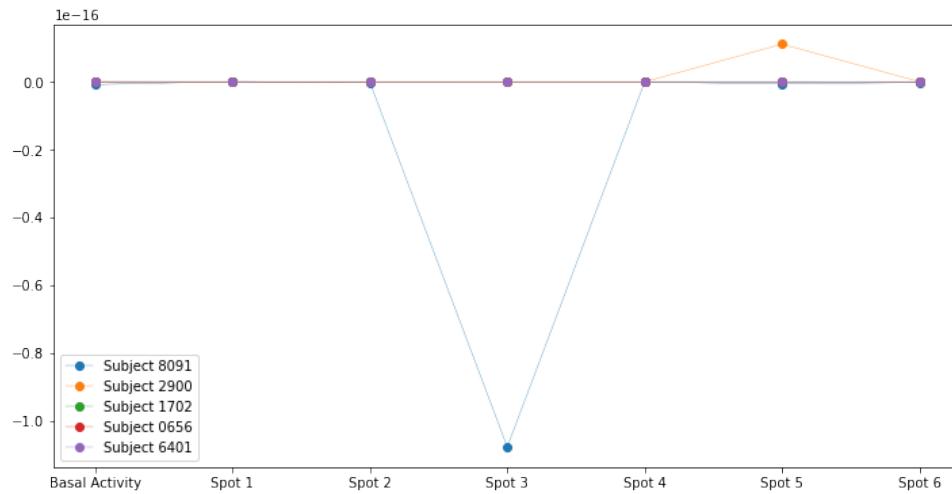


Figura 4.18: Representación de los AWI extraídos de cada anuncio, sin normalizar

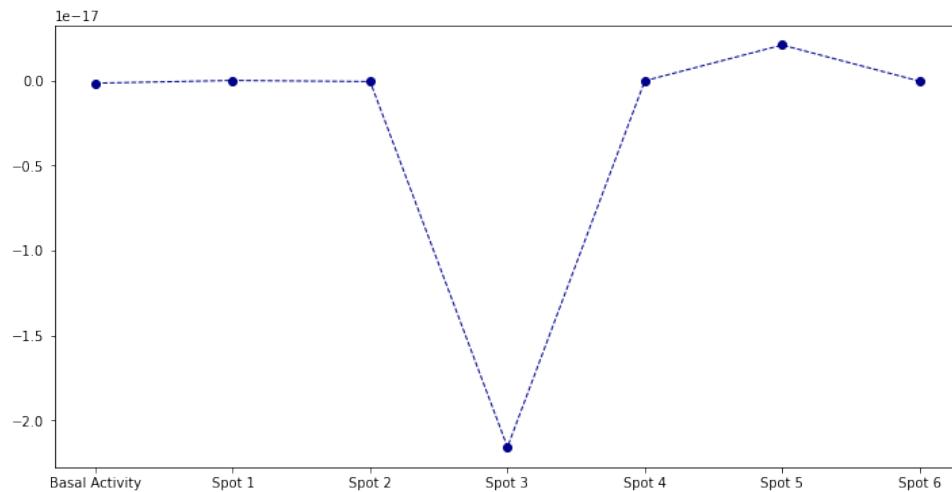


Figura 4.19: Representación de la media de los AWI extraídos de cada anuncio, sin normalizar.

A continuación se muestran los resultados del AWI tras normalizar los datos de la tabla

4.2 según la estrategia propuesta en [1]. Los AWI de los anuncios se dividen por los AWI de los minutos basales de actividad, en valor absoluto para no interferir en el signo del índice. De esta manera se realiza una normalización personalizada para cada sujeto, obteniéndose los resultados recogidos en la tabla 4.3. Los valores resaltados en color se consideran outliers por desviarse considerablemente del valor del resto de índices de la tabla. La fila del sujeto 6401 se elimina y el valor del AWI del tramo 3 del sujeto 8091 se imputa por la mediana de la columna. En el anexo A.3 se recoge un ejemplo del filtrado con ICA en el sujeto 6401, correspondiente con la fila de AWI eliminada, donde se aprecia que la adquisición es bastante ruidosa. Las representaciones obtenidas (fig 4.20 y fig 4.21) difieren considerablemente de la representación con los datos sin normalizar. En este caso, el anuncio con un índice más negativo es el 6, en el que aparece un sanitario promoviendo la ayuda de especialistas para dejar adicciones. El anuncio 4, sobre el peligro de conducir bajo el consumo de alcohol, tiene el AWI más positivo de todos.

Subject	Basal Activity	Spot 1	Spot 2	Spot 3	Spot 4	Spot 5	Spot 6
0656	-1.0	0.266	0.056	0.076	0.290	0.284	0.052
1702	1.0	-0.128	-0.321	-0.311	0.509	0.090	-0.074
2900	1.0	-0.006	-0.003	0.369	0.004	0.029	-0.717
6401	-1.0	-25.944	-28.466	-20.057	-17.060	4315.935	1.248
8091	-1.0	0.066	-0.307	-126.727	-0.077	-0.810	-0.229
mean*	0.0	0.050	-0.143	0.004	0.181	-0.101	-0.242

Tabla 4.3: Índices de agrado-rechazo de cada uno de los tramos de la señal EEG de cada sujeto. Datos normalizados según [1]. *La media se calcula sin tener en cuenta las celdas coloreadas.

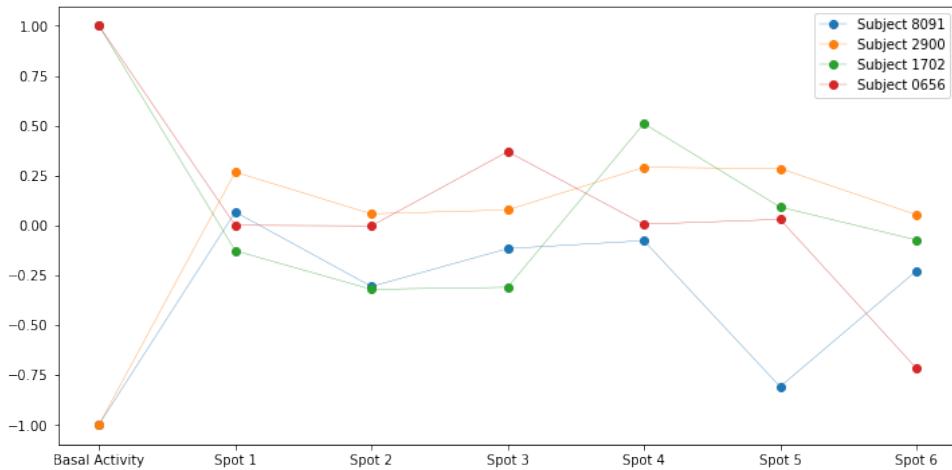


Figura 4.20: Representación de los AWI extraídos de cada anuncio, dividiendo por el AWI basal.

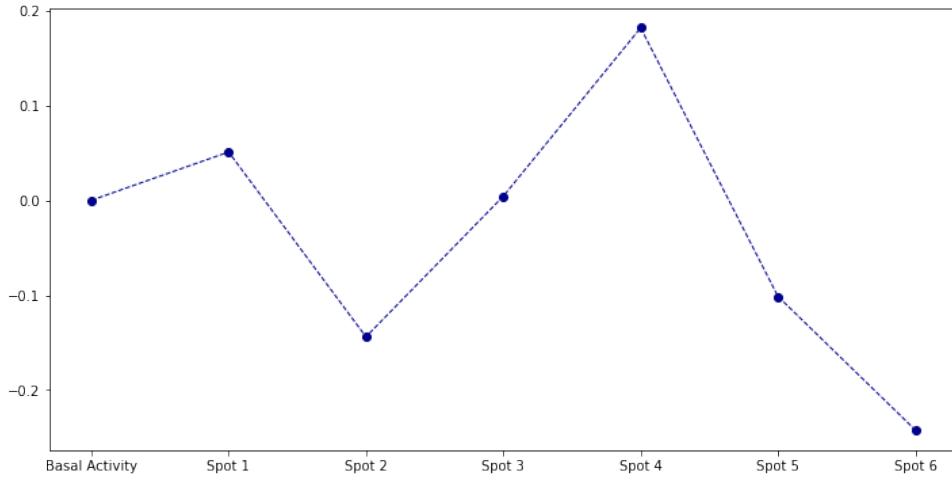


Figura 4.21: Representación de la media de los AWI extraídos de cada anuncio, dividiendo por el AWI basal.

Por último, se ha aplicado una normalización min-max o reescalado de los datos con la función *MinMaxScaler()* del paquete preprocessing del módulo *Scikit-learn*. La transformación se realiza restando a cada valor el valor mínimo y dividiendo por la diferencia entre el valor máximo y el mínimo (ecuación 4.3), de forma que todos los valores se llevan al rango [0,1]. Este escalado de los datos se aplica en sentido horizontal en la tabla 4.2, es decir, intrasujeto. De esta forma, se conserva la reacción del sujeto a cada anuncio, no se pierde información de qué anuncio provoca más rechazo o menos y no predomina el valor de algunos índices sobre el resto. Tras aplicar este tipo de normalización se representan las figuras 4.22 y 4.23 con los valores de la tabla 4.4. En este caso, no se sabe si el índice es positivo o negativo pero se puede comparar cuantitativamente con el resto de índices. El anuncio 3 tiene el AWI más bajo mientras que el 5 tiene el valor más alto de todos.

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (4.3)$$

Subject	Basal Activity	Spot 1	Spot 2	Spot 3	Spot 4	Spot 5	Spot 6
0656	0.0	0.981	0.819	0.834	1.0	0.995	0.815
1702	1.0	0.146	0.0	0.007	0.629	0.312	0.187
2900	1.0	0.417	0.415	0.632	0.420	0.434	0.0
6401	0.006	0.005	0.0	0.001	0.002	1.0	0.006
8091	0.991	1.0	0.997	0.0	0.998	0.993	0.997
mean	0.599	0.509	0.446	0.295	0.610	0.747	0.401

Tabla 4.4: Índices de agrado-rechazo de cada uno de los tramos de la señal EEG de cada sujeto, con normalización min-max.

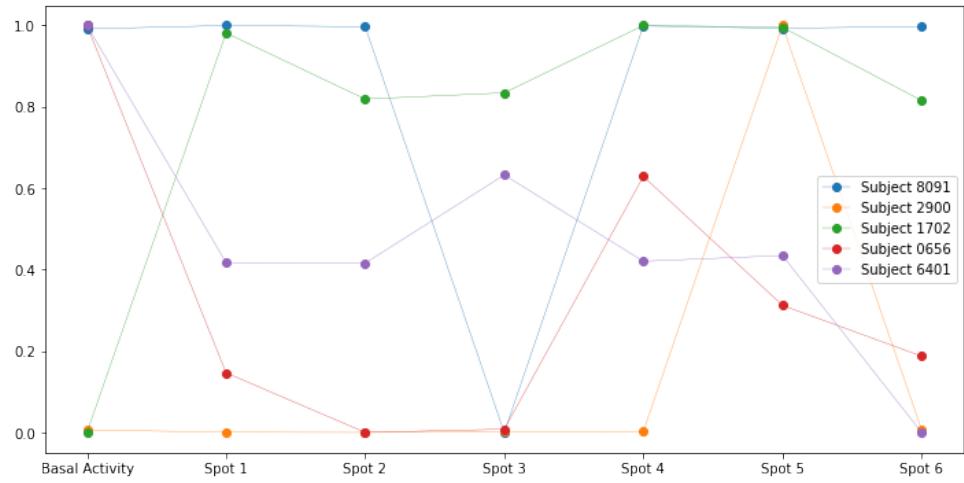


Figura 4.22: Representación de la media de los índices de agrado-rechazo extraídos de cada anuncio con normalización min-max.

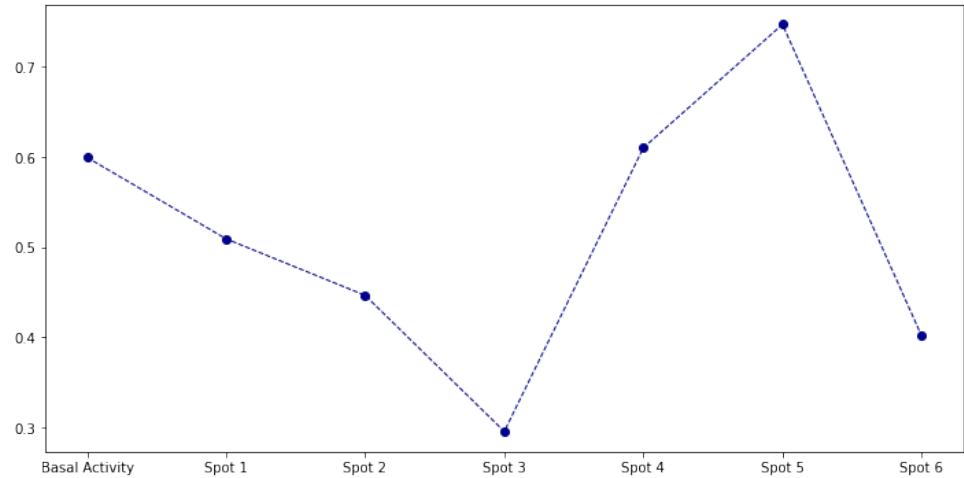


Figura 4.23: Gráfica poblacional de los índices de agrado-rechazo extraídos de cada anuncio con normalización min-max.

Capítulo 5

Conclusiones y líneas futuras

5.1. Conclusiones

Las principales conclusiones obtenidas tras la realización de este proyecto son:

- Las señales de EEG son muy complejas. Optimizar la adquisición de las mismas y mejorar su calidad es clave para poder extraer información de ellas.
- La mejor configuración de filtros básicos lineales para realizar posteriormente ICA es un BPF de 2-40 Hz seguido de un filtro *Notch* de 50 Hz.
- La técnica de ICA tiene una interpretabilidad subjetiva y complicada, aunque permite localizar y extraer correctamente los artefactos oculares.
- La extracción del AWI en el presente proyecto no ha resultado satisfactorio quizá debido al reducido tamaño de la muestra poblacional. Por otro lado, el índice ha resultado difícilmente interpretable ya que sus valores basales son positivos para algunos sujetos y negativos para otros.

5.2. Líneas futuras

Entre las preguntas que pueden formularse a partir de los resultados obtenidos en esta investigación se encuentran las siguientes líneas futuras de trabajo:

- Valorar otras herramientas de programación con más usuarios y documentación disponible, por ejemplo EEGLAB de MATLAB.
- Utilizar las señales de ECG recogidas durante el experimento para realizar una cancelación de artefactos.
- Profundizar en el número de componentes óptimos a extraer con ICA.
- Automatizar el procesado con ICA, para poder realizar el estudio de Neuromarketing con una muestra poblacional mayor y así esclarecer los resultados obtenidos.
- Incluir la señal de ECG y EDA para ampliar el estudio con otros índices neurométricos como el CEI o el índice emocional.

Apéndice A

Anexos

A.1. PSD experimentos filtros básicos sujeto 2900

A continuación se muestran las PSD de la señal EEG completa del sujeto 2900, en la realización de los experimentos con filtros lineales básicos.

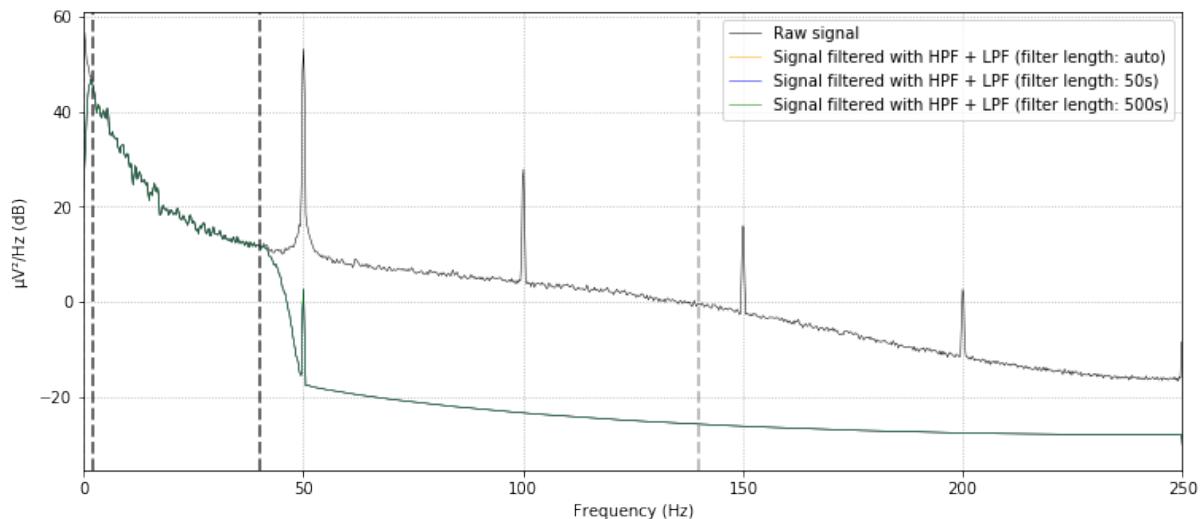


Figura A.1: PSD de la señal de EEG filtrada con LPF de diferentes longitudes. Sujeto 2900, promedio de los 31 canales.

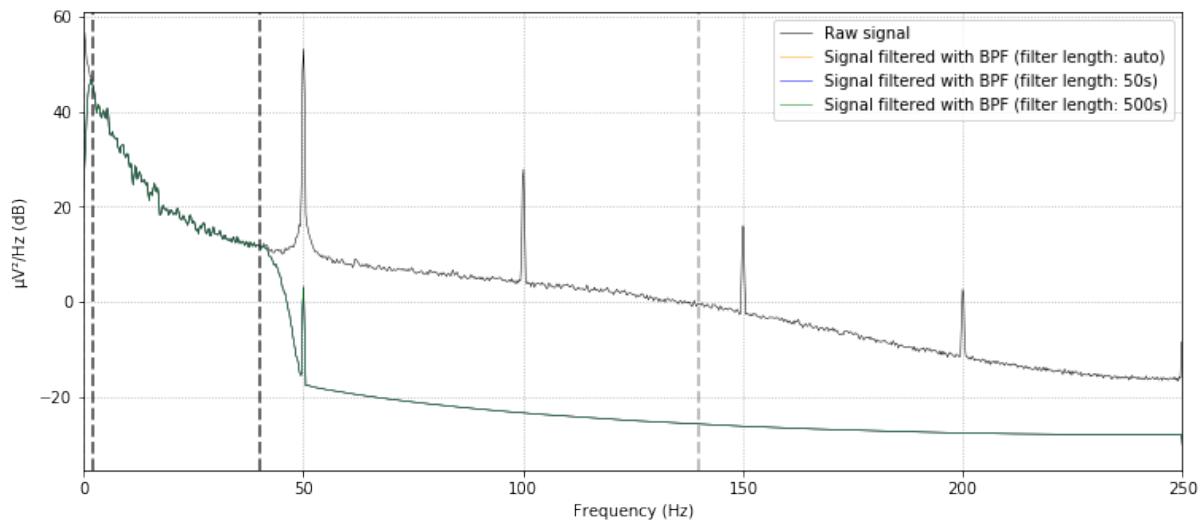


Figura A.2: PSD de la señal de EEG filtrada con BPF de diferentes longitudes. Sujeto 2900, promedio de los 31 canales.

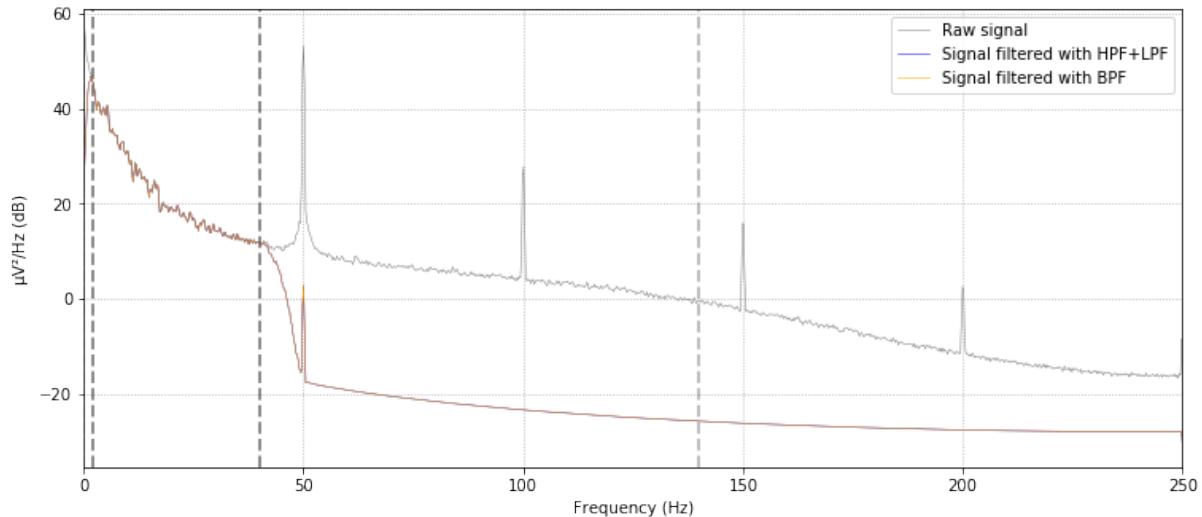


Figura A.3: PSD de la señal de EEG filtrada con BPF y con HPF+LPF. Sujeto 2900, promedio de los 31 canales.

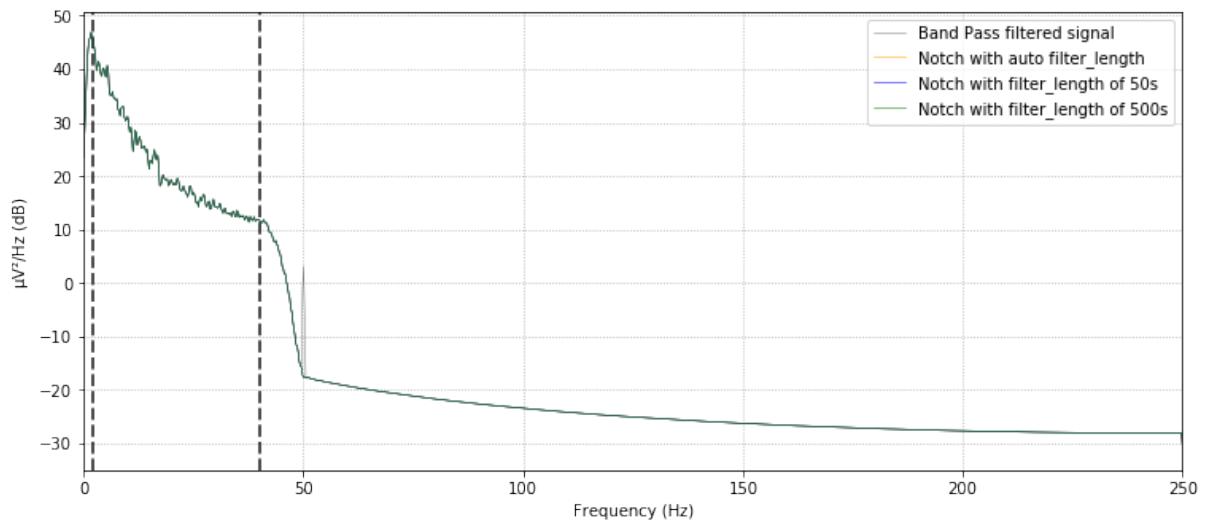


Figura A.4: PSD de la señal filtrada con filtro notch de distintas longitudes. Sujeto 2900, promedio de los 31 canales.

A.2. Mapas topográficos sujeto 2900

En este anexo se encuentran los mapas topográficos de las componentes independientes extraídas con ICA de la grabación de EEG del sujeto 2900.

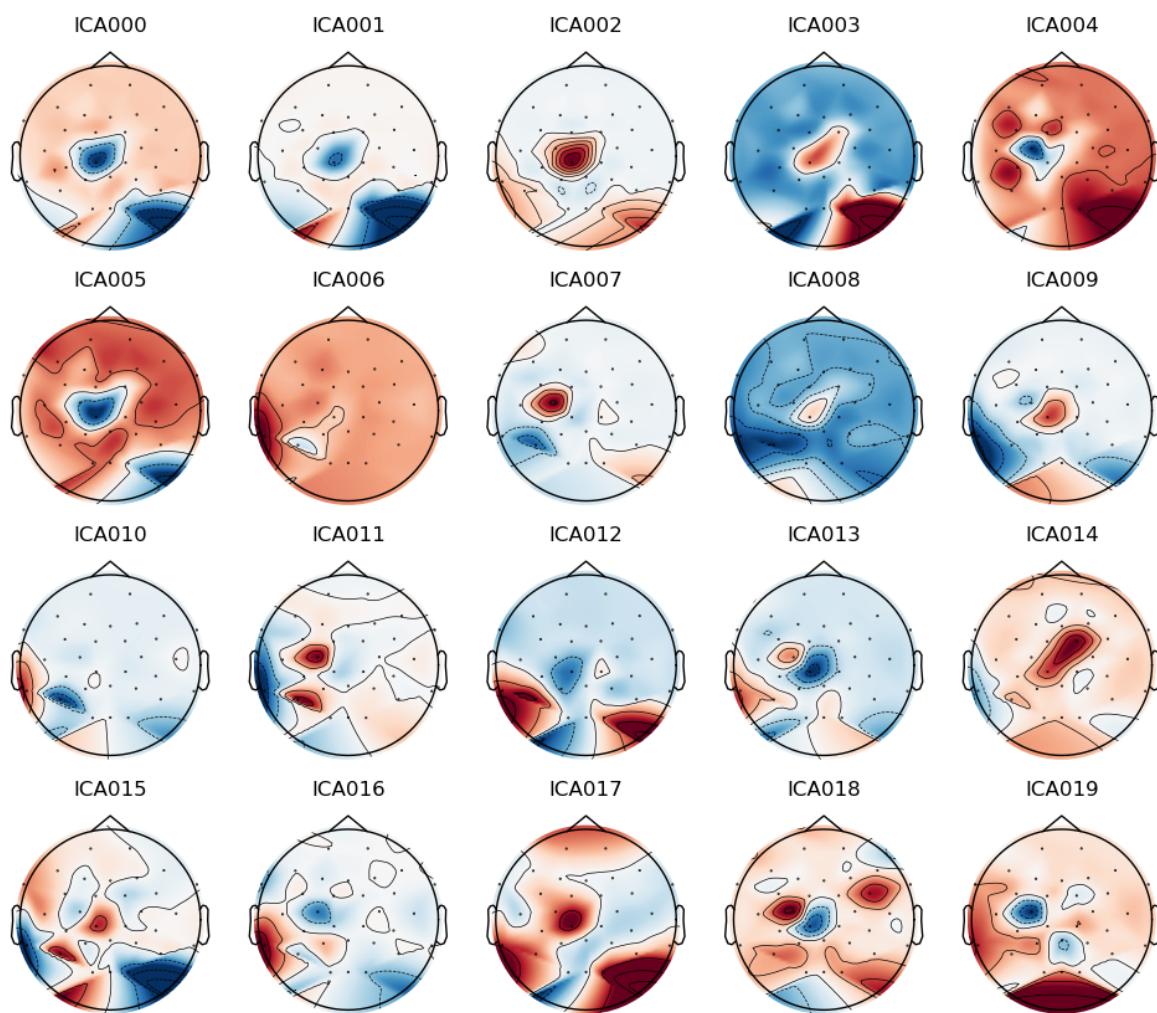


Figura A.5: Mapa topográfico de las componentes independientes del sujeto 2900, minuto de actividad basal

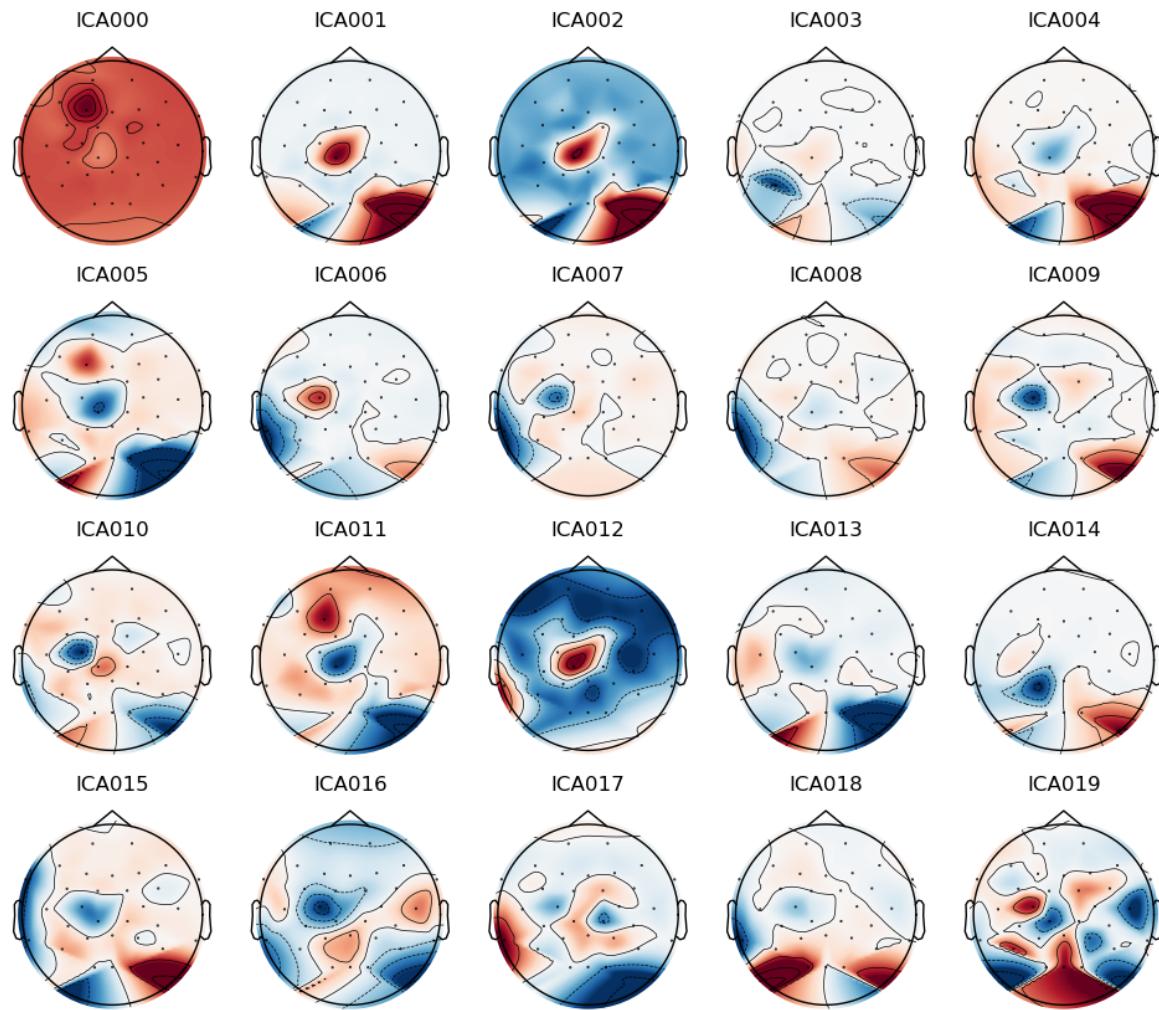


Figura A.6: Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 1

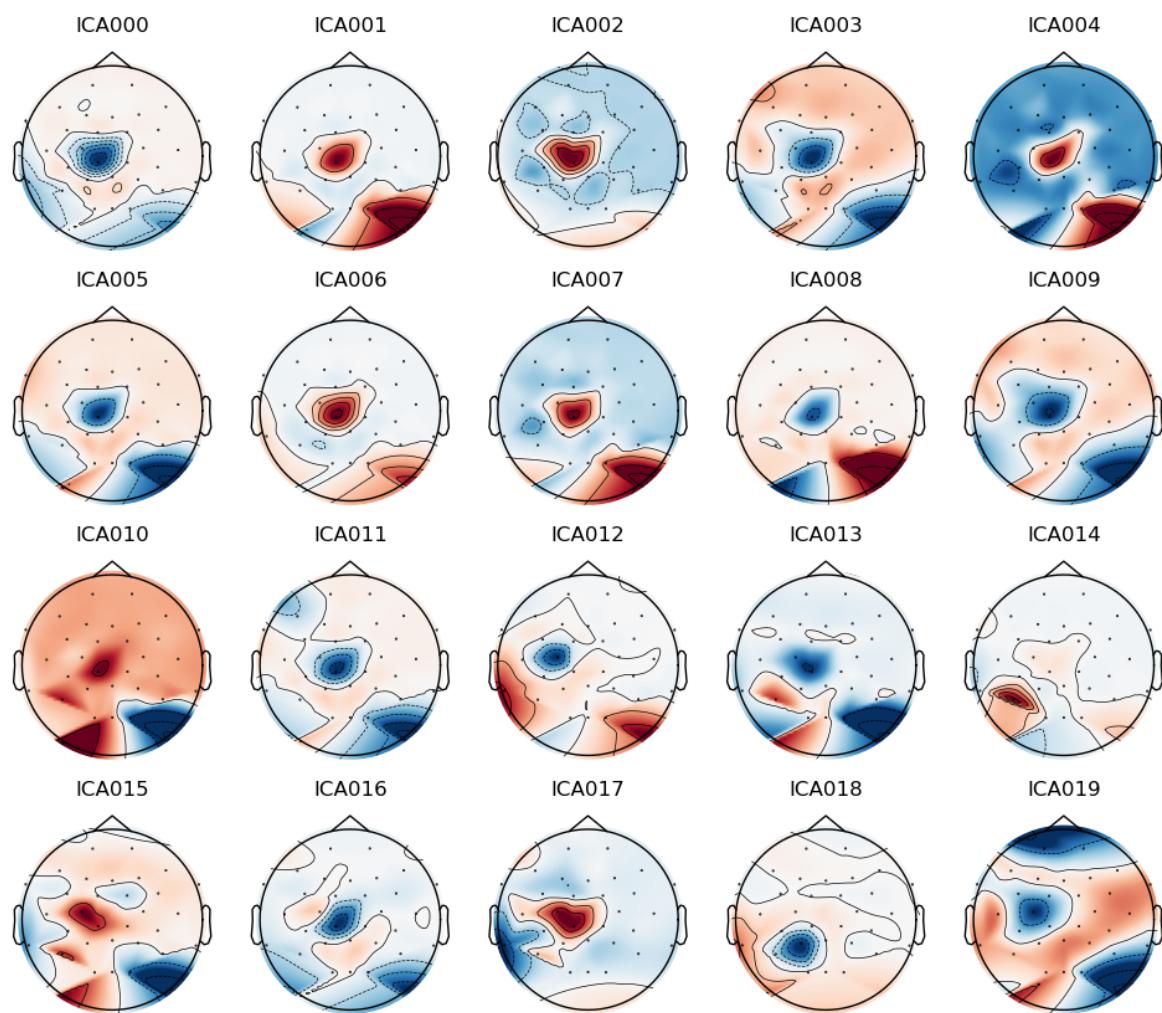


Figura A.7: Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 2

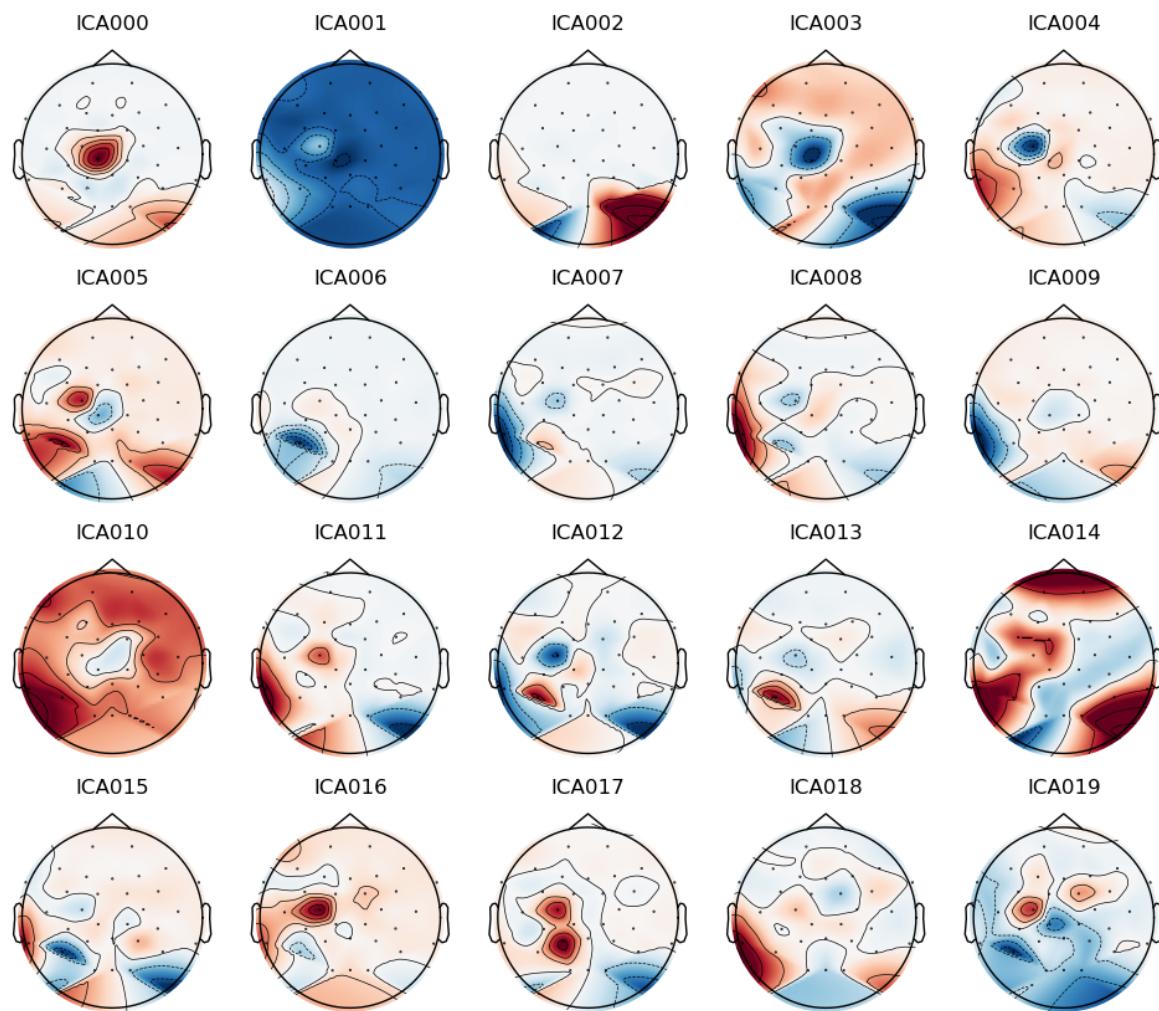


Figura A.8: Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 3

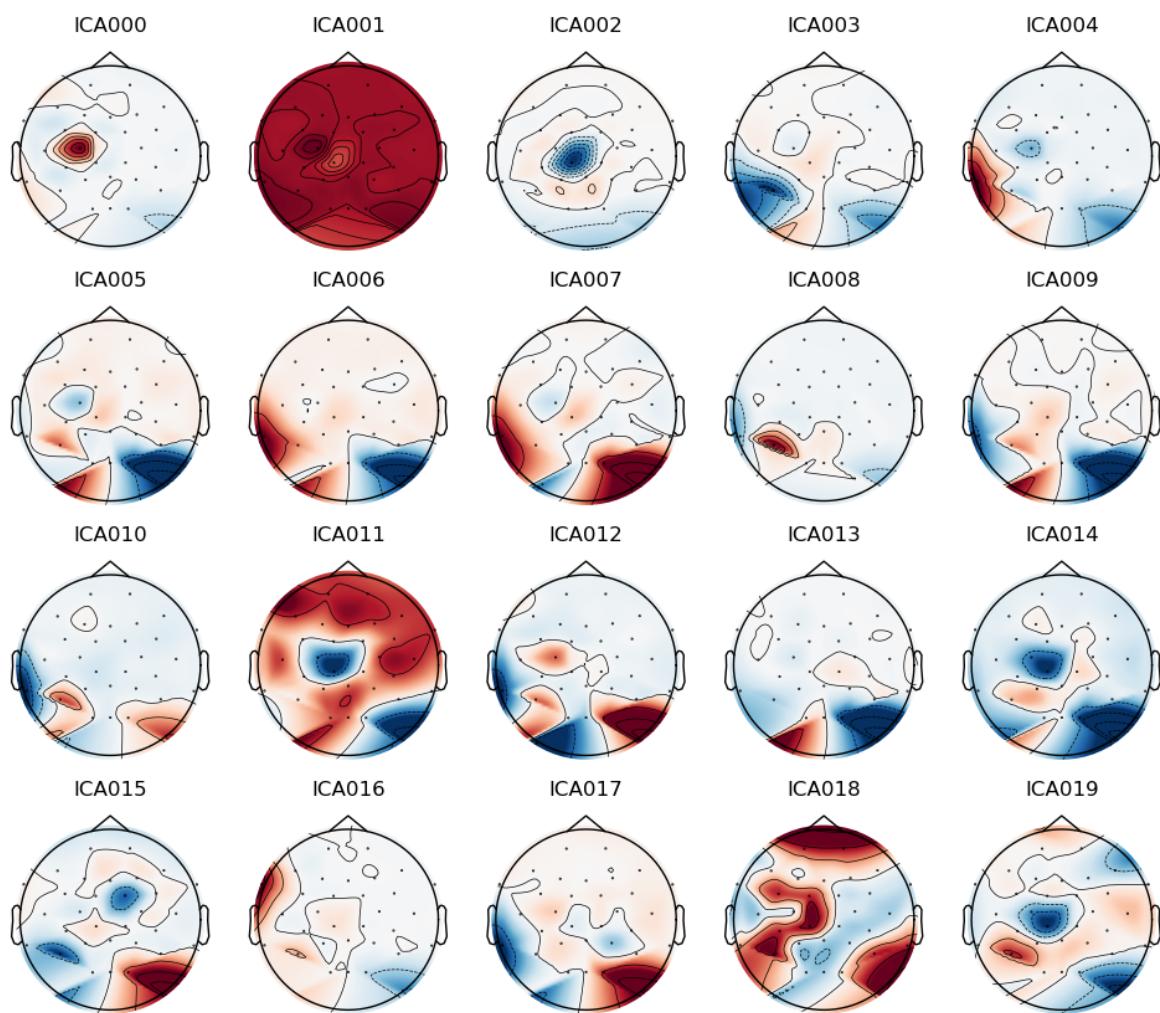


Figura A.9: Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 4

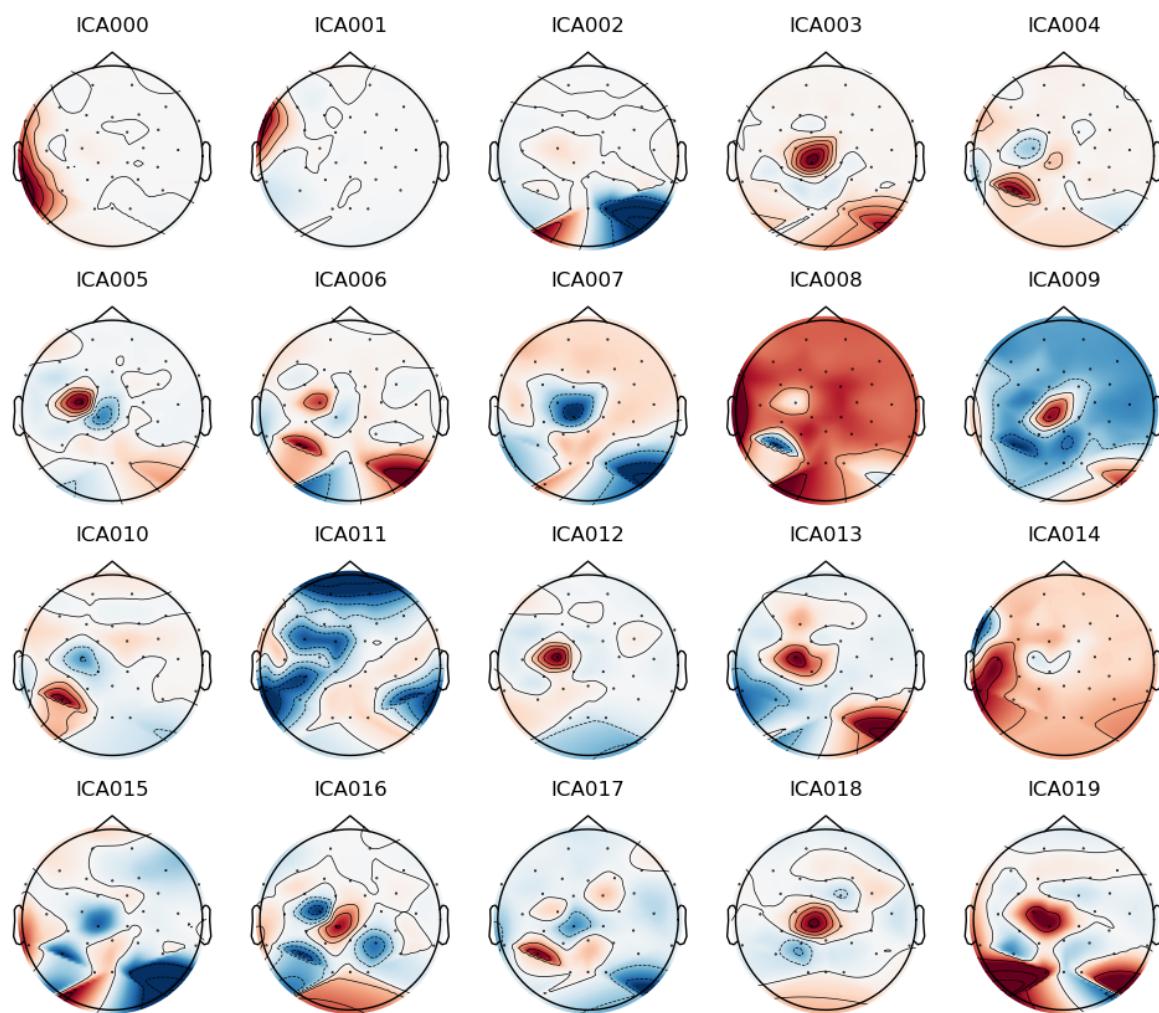


Figura A.10: Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 5

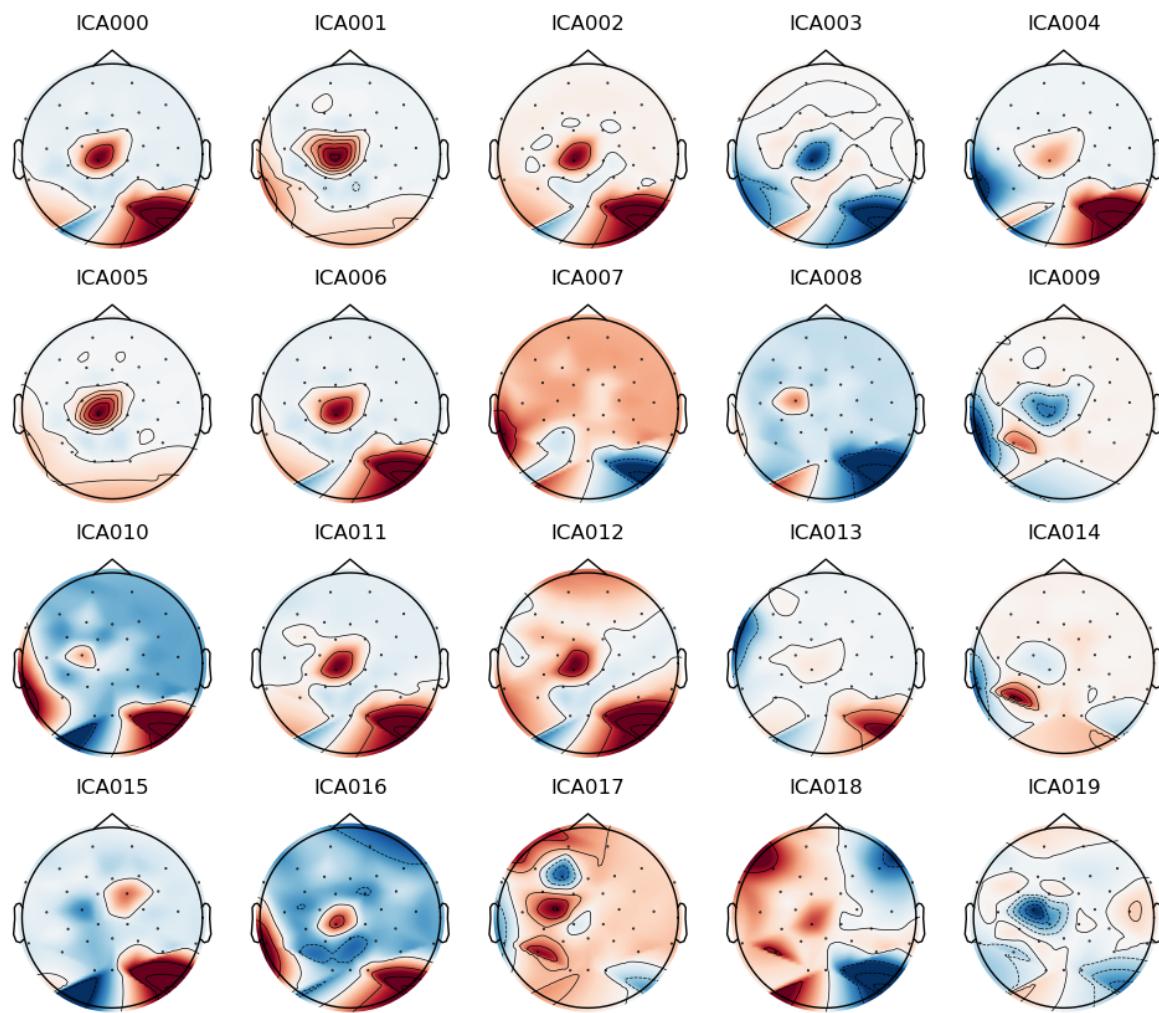


Figura A.11: Mapa topográfico de las componentes independientes del sujeto 2900, anuncio 6

A.3. ICA Anuncio 5 sujeto 6401

En este anexo se muestra un ejemplo de grabación ruidosa del sujeto 6401 (anuncio 5) y cómo es el proceso de eliminación de artefactos con ICA.

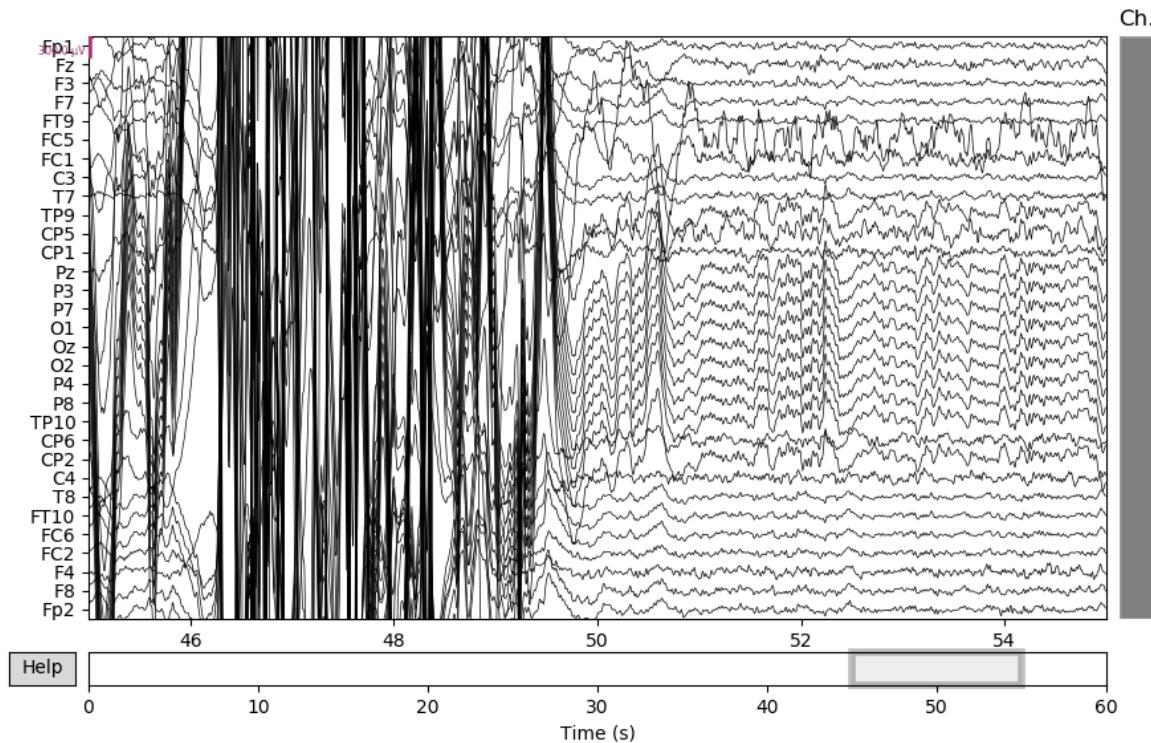


Figura A.12: Tramo del anuncio 5 del sujeto 6401 antes de la eliminación de artefactos con ICA

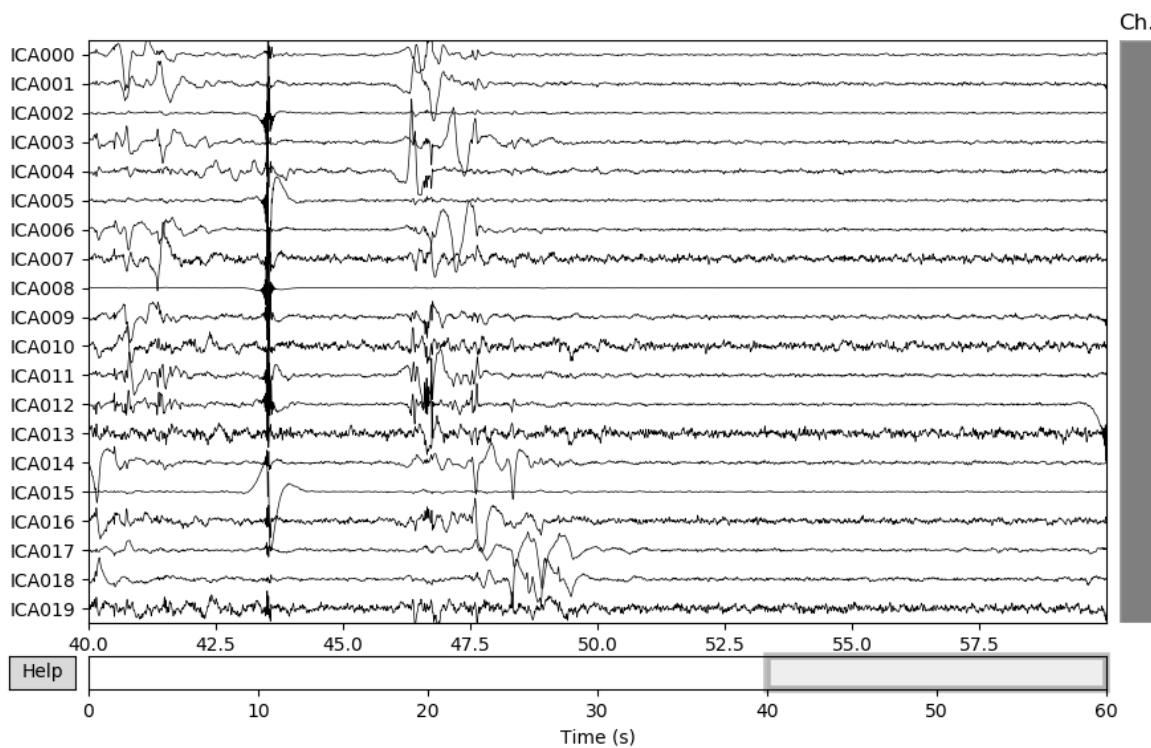


Figura A.13: Componentes independientes extraídas con ICA del tramo del anuncio 5 del sujeto 6401

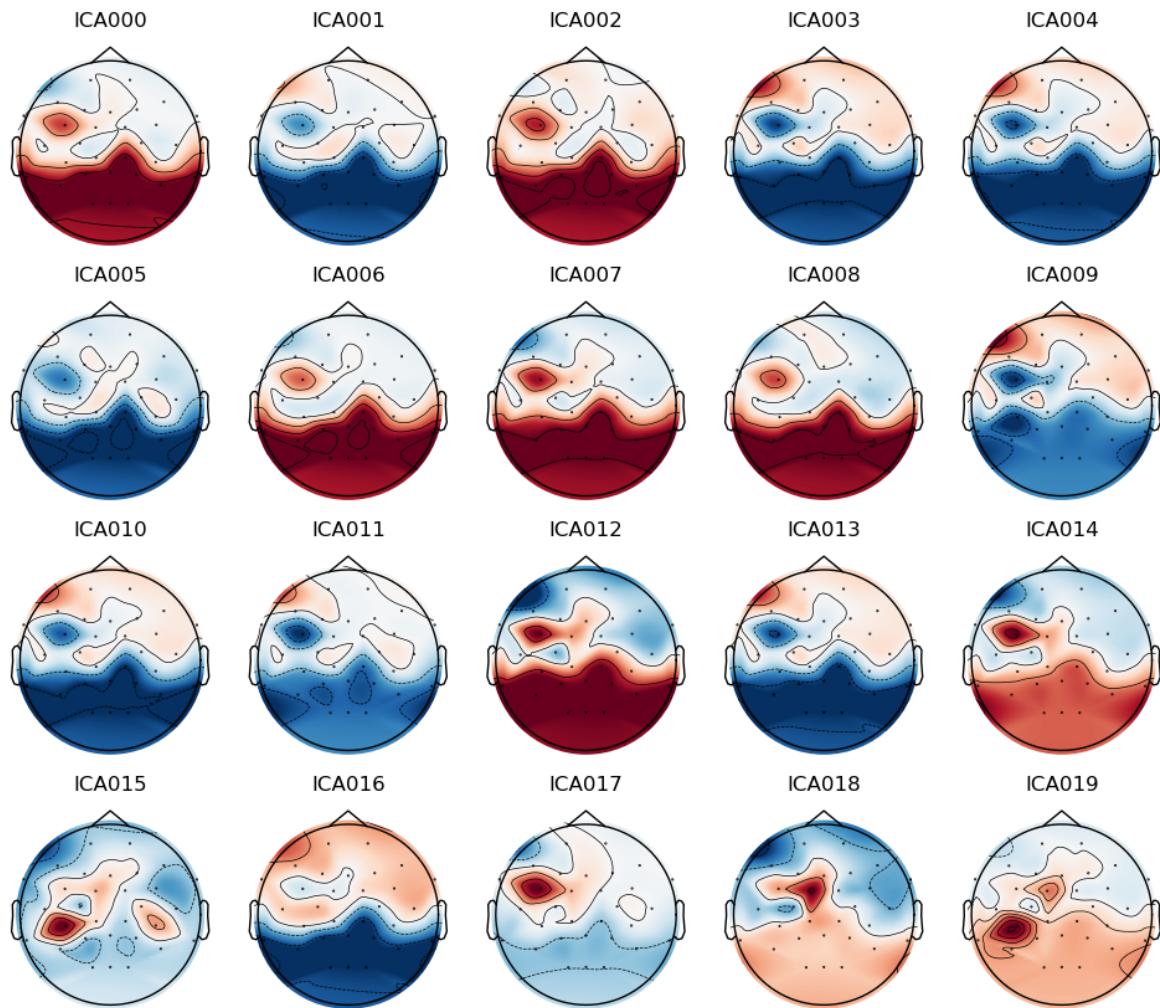


Figura A.14: Mapas topográficos obtenidos con ICA del tramo del anuncio 5 del sujeto 6401

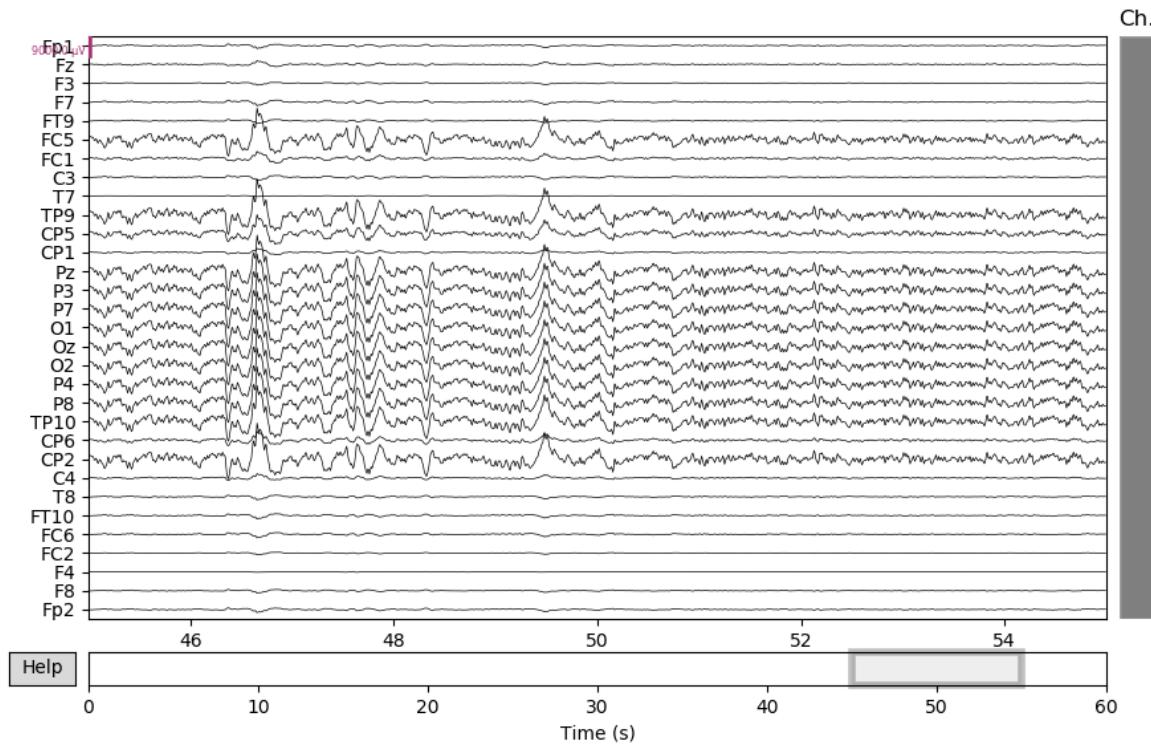


Figura A.15: Tramo del anuncio 5 del sujeto 6401 después de la eliminación de artefactos con ICA.

Bibliografía

- [1] G. Cartocci, M. Caratù, E. Modica, A. G. Maglione, D. Rossi, P. Cherubino, and F. Babiloni, “Electroencephalographic, heart rate, and galvanic skin response assessment for an advertising perception study: application to antismoking public service announcements,” *JoVE (Journal of Visualized Experiments)*, no. 126, p. e55872, 2017.
- [2] F. Babiloni, “International encyclopedia of the social and behavioral sciences,” pp. 698–702, Elsevier BV, 2nd ed., 2015.
- [3] D. Redolar Ripoll, “Neurociencia cognitiva,” *Catalunya Barcelona: Panamericana*, 2014.
- [4] C. Andreu-Sánchez, A. Contreras-García, and M.- Martín-Pascual, “Situación del neuro-marketing en España,” *El profesional de la información*, vol. 23, no. 2, 2014.
- [5] C. Morin, “Neuromarketing: the new science of consumer behavior,” *Society*, vol. 48, no. 2, pp. 131–135, 2011.
- [6] Wikimedia-Commons, “Encephalon human sagittal section multilingual.” https://commons.wikimedia.org/w/index.php?title=File:Encephalon_human_sagittal_section_multilingual.svg&oldid=406818960. [Accedido: 16 de Abril de 2020].
- [7] Wikimedia-Commons, “Neurona.” <https://commons.wikimedia.org/w/index.php?title=File:Neurona.svg&oldid=209279831>. [Accedido: 16 de Abril de 2020].
- [8] L. Sörnmo and P. Laguna, *Bioelectrical signal processing in cardiac and neurological applications*, vol. 8. Academic Press, 2005.
- [9] C. Novo-Olivas, L. Gutiérrez, and J. Bribiesca, *Mapeo Electroencefalográfico y Neurofeedback*, pp. 371–412. Febrero 2010.

- [10] F. Ramos-Argüelles, G. Morales, S. Egózcue, R. Pabón, and M. Alonso, “Técnicas básicas de electroencefalografía: principios y aplicaciones clínicas,” in *Anales del sistema sanitario de Navarra*, vol. 32, pp. 69–82, SciELO, 2009.
- [11] J. M. Reta, “Principios de electroencefalografía,” Septiembre 2012. [Accedido: 9 de Julio de 2020].
- [12] S. Cvijetic, “What are brain waves (theta, delta, alpha, beta brain waves)? what is brain-wave entrainment?,” 2018. [Accedido: 9 de Abril de 2020].
- [13] Wikimedia-Commons, “Spike-waves.” <https://commons.wikimedia.org/w/index.php?title=File:Spike-waves.png&oldid=382506611>. [Accedido: 1 de April de 2020].
- [14] A. Widmann, E. Schröger, and B. Maess, “Digital filter design for electrophysiological data—a practical approach,” *Journal of neuroscience methods*, vol. 250, pp. 34–46, 2015.
- [15] D. Bansal, R. Mahajan, *et al.*, “Design and implementation of efficient digital filter for pre-processing of eeg signals,” in *6th International Conference on Computing for Sustainable Global Development (INDIACoM)*, pp. 862–868, IEEE, 2019.
- [16] I. Winkler, S. Debener, K.-R. Müller, and M. Tangermann, “On the influence of high-pass filtering on ica-based artifact reduction in eeg-erp,” in *2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 4101–4105, IEEE, 2015.
- [17] B. Maess, E. Schröger, and A. Widmann, “High-pass filters and baseline correction in m/eeg analysis,” *Journal of neuroscience methods*, vol. 266, pp. 164–165, 2016.
- [18] B. Aldalur and M. Santamaría, “Realce de imágenes: filtrado espacial,” *Revista de telemedicina*, vol. 17, pp. 31–42, 2002.
- [19] S. Sanei and J. A. Chambers, *EEG signal processing*. John Wiley & Sons, 2013.
- [20] S. Leske and S. S. Dalal, “Reducing power line noise in eeg and meg data via spectrum interpolation,” Jan 2019.
- [21] J. J. R. Ibáñez, “Separación ciega de fuentes. fundamentos y aplicaciones en ingeniería biomédica,” in *Procesado de señales biomédicas*, pp. 57–100, Ediciones de la Universidad de Castilla-La Mancha, 2007.

- [22] A. Hyvarinen and E. Oja, “Independent component analysis: algorithms and applications,” *Neural Networks*, vol. 13, no. 4-5, pp. 411–430, 2000.
- [23] A. Tharwat, “Independent component analysis: An introduction,” *Applied Computing and Informatics*, 2020.
- [24] A. J. Bell and T. J. Sejnowski, “An information-maximization approach to blind separation and blind deconvolution,” *Neural computation*, vol. 7, no. 6, pp. 1129–1159, 1995.
- [25] S. Makeig, A. J. Bell, T.-P. Jung, and T. J. Sejnowski, “Independent component analysis of electroencephalographic data,” in *Advances in neural information processing systems*, pp. 145–151, 1996.
- [26] P. Ablin, J.-F. Cardoso, and A. Gramfort, “Faster independent component analysis by preconditioning with hessian approximations,” *IEEE Transactions on Signal Processing*, vol. 66, no. 15, pp. 4040–4049, 2018.
- [27] M. Plank, “Ocular correction ica,” *Brain product press release*, vol. 49, pp. 1–4, 2013.
- [28] “Iclabel tutorial: Eeg independent component labeling.” <https://labeling.ucsd.edu/tutorial/labels>. [Accedido: 16 Abril 2020].
- [29] C.-J. Lu, T.-S. Lee, and C.-C. Chiu, “Financial time series forecasting using independent component analysis and support vector regression,” *Decision support systems*, vol. 47, no. 2, pp. 115–125, 2009.
- [30] Y. Li, Y. Zhou, and J. Yang, “Sar image de-noising using ica basis enhancement and separation,” in *International Conference on Mechatronics and Automation*, pp. 3859–3863, 2007.
- [31] R. Davidson, P. Ekman, C. Saron, J. Senulis, and W. Friesen, “Approach-withdrawal and cerebral asymmetry: emotional expression and brain physiology,” *Journal of personality and social psychology*, vol. 58(2), p. 330–341, 1990.
- [32] R. B. Silberstein and G. E. Nield, “Measuring emotion in advertising research: Prefrontal brain activity,” *IEEE Pulse*, vol. 3, no. 3, pp. 24–27, 2012.
- [33] M. G. Wisniewski, E. R. Thompson, N. Iyer, J. R. Estepp, M. N. Goder-Reiser, and S. C. Sullivan, “Frontal midline theta power as an index of listening effort,” *NeuroReport*, vol. 26, no. 2, p. 94–99, 2015.

- [34] A. Gevins and M. E. Smith, “Neurophysiological measures of cognitive workload during human-computer interaction,” *Theoretical Issues in Ergonomics Science*, vol. 4, no. 1-2, pp. 113–131, 2003.
- [35] W. Klimesch, “Eeg alpha and theta oscillations reflect cognitive and memory performance: a review and analysis,” April 1999.
- [36] N. G. Lois, “TFG-NOEMI,” Septiembre 2020. <https://github.com/Noemiglois/TFG-NOEMI.git>.
- [37] G. Trejo-Alcantara and N. Castañeda-Villa, “Efecto del pre-procesamiento del eeg en el análisis por componentes independientes: reducción del artefacto del implante coclear en los potenciales evocados auditivos,” *Revista mexicana de ingeniería biomédica*, vol. 38, no. 1, pp. 382–389, 2017.
- [38] M. Klug and K. Gramann, “Identifying key factors for improving ica-based decomposition of eeg data in mobile and stationary experiments,” *bioRxiv*, 2020.